



Análise Topológica de Dados Aplicada a Dados de Biologia

*Homologia Persistente na Classificação de Estados
Conformacionais da Proteína MBP*

Anthony dos Anjos Marques


Universidade Federal de Sergipe – Departamento de Matemática
Bacharelado em Matemática Aplicada e Computacional

Orientador: Prof. Dr. Danilo Dias da Silva

- 1 Introdução
- 2 Contexto Biológico e Dinâmica Estrutural
- 3 Fundamentos de Topologia Algébrica
- 4 Homologia Persistente
- 5 Inferência Estatística
- 6 Redução de Dimensionalidade e Aprendizado de Máquina
- 7 RMSD como Método de Referência (Baseline)
- 8 Metodologia
- 9 Resultados
- 10 Conclusão


Motivação

- Proteínas não são entidades rígidas: transitam entre estados conformacionais para exercer funções biológicas.
- Debate clássico sobre o mecanismo de ligação proteína-ligante:
 - **Encaixe induzido** (*Induced Fit*);
 - **Seleção conformacional** (*Conformational Selection*).
- Métricas geométricas clássicas (RMSD) frequentemente falham em capturar correlações não-lineares e variações dinâmicas globais.




A Proteína de Ligação à Maltose (MBP)

- Encontrada em *Escherichia coli*; transporta maltodextrinas.
- Dois domínios globulares conectados por uma região de dobradiça (*hinge*).
- Transita entre dois estados conformacionais:
 - **Apo** – aberta, livre de ligante;
 - **Holo** – fechada, associada ao ligante (maltose).



Objetivo: investigar, fundamentar e aplicar a Análise Topológica de Dados (TDA) e a Homologia Persistente na classificação de estados conformacionais da MBP.



O Modelo de Rede Anisotrópica (ANM)

- Abordagem *coarse-grained*: cada resíduo $\rightarrow$ um nó (átomo C_α).
- Interações modeladas por molas elásticas dentro de um raio de corte.
- Matriz Hessiana H (segundas derivadas do potencial elástico).
- Decomposição espectral $\rightarrow$ 20 primeiros modos normais de baixa frequência.
- Resultado: **Matriz de Correlação Cruzada** C , com $C_{ij} \in [-1, 1]$.

Transformação da correlação em dissimilaridade dinâmica:

$$D_{ij} = 1 - |C_{ij}|$$

- $C_{ij} \rightarrow \pm 1 \Rightarrow D_{ij} \rightarrow 0$ (resíduos dinamicamente próximos);
- D **não** é uma métrica clássica: viola identidade dos indiscerníveis e desigualdade triangular;
- Classificada como **medida de dissimilaridade simétrica não-negativa**;
- A filtração de Vietoris-Rips prescinde desses axiomas: opera sobre um grafo ponderado completo.

Complexos Simpliciais

Definição. Para qualquer conjunto de pontos $a_1, \dots, a_k \in \mathbb{R}^n$, definimos seu fecho convexo como:

$$\text{conv}(a_1, \dots, a_k) = \left\{ \sum_{1 \leq i \leq k} t_i a_i \mid \sum_{j=1}^k t_j = 1, t_j \geq 0 \right\}.$$

Portanto, podemos dizer que Δ_n , definido como simplexo padrão

$$\Delta_n = \left\{ x = (x_1, \dots, x_{n+1}) \in \mathbb{R}^{n+1} \mid x_i \geq 0 \text{ e } \sum_{i=1}^{n+1} x_i = 1 \right\}.$$

é o fecho convexo dos vetores $e_1, \dots, e_{n+1} \in \mathbb{R}^{n+1}$, onde

$$e_i = (0, \dots, 1, 0, \dots, 0) \quad (\text{i-ésima coordenada igual a 1, as demais iguais 0}).$$

Complexos Simpliciais


Definição. Um complexo simplicial sobre V é um conjunto K de subconjuntos de V tal que, para todo $\sigma \in K$ e todo $\tau \subset \sigma$ não vazio, $\tau \in K$.




Δ_0



Δ_1



Δ_2



Δ_3

Definição. Seja K um complexo simplicial com conjunto de vértices $V = \{1, \dots, n\}$. Em $\mathbb{R}^{n+1}$, considere, para cada $i \in \{0, \dots, n\}$, o vetor $e_i = (0, \dots, 1, 0, \dots, 0)$. Seja $|K|$ o subconjunto de $\mathbb{R}^{n+1}$ definido por:

$$|K| = \bigcup_{\sigma \in K} \text{conv}(\{e_j, j \in \sigma\})$$

onde conv representa o fecho convexo. Munido da topologia de subespaço, $(|K|, \tau_{|K|})$ é um espaço topológico, que denominamos realização topológica de K .

Complexos Simpliciais

Definição. Seja $(X, \mathcal{T})$ um espaço topológico. Uma triangulação de X é um complexo simplicial K tal que sua realização topológica $(|K|, \mathcal{T}_{|K|})$ é homeomorfa a $(X, \mathcal{T})$.




Figura: À esquerda, a triangulação de um círculo. À direita, a triangulação de um toro.

Definição. Seja K um complexo simplicial e $n \geq 0$. O conjunto de n -cadeias de K , denotado $C_n(K)$, é o conjunto cujos elementos são as somas formais:

$$\sum_{\sigma \in K_{(n)}} \epsilon_{\sigma} \cdot \sigma, \quad \text{onde } \forall \sigma \in K_{(n)}, \epsilon_{\sigma} \in \mathbb{Z}/2\mathbb{Z}.$$


Definição. Seja $n \geq 1$ e $\sigma = [x_0, \dots, x_n] \in K_{(n)}$ um símplexo de dimensão n . A fronteira de σ é o elemento de $C_{n-1}(K)$ definido por:

$$\partial_n \sigma = \sum_{\substack{\tau \subset \sigma \\ |\tau| = |\sigma| - 1}} \tau.$$


O operador ∂_n estende-se por linearidade a uma aplicação linear $\partial_n : C_n(K) \rightarrow C_{n-1}(K)$.

Cadeias, Fronteira e Homologia

Um exemplo das 1-cadeias $C_1(K)$ do complexo $K = \{[0], [1], [2], [0, 1], [0, 2]\}$.




Considerando o complexo $K = \{[0], [1], [2], [3], [0, 1], [0, 2], [1, 2], [1, 3], [2, 3], [0, 1, 2]\}$, aplicando o operador fronteira no simplexo $[0, 1]$, temos:



Definição. Seja K um complexo simplicial. O n -ésimo grupo de homologia de K é o quociente:

$$H_n(K) = Z_n(K)/B_n(K).$$

A dimensão deste espaço vetorial é o n -ésimo número de Betti, dado por $\beta_n(K) = \dim H_n(K) = \dim Z_n(K) - \dim B_n(K)$. Geometricamente, β_0 conta o número de componentes conexas, β_1 o número de “buracos” ou ciclos unidimensionais, e β_2 o número de cavidades fechadas.




Inferência Topológica: do Ponto à Forma


Definição. Seja $X \subset \mathbb{R}^n$ e $t \geq 0$. O t -espessamento de X , denotado X^t , é o conjunto de pontos do espaço ambiente com o máximo de distância t de X :

$$X^t = \{y \in \mathbb{R}^n \mid \exists x \in X, \|x - y\| \leq t\} = \bigcup_{x \in X} \overline{B}(x, t).$$


Lê-se que X^t é uma união de bolas fechadas centradas em cada ponto de X .



$X^{0.1}$




$X^{0.15}$



$X^{0.2}$

Inferência Topológica: do Ponto à Forma

Teorema do Nervo. Suponha que X seja um subconjunto de $\mathbb{R}^n$. Considere uma cobertura $\mathcal{U} = \{U_i\}_{1 \leq i \leq N}$ de X tal que cada um dos U_i são bolas fechadas e convexas. Então $\mathcal{N}(\mathcal{U})$ é homotopia equivalente a X .



Isso permite recuperar $H_i(X)$ a partir de $H_i(X^t)$, para t adequado.


Complexo de Čech e de Rips

Definição. (Complexo de Čech). Sejam $X \subset \mathbb{R}^n$ finito e $t \geq 0$. Considere a coleção $\mathcal{V}^t = \{\overline{B}(x, t) \mid x \in X\}$. O nervo desta coleção é denotado $\check{\text{Cech}}^t(X)$ e é chamado de complexo de Čech de X no instante t .


Definição. (Complexo de Rips). Sejam $X = \{x_1, \dots, x_N\} \subset \mathbb{R}^n$ um conjunto finito e $t \geq 0$. O complexo de Rips de X no instante t , denotado $\text{Rips}^t(X)$, é o complexo do grafo $G^t = (\check{\text{Cech}}^t(X))$ cujo conjunto de vértices é $\{1, \dots, N\}$ e cujas arestas são os pares (i, j) tais que a distância entre eles obedece a $\|x_i - x_j\| \leq 2t$.



G^t



$\check{\text{Cech}}^t(X)$






$\text{Rips}^t(X)$

Curvas de Betti

Definição. Seja $X \subset \mathbb{R}^n$ e $i \geq 0$. A i -ésima curva de Betti de X é a aplicação

$$\begin{aligned}\beta_i(t) : \mathbb{R}^+ &\longrightarrow \mathbb{N} \\ t &\longmapsto \beta_i(X^t)\end{aligned}$$

Podemos observar essa definição por uma amostra ruidosa de um círculo X .



Definição. Uma **filtração** de um complexo simplicial E é uma família de subcomplexos $\mathbb{X} = (X^t)_{t \in \mathbb{R}^+}$ de E tais que $X_s \subseteq X_t$ sempre que $s \leq t$.

Aplica-se isso à família de complexos de Vietoris-Rips:

$$X_{t_1} \subseteq X_{t_2} \subseteq X_{t_3} \subseteq \cdots \subseteq X_{t_n}$$

A inclusão $i : X_s \hookrightarrow X_t$ induz um homomorfismo nos grupos de homologia:

$$(i_*)_k : H_k(X_s) \longrightarrow H_k(X_t)$$

Propriedade Funtorial: Permite rastrear a evolução dos ciclos H_k , identificando o momento exato em que um ciclo nasce e morre.

Definição. (Módulo de Persistência) A coleção dos espaços vetoriais $V_t = H_k(X_t)$ acompanhada das aplicações induzidas $v_{s,t} : V_s \rightarrow V_t$.

Teorema da Decomposição Todo módulo de persistência de dimensão finita decompoe-se de forma única em somas diretas de módulos intervalares $\mathbb{I}(b_i, d_i)$:

$$V \cong \bigoplus_{i=1}^m \mathbb{I}(b_i, d_i)$$

Representações Equivalentes:

- **Código de Barras (Barcode):** Conjunto de intervalos de vida $[b_i, d_i)$.
- **Diagrama de Persistência:** Multiconjunto de pontos $(b_i, d_i) \in \mathbb{R}^2$.

Módulos de Persistência e Barcodes

À medida que o parâmetro de filtração t avança, a topologia do complexo se altera com o surgimento e desaparecimento de ciclos homológicos. Esse histórico é sintetizado nos resumos de persistência:




Figura: $t = 0.50$




Figura: $t = 1.45$




Figura: $t = 1.62$




Figura: $t = 1.84$

Módulos de Persistência e Barcodes




Figura: Código de Barras (*Barcode*)




Figura: Diagrama de Persistência

Paisagens de Persistência (Persistence Landscapes)



Definição. Dado um diagrama de persistência com intervalos $\mathcal{B} = \{(b_i, d_i)\}_{i=1}^m$, define-se para cada ponto a função auxiliar:

$$f_{(b,d)}(t) = \max(0, \min(t - b, d - t)).$$




A paisagem de persistência é a sequência de funções $\lambda_k : \mathbb{R} \rightarrow \mathbb{R}$ definidas por:

$$\lambda_k(t) = k\text{-ésimo maior valor do conjunto } \{f_{(b_i,d_i)}(t)\}_{i=1}^m,$$

adotando $\lambda_k(t) = 0$ caso $k > m$.



Paisagens de Persistência (Persistence Landscapes)



Paisagens de Persistência (Persistence Landscapes)

Essa vetorização através das Paisagens de Persistência nos dá as seguintes vantagens:

- Mapeia a topologia não-linear em um espaço de Banach $L^p(\mathbb{N} \times \mathbb{R})$;
- Para $p = 2$: Espaço de **Hilbert** $\Rightarrow$ produto interno $\langle \lambda, \lambda' \rangle_{L^2}$ bem definido;
- Permite o uso direto de Máquinas de Vetores de Suporte (SVM) e Análise de Componentes Principais (PCA).

Área total sob a paisagem de persistência:

$$X = \sum_{k=1}^{\infty} \int_{\mathbb{R}} \lambda_k(t) dt$$

Teste de hipóteses entre as populações Fechada (μ_1) e Aberta (μ_2):

$$H_0 : \mu_1 = \mu_2 \quad \text{vs.} \quad H_a : \mu_1 \neq \mu_2$$


Amostra pequena ($n = 14$) $\Rightarrow$ normalidade não garantida $\Rightarrow$ **teste não-paramétrico**.

$$T_{\text{obs}} = |\bar{X}_1 - \bar{X}_2|, \quad \text{Valor-p} = \frac{1}{M} \sum_{i=1}^M \mathbb{I}(T_i \geq T_{\text{obs}})$$

- $n = 14$ (7 Apo + 7 Holo) $\Rightarrow \binom{14}{7} = 3432$ permutações possíveis;
- Não assume distribuição prévia dos dados;
- Rejeição de H_0 (valor-p pequeno) $\Rightarrow$ evidência estatística de separabilidade das assinaturas topológicas.

ISOMAP e Dimensionalidade Intrínseca

- PCA/MDS clássico assumem geometria euclidiana $\rightarrow$ distorcem a variedade da proteína.
- **ISOMAP**: grafo de vizinhança $\rightarrow$ distâncias geodésicas (Dijkstra/Floyd-Warshall) $\rightarrow$ MDS clássico.
- Gráfico Scree indica a dimensão intrínseca ótima (ponto de “cotovelo”).
- Usado apenas para diagnóstico visual (não admite projeção *out-of-sample*).



SVM: Margem Rígida


Hiperplano separador:

$$f(x) = w \cdot x + b = 0$$

com $y_i(w \cdot x_i + b) \geq 1$.

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i(w \cdot x_i + b) \geq 1, \quad \forall i$$

- Margem geométrica: $\frac{2}{\|w\|}$;
- Problema dual: resolvido via multiplicadores de Lagrange α_i ;
- Vetores de suporte: pontos com $\alpha_i^* > 0$.




Margem Suave e Kernels

Margem suave (dados não perfeitamente separáveis): variáveis de folga $\xi_i \geq 0$ e constante C :

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_i \xi_i$$

Não linear: mapeamento Φ para espaço de características, via *kernel* $K(x_i, x_j) = \Phi(x_i) \cdot \Phi(x_j)$ (Teorema de Mercer).

- Neste trabalho, o mapeamento Φ já está embutido na construção da Paisagem de Persistência ($\lambda_k(t)$) $\rightarrow$ kernel de Mercer satisfeito naturalmente.



Validação Cruzada: Leave-One-Out (LOOCV)

Com amostras pequenas, dividir os dados em treino e teste fixos atrapalha os algoritmos e causa erros ou sobreajuste, sendo melhor usar a validação cruzada *Leave-One-Out* (LOOCV) para obter um resultado estável.

$$E_{\text{LOO}} = \frac{1}{n} \sum_{i=1}^n \mathbb{I} \left(g^{\setminus i}(x_i) \neq y_i \right)$$

- Necessária pelo tamanho amostral restrito ($n = 14$);
- Estimador quase não-enviesado do erro de generalização (Luntz–Brailovsky);
- Padronização e PCA ajustados **exclusivamente** sobre o conjunto de treino em cada iteração – sem vazamento de dados.

RMSD e o Algoritmo de Kabsch

Neste trabalho, o RMSD é usado como métrica base tradicional (distância euclidiana estática) para comparar as formas Apo e Holo da MBP, servindo como referência para avaliar as novas métricas topológicas estudadas.

$$\text{RMSD}(V, W) = \min_{R, \vec{t}} \sqrt{\frac{1}{N} \sum_{i=1}^N \|Rv_i + \vec{t} - w_i\|^2}$$

- Solução exata via SVD da matriz de covariância (Algoritmo de Kabsch);
- Métrica puramente geométrica/estática – não captura correlações dinâmicas globais;
- Sem escala absoluta de interpretação: cutoffs (ex. 3 Å) dependem do comprimento da cadeia (Maiorov & Crippen);
- Usado como método de comparação (baseline) contra o classificador topológico.


- Conjunto de calibração: 14 estruturas de Kovacev-Nikolic et al. (2016) – 7 Apo, 7 Holo;
- Expansão: mineração de **29 novas estruturas** de alta resolução no PDB;
- Limpeza via ProDy: extração de coordenadas (x, y, z) dos C_α da Cadeia A;
- Matrizes espaciais padronizadas 370×3 por estrutura.

- ANM (ProDy) $\rightarrow$ 20 primeiros modos normais $\rightarrow$ matriz C (370×370);
- $D_{ij} = 1 - |C_{ij}| \rightarrow$ filtração de Vietoris-Rips com $t_{\max} = 0.7$;
- Escolha de $t_{\max}$: laços de H_1 nascem em $t \approx 0.2$ e morrem antes de $t = 0.6$.

Extração da Dinâmica e Filtração




$d = 1.0\text{\AA}$




$d = 4.0\text{\AA}$




$d = 5.5\text{\AA}$




$d = 6.0\text{\AA}$




$d = 7.0\text{\AA}$



$d = 8.0\text{\AA}$



$d = 9.0\text{\AA}$




$d = 12.0\text{\AA}$


Vetorização e Classificação

- Paisagem de persistência: $K = 73$ camadas $\times R = 50$ pontos $\rightarrow$ vetor $\mathbb{R}^{3650}$;
- Padronização + PCA (3 componentes principais, $\sim 52,5\%$ da variância em H_1);
- SVM linear ($C = 1,0$), validado por LOOCV, sem vazamento de dados.

1ANF (Aberta) - Persistence Landscape



1OMP (Fechada) - Persistence Landscape



Teste de Permutação: Resultado

- $\bar{X}_{\text{Holo}} = 0,269778$, $\bar{X}_{\text{Apo}} = 0,290403$
- $T_{\text{obs}} = 0,020625$
- Das $M = 3432$ permutações, apenas 2 superaram T_{obs}

$$\text{valor-p} = \frac{2}{3432} \approx 5,83 \times 10^{-4} \ll \alpha = 0,05$$

Conclusão: rejeita-se H_0 – a assinatura topológica das flutuações difere significativamente entre Apo e Holo.

Validação Independente: SVM vs. RMSD



Avaliação sobre as 29 estruturas mineradas independentemente:

Modelo	Acurácia	Precisão	Sensibilidade	Especificidade	F1
SVM Topológico	93,10%	91,67%	91,67%	94,12%	91,67%
RMSD Médio (baseline)	89,66%	84,62%	91,67%	88,24%	88,00%

- Mesmo número de falsos negativos (1DMB, em ambos);
- SVM: menos falsos positivos (1 vs. 2);
- Diferença pontual (29 amostras) – sem teste de McNemar formal.

Projeção do Hiperplano de Decisão

Inferência Topológica das Proteínas Desconhecidas



Caso 7Z7H: RMSD $> 26 \text{ \AA}$ (erro catastrófico).

- Causa: *gaps* de numeração na cadeia (mismatch de índices);
- RMSD exige correspondência estrita de índices $\rightarrow$ colapsa;
- SVM topológico opera sobre a matriz **intrínseca** de conectividade (ANM) $\rightarrow$ invariante a artefatos de numeração;
- Classificação correta (“Aberta”) mantida pelo método topológico.

- **1DMB** (rotulada Holo): classificada como Aberta por *ambos* os métodos – possível falha de cristalização do ligante.
- **2N45** (rotulada Apo): RMSD → Aberta; SVM → Fechada, com baixa confiança (distância ao hiperplano $d = 0,1985$).
- Resultado limítrofe compatível com a hipótese de **Seleção Conformacional**: o método topológico capta estados transientes de flexibilidade latente.

- A transformação $D_{ij} = 1 - |C_{ij}|$ traduz a dinâmica do ANM em um espaço de dissimilaridade apto à TDA;
- A Homologia Persistente e as Paisagens de Persistência fornecem uma base rigorosa (espaço de Hilbert) para a classificação estatística e via SVM;
- O teste de permutação confirma separabilidade estatística significativa ($p \approx 5,83 \times 10^{-4}$);
- O classificador topológico superou o RMSD clássico, com maior robustez frente a artefatos estruturais;
- Evidências compatíveis com o modelo biológico de Seleção Conformacional.

Obrigado!

“É justo que muito me custe o que muito me vale.”

— Santa Teresa d'Ávila

Anthony dos Anjos Marques

Orientador: Prof. Dr. Danilo Dias da Silva
Departamento de Matemática – UFS