

Sumário

1	Fundamentação Teórica	3
1.1	Da Estrutura Estática à Dinâmica: Cristalografia e Modelo de Grão Grosso	3
1.2	Termodinâmica do Fechamento Conformacional e Seleção Conformacional	4
1.3	O Formalismo da Rede Anisotrópica (ANM) e a Matriz Hessiana Estrutural	6
1.3.1	Formulação Tridimensional da Energia Potencial Elástica . . .	6
1.3.2	Construção Analítica da Matriz Hessiana	7
1.4	Decomposição Espectral, Truncamento e a Correlação Cruzada	8
1.4.1	Modos Normais e Truncamento de Baixa Frequência	8
1.4.2	Derivação da Matriz de Correlação Cruzada	9
1.5	Transição Métrica: Da Geometria Euclidiana à Topologia Dinâmica .	9
1.5.1	O Significado Probabilístico e a Pseudométrica	10
1.6	Redução de Dimensionalidade e Visualização do Espaço de Comunicação: ISOMAP	10
1.6.1	A Limitação do MDS Clássico	11
1.6.2	A Solução via ISOMAP e Distâncias Geodésicas	11
1.6.3	Dimensionalidade Intrínseca e o Gráfico Scree (Cotovelo) . . .	12
1.7	Definições Topológicas e a Geometria da Comunicação Dinâmica . . .	13
1.7.1	Fundamentos de Topologia Algébrica	14
1.7.2	Filtração e Persistência no Espaço Dinâmico	15
1.7.3	Paisagens de Persistência e Espaços Lineares Funcionais . . .	16
2	Inferência Estatística sobre Invariantes Topológicos	16
2.1	A Variável Aleatória Topológica X	17
2.1.1	Da Paisagem de Persistência ao Escalar	17
2.1.2	Finitude da Média e da Variância	17
2.2	Leis Limites e a Necessidade de Testes Não-Paramétricos	18
2.3	Formulação do Teste de Permutação (Valor- p)	18
2.3.1	Populações e a Estatística t	18
2.3.2	Distribuição Nula e Significado Topológico	19

3	A aplicação do Machine-Learning	20
3.1	Classificação Temática via Máquinas de Vetores de Suporte (SVM)	20
3.1.1	O Hiperplano Separador e a Regra de Decisão	20
3.1.2	Maximização da Margem e o Problema Primal Rígido	20
3.1.3	Formulação de Margens Suaves e Variáveis de Folga	21
3.1.4	Formulação Dual e o Truque do Kernel no Espaço de Paisagens	21
3.1.5	Métrica de Confiança e Interpretação Topológico-Termodinâmica	23
3.2	Validação Estrutural e Comparação Geométrica: RMSD e o Algoritmo de Kabsch	24
3.2.1	Definição Matemática do RMSD	24
3.2.2	O Problema da Sobreposição Óptima (Algoritmo de Kabsch)	25
3.2.3	Interpretação Biofísica da Distância	26
4	Resultados e Discussão	26
4.1	O Pipeline Computacional do Estudo	27
4.2	Pipeline Topológico e Aprendizado de Máquina	27
4.3	Projeção de Novas Estruturas e Distância ao Hiperplano	28
4.4	Validação Estrutural Ortogonal via Algoritmo de Kabsch (RMSD)	28
4.4.1	Análise das Divergências Topológico-Geométricas	29

Monografia

-

23 de junho de 2026

1 Fundamentação Teórica

1.1 Da Estrutura Estática à Dinâmica: Cristalografia e Modelo de Grão Grosso

A proteína de ligação à maltose é uma proteína bacteriana encontrada em *Escherichia coli*, onde sua função primária é ligar e transportar moléculas de açúcar através das membranas celulares, fornecendo energia à bactéria [3]. Embora às vezes cause doenças graves, a maioria das cepas de *E. coli* é não patogênica e, na verdade, benéfica. Essas bactérias colonizam o trato gastrointestinal de humanos e animais e protegem o intestino de bactérias nocivas [10]. Além disso, *E. coli* é o organismo vivo mais bem conhecido e é usado para estudar vários processos celulares [16]. Em nosso artigo, usamos métodos topológicos para estudar a MBP.

Enquanto realiza funções biológicas, a MBP muda sua estrutura. As 14 estruturas cristalográficas da MBP utilizadas como modelo gabarito foram obtidas por cristalografia de raios X e depositadas no *Protein Data Bank* (PDB). A cristalografia de raios X é uma técnica experimental onde a proteína purificada é forçada a precipitar de uma solução até formar um cristal sólido e ordenado [14]. Quando um feixe de raios X é disparado contra esse cristal, os elétrons dos átomos da proteína difratam (espalham) os raios em várias direções. Computadores analisam o padrão e a intensidade desses feixes difratados para reconstruir um "mapa de densidade eletrônica", o que permite aos pesquisadores deduzir as coordenadas espaciais (x, y, z) exatas de quase todos os átomos da biomolécula no espaço tridimensional. É essencialmente uma fotografia de alta resolução, mas estática, da proteína.

Cada estrutura da MBP contém aproximadamente 3000 átomos pesados. Trabalhar diretamente com todos eles implicaria operar num espaço de configurações $\mathbb{R}^{3 \times 3000} \cong \mathbb{R}^{9000}$, tornando inviável tanto a construção computacional do Complexo de Vietoris-Rips quanto a interpretação biológica dos invariantes topológicos obtidos [7]. A solução adotada é o **modelo de grão grosso** (*coarse-grained model*): agrupam-se todos os átomos de cada resíduo de aminoácido num único nó representativo, reduzindo os 3000 átomos a $N = 370$ pontos [11].

Definição 1 (Espaço de Configurações Reduzido). *Seja $N = 370$ o número de resíduos da MBP. Denota-se por $\mathbf{r}_i \in \mathbb{R}^3$ a posição do nó representativo do i -ésimo*

resíduo. Uma conformação da proteína é o vetor de estado espacial:

$$\mathbf{R} = (\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_N) \in \mathbb{R}^{3 \times N} \cong \mathbb{R}^{1110}.$$

O espaço de conformações termicamente acessíveis é um subespaço de $\mathbb{R}^{1110}$, e é este subespaço reduzido que a homologia persistente irá caracterizar topologicamente.

O nó representativo escolhido é o **carbono-alfa** (C_α), o átomo central do esqueleto peptídico do qual partem tanto as ligações peptídicas (que unem resíduos consecutivos) quanto as cadeias laterais (que variam entre os 20 aminoácidos). A escolha geométrica é justificada por três razões complementares atestadas na literatura estrutural:

1. **Estabilidade geométrica:** as cadeias laterais apresentam grande mobilidade rotacional (ruído conformacional térmico), enquanto a cadeia principal de C_α forma uma curva contínua e geometricamente estável que define a topologia de contactos essenciais da proteína [6].
2. **Redução de complexidade algorítmica:** ao focar nos C_α , o espaço de trabalho métrico cai de $\mathbb{R}^{9000}$ para $\mathbb{R}^{1110}$, reduzindo drasticamente o custo computacional da matriz de distâncias e da subsequente filtração topológica [6].
3. **Base para a Dinâmica de Redes:** como demonstrado formalmente por Atilgan et al. [1], os átomos C_α funcionam como os *nós* da rede elástica, e as distâncias de equilíbrio entre eles representam os parâmetros geométricos estritamente necessários para construir a Matriz Hessiana do sistema mecânico.

1.2 Termodinâmica do Fechamento Conformacional e Seleção Conformacional

A função biológica da MBP — capturar e transportar moléculas de maltose no espaço periplasmático — é governada por uma arquitetura estrutural altamente flexível. A proteína é composta por dois domínios globulares principais (N-terminal e C-terminal) conectados por uma região de laços flexíveis que actua como uma dobradiça (*hinge*). O mecanismo de captura do ligante assemelha-se ao fechamento de uma armadilha (*Venus flytrap mechanism*), resultando em alterações geométricas macroscópicas na estrutura da macromolécula [14].

Estudos baseados em cristalografia de raios X e dinâmica molecular, como os conduzidos por Bucher et al. [5], classificam as conformações da MBP em três macroestados estruturais principais (ver Figura 1):

1. **Estado Aberto (*Open*):** Caracteriza-se por uma grande separação angular e espacial entre os dois domínios globulares. É a forma predominante da proteína no estado *apo* (livre de ligante), representando o mínimo global de energia do sistema na ausência do açúcar.
2. **Estado Semi-fechado (*Semi-closed*):** Um estado intermediário transiente. A estrutura apresenta um fechamento parcial da fenda interdominial.

3. **Estado Fechado (*Closed*):** Os domínios globulares aproximam-se significativamente, engolfando completamente o ligante na fenda catalítica. Este é o estado funcional ativo, frequentemente associado à forma *holo* (ligada à maltose).




Figura 1: Representação das transições conformacionais da MBP. Da esquerda para a direita: Estado Aberto, Semi-fechado transiente e Fechado estabilizado pelo ligante (em vermelho). Fonte: Adaptado de Bucher et al. [5].

Historicamente, assumia-se que a transição do estado aberto para o fechado era estritamente induzida pelo impacto mecânico da entrada da maltose na fenda (modelo de *Encaixe Induzido*). Contudo, a biofísica estrutural contemporânea demonstra que a MBP opera sob o princípio da **Seleção Conformacional** [13]. Segundo este modelo, a proteína não é estática; ela "respira" e oscila naturalmente entre as formas aberta e semi-fechada através de flutuações térmicas, mesmo sem a presença do ligante.

O papel da maltose, portanto, não é forçar o fechamento da dobradiça, mas sim *estabilizar* a forma fechada pré-existente. Quando o ligante se aloja na fenda, ele estabelece uma rede complexa de ligações de hidrogénio que compensa a tensão elástica da proteína, tornando a conformação fechada termodinamicamente favorável [5].

É precisamente esta vasta gama de flutuações e movimentos cooperativos de dobradiça — que ocorrem independentemente da presença do açúcar — que torna a geometria euclidiana estática insuficiente para classificar as proteínas. Para mapear com rigor estes padrões de oscilação em trajetórias matemáticas, o sistema deve ser modelado através das suas interações de rede elástica.

Em [11] é coletado um conjunto de 14 proteínas, separadas em: sete conformações fechadas e sete conformações abertas. Há uma diferença entre elas usando energias de deformação; a conformação fechada energeticamente mais favorável liga uma molécula de açúcar, enquanto sua contraparte aberta requer maiores energias de deformação e pode ou não se envolver no processo de ligação. A lista das quatorze estruturas da MBP que foram investigadas é mostrada na Tabela 1.

Nº	Código PDB	Nome do Ligante	Estrutura da Proteína	Referência
1	1ANF	maltose	fechada- <i>holo</i>	Quiocho et al. (1997)
2	1FQC	maltotriitol	fechada- <i>holo</i>	Duan et al. (2001)
3	1FQD	maltotetraitol	fechada- <i>holo</i>	Duan et al. (2001)
4	1MPD	maltose	fechada- <i>holo</i>	Shilton et al. (1996)
5	3HPI	sacarose	fechada- <i>holo</i>	Gould & Shilton (2010)
6	3MBP	maltotriose	fechada- <i>holo</i>	Quiocho et al. (1997)
7	4MBP	maltotetraose	fechada- <i>holo</i>	Quiocho et al. (1997)
8	1EZ9	maltotetraitol	aberta- <i>holo</i>	Duan & Quiocho (2002)
9	1FQA	maltotetraitol	aberta- <i>holo</i>	Duan et al. (2001)
10	1FQB	maltotetraitol	aberta- <i>holo</i>	Duan et al. (2001)
11	1JW4	—	aberta- <i>apo</i>	Duan & Quiocho (2002)
12	1JW5	maltose	aberta- <i>holo</i>	Duan & Quiocho (2002)
13	1LLS	—	aberta- <i>apo</i>	Rubin et al. (2002)
14	1OMP	—	aberta- <i>apo</i>	Sharff et al. (1992)

Tabela 1: Tabela retirada de [11]. Quatorze estruturas da MBP com os nomes dos ligantes para as formas *holo*. Cada estrutura é identificada por um código de quatro letras do Protein Data Bank [2].

1.3 O Formalismo da Rede Anisotrópica (ANM) e a Matriz Hessiana Estrutural

Para mapear com rigor analítico as flutuações e os movimentos cooperativos de dobradiça da MBP, faz-se necessário transcender as descrições estáticas e adotar um modelo mecânico das interações moleculares. O fundamento teórico para modelar as flutuações direcionais tridimensionais repousa sobre o formalismo do Modelo de Rede Anisotrópica (*Anisotropic Network Model* – ANM), introduzido pelo estudo seminal de Atilgan et al. [1]. Este modelo supera as limitações topológicas clássicas do Modelo de Rede Gaussiana (*Gaussian Network Model* – GNM) o qual, por ser puramente escalar, pressupõe flutuações isotrópicas e omite as preferências direcionais dos resíduos ao longo dos eixos cartesianos.

1.3.1 Formulação Tridimensional da Energia Potencial Elástica

No âmbito do ANM, a arquitetura estrutural da MBP ($N = 370$ resíduos) é convertida num sistema mecânico de grão grosso. Pares de nós (carbonos-alfa) cujas distâncias geométricas na estrutura cristalográfica de equilíbrio sejam inferiores a um raio de corte termodinâmico (r_c , tipicamente parametrizado entre 13 e 15 Å) são modelados como se estivessem conectados por molas harmônicas virtuais submetidas a uma constante de força fenomenológica uniforme γ .

Sejam $\mathbf{r}_i = (X_i, Y_i, Z_i)^T$ e $\mathbf{r}_j = (X_j, Y_j, Z_j)^T$ os vetores posição instantâneos dos resíduos i e j sob agitação térmica, e $\mathbf{r}_i^0, \mathbf{r}_j^0$ as suas respectivas coordenadas de relaxamento (equilíbrio) obtidas via cristalografia. A distância instantânea é definida pela norma euclidiana $s_{ij} = |\mathbf{r}_{ij}| = |\mathbf{r}_j - \mathbf{r}_i|$, enquanto a distância de relaxamento elástico é dada por $s_{ij}^0 = |\mathbf{r}_{ij}^0| = |\mathbf{r}_j^0 - \mathbf{r}_i^0|$.

Sob a aproximação harmônica para pequenas flutuações, a energia potencial total

de deformação do sistema mecânico, V_{total} , é expressa pelo somatório escalar das contribuições elásticas par a par:

$$V_{\text{total}} = \frac{\gamma}{2} \sum_{i=1}^{N-1} \sum_{j=i+1}^N \left[\sqrt{(X_j - X_i)^2 + (Y_j - Y_i)^2 + (Z_j - Z_i)^2} - s_{ij}^0 \right]^2 \mathbf{1}_{[(i,j) \in \mathcal{E}]}, \quad (1)$$

onde $\mathcal{E}$ define o conjunto de contactos topológicos intrínsecos determinado pelo raio de corte, de modo que a função indicadora $\mathbf{1}_{[(i,j) \in \mathcal{E}]} = 1$ se, e somente se, $s_{ij}^0 \leq r_c$, assumindo o valor 0 caso contrário.

1.3.2 Construção Analítica da Matriz Hessiana

O comportamento dinâmico e as forças de restituição do sistema linearizado em torno do mínimo global de energia elástica são inteiramente mapeados pela matriz Hessiana estrutural, denotada por $\mathbf{H} \in \mathbb{R}^{3N \times 3N}$. A matriz $\mathbf{H}$ é construída através da expansão em série de Taylor de segunda ordem do potencial V_{total} e é estruturada matematicamente em $N \times N$ sub-blocos (ou super-elementos) de dimensão 3×3 .

Cada sub-bloco $\mathbf{H}_{ij}$ encapsula as segundas derivadas parciais do potencial elástico em relação às componentes cartesianas dos deslocamentos espaciais dos nós i e j . Para os super-elementos *fora da diagonal principal* ($i \neq j$), que calculam o acoplamento mecânico direcional da mola entre dois resíduos distintos, a diferenciação analítica da Equação (1) avaliada na configuração de equilíbrio resulta na seguinte matriz Jacobiana de interações:

$$\mathbf{H}_{ij} = \begin{bmatrix} \frac{\partial^2 V}{\partial X_i \partial X_j} & \frac{\partial^2 V}{\partial X_i \partial Y_j} & \frac{\partial^2 V}{\partial X_i \partial Z_j} \\ \frac{\partial^2 V}{\partial Y_i \partial X_j} & \frac{\partial^2 V}{\partial Y_i \partial Y_j} & \frac{\partial^2 V}{\partial Y_i \partial Z_j} \\ \frac{\partial^2 V}{\partial Z_i \partial X_j} & \frac{\partial^2 V}{\partial Z_i \partial Y_j} & \frac{\partial^2 V}{\partial Z_i \partial Z_j} \end{bmatrix} \quad (2)$$

A expressão (2) pode ser escrita de forma elegante através do produto externo (*outer product*) do vetor de distância geométrica $\mathbf{r}_{ij}^0$:

$$\mathbf{H}_{ij} = -\frac{\gamma}{(s_{ij}^0)^2} (\mathbf{r}_{ij}^0) (\mathbf{r}_{ij}^0)^T \mathbf{1}_{[(i,j) \in \mathcal{E}]}. \quad (3)$$

Inversamente, os super-elementos localizados na *diagonal principal* da Hessiana ($\mathbf{H}_{ii}$) não modelam uma interação individual, mas sim a soma vetorial das forças de reação elástica exercidas por todas as molas conectadas ao i -ésimo nó. Por imperativo da terceira lei de Newton e da conservação do momento linear (invariância translacional), a diagonal é rigorosamente definida pelo balanço negativo das interações circundantes:

$$\mathbf{H}_{ii} = -\sum_{j \neq i}^N \mathbf{H}_{ij}. \quad (4)$$

A matriz global $\mathbf{H}$ assim construída é simétrica e semidefinida positiva, abrigando toda a topologia de conectividade e as anisotropias mecânicas que definem o estado termodinâmico da MBP.

1.4 Decomposição Espectral, Truncamento e a Correlação Cruzada

A matriz Hessiana $\mathbf{H} \in \mathbb{R}^{3N \times 3N}$, derivada na secção anterior, contém a totalidade da informação sobre o panorama de flutuações da proteína ao redor do seu estado de equilíbrio. Sendo $\mathbf{H}$ uma matriz real, simétrica e semidefinida positiva, o seu comportamento termodinâmico pode ser dissecado resolvendo o problema de autovalores, o que equivale a realizar uma transformação ortogonal de coordenadas conhecida como decomposição espectral.

1.4.1 Modos Normais e Truncamento de Baixa Frequência

A diagonalização da matriz Hessiana fornece um conjunto completo de $3N$ autovalores λ_k e os seus respetivos autovetores ortonormais $\mathbf{u}_k \in \mathbb{R}^{3N}$:

$$\mathbf{H} = \sum_{k=1}^{3N} \lambda_k \mathbf{u}_k \mathbf{u}_k^T. \quad (5)$$

Fisicamente, os autovalores estão diretamente relacionados com a rigidez direcional e são proporcionais ao quadrado das frequências vibracionais dos modos normais ($\lambda_k \propto \omega_k^2$). Os autovetores $\mathbf{u}_k$ descrevem a forma geométrica (direção e amplitude) do deslocamento coletivo dos resíduos sob aquele específico modo de vibração.

Devido à invariância translacional e rotacional da molécula inteira como um corpo rígido livre no espaço tridimensional, os primeiros seis autovalores ($k = 1, \dots, 6$) são estritamente nulos ($\lambda_k = 0$). Restam, portanto, $3N - 6 = 1104$ modos físicos não-triviais de oscilação interna.

A conexão matemática entre este arcabouço biofísico e a metodologia estatística delineada por Kovacev-Nikolic et al. [11] estabelece-se por meio do **truncamento espectral**. Autovalores de grande magnitude correspondem a movimentos rápidos, locais e de alta frequência (tais como estiramentos de ligações covalentes pontuais), que representam mero ruído termodinâmico na perspetiva da transição funcional da proteína.

Para capturar exclusivamente a mecânica cooperativa global — isto é, o movimento de dobradiça essencial para a captura do ligante — opera-se uma restrição dimensional. Retêm-se apenas os primeiros $M = 20$ modos não-triviais de menor autovalor (do índice $k = 7$ ao $k = 6 + M$). A matriz pseudoinversa de Moore-Penrose truncada, $\mathbf{H}_{\text{trunc}}^+$, é reconstruída estritamente sobre este subespaço:

$$\mathbf{H}_{\text{trunc}}^+ = \sum_{k=7}^{6+M} \frac{1}{\lambda_k} \mathbf{u}_k \mathbf{u}_k^T. \quad (6)$$

1.4.2 Derivação da Matriz de Correlação Cruzada

Sob a aproximação de que as flutuações conformacionais ($\Delta \mathbf{R}$) seguem uma distribuição multivariada exata de Boltzmann, Atilgan et al. [1] demonstram que a covariância termodinâmica entre as flutuações espaciais dos resíduos i e j é diretamente proporcional aos sub-blocos 3×3 da matriz pseudoinversa.

O produto interno termodinâmico (covariância cruzada) é obtido calculando o traço (Tr), ou seja, a soma dos elementos da diagonal principal, do respectivo sub-bloco $[\mathbf{H}_{\text{trunc}}^+]_{ij}$:

$$\langle \Delta \mathbf{r}_i \cdot \Delta \mathbf{r}_j \rangle = k_B T \text{Tr} \left([\mathbf{H}_{\text{trunc}}^+]_{ij} \right), \quad (7)$$

onde k_B é a constante de Boltzmann e T a temperatura absoluta. Para isolar a pureza direcional do movimento e anular as diferenças de magnitude absoluta das flutuações, normaliza-se esta covariância. Define-se assim a **correlação cruzada dinâmica normalizada** (C_{ij}) entre qualquer par de resíduos na proteína:

$$C_{ij} = \frac{\text{Tr} \left([\mathbf{H}_{\text{trunc}}^+]_{ij} \right)}{\sqrt{\text{Tr} \left([\mathbf{H}_{\text{trunc}}^+]_{ii} \right) \text{Tr} \left([\mathbf{H}_{\text{trunc}}^+]_{jj} \right)}}, \quad C_{ij} \in [-1, 1]. \quad (8)$$

Esta matriz de correlação $\mathbf{C} \in \mathbb{R}^{N \times N}$ destila a totalidade da coreografia mecânica da MBP: valores positivos próximos de 1 denotam resíduos que se deslocam de forma coordenada na mesma direção; valores negativos próximos de -1 identificam resíduos em oposição de fase (anticorrelação, agindo como os braços opostos de uma alavanca); e valores nulos indicam independência cinemática e ausência de comunicação alostérica.

1.5 Transição Métrica: Da Geometria Euclidiana à Topologia Dinâmica

O emprego clássico da Análise Topológica de Dados (TDA) em biologia estrutural baseia-se frequentemente nas coordenadas espaciais cartesianas (X, Y, Z) para construir o espaço métrico subjacente. Contudo, como estabelecido nas secções anteriores, as coordenadas obtidas por cristalografia de raios X fornecem apenas uma estrutura média termodinâmica da molécula. Visto que a função de captura do ligante pela MBP depende intrinsecamente das flutuações ao longo do tempo, o descarte deliberado da distância euclidiana pura em favor de um descritor dinâmico é estritamente necessário [11].

Para preparar os dados das flutuações para a construção do complexo de Vietoris-Rips, utiliza-se a transformação linear da matriz de correlação cruzada normalizada $\mathbf{C}$ (Equação 8) na matriz de distâncias dinâmicas $\mathbf{D}$ (Equação 9). Esta nova matriz é definida elemento a elemento pela relação:

$$D_{ij} = 1 - |C_{ij}|. \quad (9)$$

Esta conversão mapeia o domínio de $[-1, 1]$ da correlação para um espaço pseudométrico rigoroso $[0, 1]$, carregando implicações estatísticas e topológicas profundas. É crucial notar que $\mathbf{D}$ não é estritamente uma métrica, mas sim uma **pseudométrica**. Isto ocorre porque a identidade dos indiscerníveis não se verifica rigorosamente: dois resíduos distintos ($i \neq j$) podem oscilar de forma perfeitamente correlacionada ($|C_{ij}| = 1$), resultando numa distância $D_{ij} = 0$. A Topologia Algébrica, contudo, é perfeitamente bem definida sobre espaços pseudométricos, permitindo a construção de complexos simpliciais sem perda de generalidade teórica.

1.5.1 O Significado Probabilístico e a Pseudométrica

Sob a óptica da teoria das probabilidades [9], o coeficiente de correlação é um estimador paramétrico que quantifica a força e a direção da dependência linear entre duas variáveis aleatórias. A aplicação do valor absoluto acoplada ao deslocamento linear em (9) promove um reescalonamento probabilístico exacto:

- **Alta Dependência Cinemática** ($|C_{ij}| \rightarrow 1$): A operação de módulo confere o mesmo peso analítico tanto à correlação perfeitamente positiva (movimento uníssono no mesmo sentido) quanto à anticorrelação extrema (movimento em sentidos opostos, como as alavancas de uma tesoura). Neste limite, a distância atribuída tende a zero ($D_{ij} \rightarrow 0$). Probabilisticamente, isto atesta um elevado grau de determinismo: conhecer o vetor de deslocamento termodinâmico do resíduo i determina de forma perfeitamente previsível a resposta mecânica do resíduo j .
- **Independência e Ruído Térmico** ($C_{ij} \rightarrow 0$): Se as vibrações mecânicas de dois resíduos são ortogonais ou governadas por ruído térmico aleatório e independente, a relação linear anula-se. Consequentemente, a equação devolve a distância matemática máxima estipulada pelo modelo ($D_{ij} \rightarrow 1$).

A matriz $\mathbf{D}$ satisfaz as propriedades de não-negatividade ($D_{ij} \geq 0$), simetria ($D_{ij} = D_{ji}$) e identidade dos indiscerníveis ($D_{ii} = 0$). A desigualdade triangular ($D_{ik} \leq D_{ij} + D_{jk}$) é matematicamente garantida pelo facto de $|C_{ij}|$ derivar de um produto interno num espaço de Hilbert de flutuações, decorrendo assim da desigualdade de Cauchy-Schwarz. Estas propriedades validam $\mathbf{D}$ como uma pseudométrica fidedigna.

1.6 Redução de Dimensionalidade e Visualização do Espaço de Comunicação: ISOMAP

A construção da matriz de distâncias dinâmicas $\mathbf{D} \in \mathbb{R}^{N \times N}$ (onde $N = 370$ resíduos) dota a proteína de uma nova geometria topológica, fundamentalmente distinta da sua estrutura física. Neste novo espaço métrico de dimensão N , os resíduos

que se movem de forma termodinamicamente coordenada estão próximos (distância tendendo a zero), independentemente de quão distantes estejam na estrutura cristalográfica original em $\mathbb{R}^3$.

Contudo, $\mathbf{D}$ é um objeto de alta dimensionalidade. Para que seja possível inspecionar visualmente este “espaço de comunicação” e extrair a sua estrutura global latente, é imperativo aplicar técnicas de redução de dimensionalidade. O objetivo matemático subjacente é encontrar um conjunto de coordenadas de baixa dimensão $\mathbf{Y} = \{\mathbf{y}_1, \dots, \mathbf{y}_N\} \subset \mathbb{R}^d$ (com $d \ll N$) de modo que a distância euclidiana neste novo subespaço mapeie o mais fielmente possível a distância dinâmica original, ou seja, $\|\mathbf{y}_i - \mathbf{y}_j\|_{\mathbb{R}^d} \approx D_{ij}$.

1.6.1 A Limitação do MDS Clássico

A abordagem analítica padrão para este problema de imersão métrica é o *Multidimensional Scaling* Clássico (MDS). O MDS opera transformando a matriz de distâncias ao quadrado $\mathbf{D}^{(2)}$ numa matriz de produtos internos (matriz de Gram) através de um operador de dupla centralização (*double centering*):

$$\mathbf{B} = -\frac{1}{2}\mathbf{H}\mathbf{D}^{(2)}\mathbf{H}, \quad \text{onde } \mathbf{H} = \mathbf{I} - \frac{1}{N}\mathbf{1}\mathbf{1}^T, \quad (10)$$

sendo $\mathbf{I}$ a matriz identidade de ordem N e $\mathbf{1}$ um vetor coluna de uns. Em seguida, realiza-se a decomposição espectral $\mathbf{B} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$ e retêm-se os d maiores autovalores para construir as coordenadas projetadas.

No entanto, conforme reportado por Kovacev-Nikolic et al. [11], o MDS apresenta erros residuais elevados ao lidar com a dinâmica da MBP. A justificativa rigorosa para esta falha reside no facto de o MDS assumir que os dados residem num subespaço global *linear* (um hiperplano rígido). A dinâmica conformacional de uma proteína, guiada por potenciais harmónicos locais e barreiras estéricas, desenvolve-se sobre uma *variedade não-linear* (*manifold*) intrincada e curva no espaço de fase. Ao tentar preservar todas as distâncias globais por meio de linhas retas euclidianas intrínsecas ao modelo linear, o MDS cria "curtos-circuitos" através de regiões do espaço que são termodinamicamente inatingíveis para a estrutura real da proteína.

1.6.2 A Solução via ISOMAP e Distâncias Geodésicas

Para mitigar a distorção imposta pelas projeções lineares, o estudo adota o **ISOMAP** (*Isometric Mapping*) [15]. O ISOMAP é uma técnica de *manifold learning* que generaliza o MDS clássico, substituindo as métricas euclidianas diretas por **distâncias geodésicas** — isto é, as distâncias medidas estritamente *ao longo da superfície* curvada da variedade dos dados. O rigor do algoritmo ISOMAP desdobra-se em três etapas computacionais:

1. **Construção do Grafo de Vizinhança Local:** Define-se um grafo ponderado $G = (V, E)$, onde os vértices são os N resíduos. Uma aresta conecta o nó i ao nó j apenas se estes forem vizinhos próximos sob a matriz dinâmica

$\mathbf{D}$ (por norma, através do algoritmo dos k -vizinhos mais próximos ou de uma bola limitante de raio ϵ). O peso da aresta é o próprio valor D_{ij} . Esta etapa captura a topologia local onde o espaço pode ser aproximado por um plano linear.

2. **Cálculo Global das Geodésicas:** Para resíduos distantes, a separação não é ditada pela matriz original $\mathbf{D}$ (que poderia causar um curto-circuito não-linear), mas sim pela acumulação dos caminhos mais curtos através do grafo local G . Recorrendo a algoritmos de optimização em grafos (como Dijkstra ou Floyd-Warshall), constrói-se a matriz de distâncias geodésicas $\mathbf{D}^{(G)}$:

$$D_{ij}^{(G)} = \min_{\text{caminho } p} \left(\sum_{e \in p} \text{peso}(e) \right).$$

3. **Imersão Métrica (MDS Geodésico):** O operador do MDS Clássico (Equação 10) é, por fim, aplicado estritamente sobre a matriz geodésica não-linear $\mathbf{D}^{(G)}$, gerando o espectro de coordenadas de baixa dimensão $\mathbf{Y}$ que desdobra (*unfolds*) e preserva a topologia curva intrínseca.

O ISOMAP exhibe erros residuais substancialmente menores que o MDS porque respeita a continuidade dos movimentos biológicos: a correlação alostérica entre domínios distantes da MBP é forçada a fluir através da malha de aminoácidos intermédios conectados.

1.6.3 Dimensionalidade Intrínseca e o Gráfico Scree (Cotovelo)

A determinação empírica da dimensão alvo d para a projeção final $\mathbf{Y} \in \mathbb{R}^d$ exige a avaliação da **dimensionalidade intrínseca** da variedade subjacente — o número mínimo de eixos latentes indispensáveis para encapsular a totalidade da informação estrutural sem introduzir ruído ou aglomeração espúria (*crowding problem*).

Para avaliar a fidelidade da redução, quantifica-se o *stress* topológico, formulado pela variância residual do mapeamento. Trata-se de uma função estritamente decrescente da dimensão d , dada por:

$$\text{Variância Residual}(d) = 1 - R^2 \left(\text{vec}(\mathbf{D}^{(G)}), \text{vec}(\mathbf{D}_{\mathbf{Y}}^{(d)}) \right),$$

onde R^2 representa o coeficiente de correlação linear (o quadrado da correlação de Pearson) calculado entre o vetor de distâncias geodésicas originais e as distâncias euclidianas estimadas no subespaço de dimensão d ($\mathbf{D}_{\mathbf{Y}}^{(d)}$).

A análise do comportamento assintótico desta métrica em função do número sucessivo de dimensões d projeta-se visualmente no designado **Gráfico Scree** (*Scree Plot*). A extração da dimensão ótima assenta no **Crítério do Cotovelo** (*Elbow Method*). Este critério geométrico identifica o hiperparâmetro de transição (o "cotovelo" da curva) onde a taxa de mitigação do erro residual sofre uma flexão abrupta e passa a assemelhar-se a um platô assintótico horizontal.

Conforme evidenciado pelas matrizes dinâmicas da MBP estudadas por Kovacev-Nikolic et al. [11] (Figura 3 do respetivo artigo), o declínio acentuado das distorções de mapeamento termina precisamente quando $d = 3$. A incorporação de autovetores sucessivos para gerar uma quarta ou quinta dimensão induz ganhos marginais e irrisórios no coeficiente de determinação R^2 . Esta observação matemática corrobora a tese de que a imensa complexidade dinâmica estabelecida pelos 370 resíduos macromoleculares pode ser otimizadamente embutida num subespaço denso de três dimensões ($\mathbb{R}^3$). É neste prisma reduzido e fiel à mecânica da proteína que as nuvens de pontos de interações se revelam preparadas para a subsequente análise de agrupamentos de classes (*apo* versus *holo*).




Figura 2: Redução de dimensão via Isomap para a estrutura 1OMP. A flexão abrupta no parâmetro $d = 3$ (Critério do Cotovelo) indica a dimensionalidade intrínseca ideal para a representação das flutuações dinâmicas da MBP.

Nota (Nota sobre o Fluxo Metodológico). *Ressalta-se que a aplicação do ISOMAP possui um propósito estritamente exploratório e visual no contexto deste estudo, permitindo a inspeção gráfica da dimensionalidade intrínseca (Gráfico Scree). O fluxo computacional analítico de classificação (Machine Learning) não transita por este subespaço tridimensional gerado pelo ISOMAP. A extração de características preditivas opera diretamente e independentemente sobre as paisagens de persistência através de Análise de Componentes Principais (PCA), conforme detalhado na secção do pipeline computacional.*

1.7 Definições Topológicas e a Geometria da Comunicação Dinâmica

O emprego clássico da Análise Topológica de Dados (TDA) em biologia estrutural baseia-se frequentemente nas coordenadas espaciais cartesianas (X, Y, Z) para construir o espaço métrico subjacente. Contudo, visto que a função de captura do ligante

pela MBP depende intrinsecamente das flutuações térmicas ao longo do tempo, a distância euclidiana pura fornece apenas um instantâneo estático. Torna-se, portanto, estritamente necessário substituir essa geometria por um descritor dinâmico [11].

1.7.1 Fundamentos de Topologia Algébrica

Para extrair a arquitetura de comunicação da biomolécula a partir desta pseudo-métrica, traduzimos este espaço num objecto combinatório. Seja K um complexo simplicial abstracto. Para $n \geq 0$, definimos os conjuntos

$$K_n = \{\sigma \in K \mid \dim(\sigma) \leq n\}$$

$$K_{(n)} = \{\sigma \in K \mid \dim(\sigma) = n\}.$$

O primeiro conjunto é um complexo simplicial, chamado de n -esqueleto de K . O segundo não é um complexo simplicial em geral.

Definição 2 (Complexo Simplicial). *Seja V um conjunto (chamado de conjunto de vértices). Um **complexo simplicial** sobre V é um conjunto K de subconjuntos de V (chamados de **simplexos**) tal que, para todo $\sigma \in K$ e todo $\tau \subset \sigma$ não-vazio, temos $\tau \in K$.*

Definição 3 (n -Cadeias). *Seja K um complexo simplicial e $n \geq 0$. O conjunto de n -cadeias de K , denotado $C_n(K)$, é o conjunto cujos elementos são as somas formais:*

$$\sum_{\sigma \in K_{(n)}} \epsilon_\sigma \cdot \sigma, \quad \text{onde } \forall \sigma \in K_{(n)}, \epsilon_\sigma \in \mathbb{Z}/2\mathbb{Z}.$$

Este conjunto possui estrutura de espaço vetorial sobre o corpo $\mathbb{Z}/2\mathbb{Z}$, com a adição a ocorrer componente a componente.

Definição 4 (Operador de Fronteira). *Seja $n \geq 1$ e $\sigma = [x_0, \dots, x_n] \in K_{(n)}$ um simplex de dimensão n . A **fronteira** de σ é o elemento de $C_{n-1}(K)$ definido por:*

$$\partial_n \sigma = \sum_{\substack{\tau \subset \sigma \\ |\tau| = |\sigma| - 1}} \tau.$$

O operador ∂_n estende-se por linearidade a uma aplicação linear $\partial_n : C_n(K) \rightarrow C_{n-1}(K)$. Para $n = 0$, define-se ∂_0 como a aplicação nula.

Definição 5 (Ciclos e Fronteiras). *Sejam K um complexo simplicial e $n \geq 0$. Definimos:*

- *Os n -ciclos:* $Z_n(K) = \ker(\partial_n) \subset C_n(K)$,
- *As n -fronteiras:* $B_n(K) = \text{Im}(\partial_{n+1}) \subset C_n(K)$.

Definição 6 (Grupo de Homologia e Números de Betti). *Seja K um complexo simplicial. O n -ésimo grupo de homologia de K é o quociente:*

$$H_n(K) = Z_n(K) / B_n(K).$$

A dimensão deste espaço vetorial é o n -ésimo número de Betti, dado por $\beta_n(K) = \dim H_n(K) = \dim Z_n(K) - \dim B_n(K)$. Geometricamente, β_0 conta o número de componentes conexas, β_1 o número de "buracos" ou ciclos unidimensionais, e β_2 o número de cavidades fechadas.

Definição 7. *Seja X um espaço topológico e $\mathcal{U} = \{U_i\}_{1 \leq i \leq N}$ uma cobertura de X . O **nervo** de $\mathcal{U}$ é o complexo simplicial com conjunto de vértices $\{1, \dots, N\}$ cujos m -símplices são os subconjuntos $\{i_1, \dots, i_m\} \subset \{1, \dots, N\}$ tais que $\bigcap_{k=1}^m U_{i_k} \neq \emptyset$. É denotado $\mathcal{N}(\mathcal{U})$.*

Definição 8 (Complexo de Čech). *Sejam $X \subset \mathbb{R}^n$ finito e $t \geq 0$. Considere a coleção $\mathcal{V}^t = \{\bar{B}(x, t) \mid x \in X\}$. O nervo desta coleção é denotado $\check{\text{Cech}}^t(X)$ e é chamado de **complexo de Čech** de X no instante t .*

Explicitamente, $\check{\text{Cech}}^t(X)$ é o complexo simplicial sobre os vértices X cujos símplices são os subconjuntos $\{x_{i_1}, \dots, x_{i_m}\}$ tais que $\bigcap_{k=1}^m \bar{B}(x_{i_k}, t) \neq \emptyset$.

1.7.2 Filtração e Persistência no Espaço Dinâmico

Para que a topologia seja computável a partir da matriz de distâncias dinâmicas, constrói-se o complexo a partir de um parâmetro de limiar evolutivo:

No contexto deste estudo, substituímos o espaço euclidiano $\mathbb{R}^3$ pelo espaço probabílistico das interações dinâmicas da MBP. Assim, o complexo $\text{Rips}^t(X)$ instanciará um 1-simplexo (aresta) entre dois resíduos se a distância dinâmica $D_{ij} \leq 2t$. Conforme demonstrado por Cang et al. [6], esta substituição dota os invariantes de uma ontologia puramente mecanicista:

1. **Arestas como Interação:** Se dois resíduos operam em uníssono termodinâmico para fechar a fenda, $D_{ij} \approx 0$, e uma aresta conectá-los-á nos primeiros instantes da filtração, mesmo que estejam fisicamente distantes na proteína.
2. **Laços de Homologia (β_1) como Comunicação:** Os "buracos" abstraídos sobre a matriz $\mathbf{D}$ não são espaços vazios na matéria, mas sim *circuitos elásticos fechados* e *vias alostéricas* de propagação de força [11].

Ao fazer t crescer de 0 até ao máximo, obtemos uma filtração. O rastreamento de H_n ao longo desta filtração gera um módulo de persistência.

Definição 9 (Decomponibilidade e Barcode). *Um módulo de persistência $\mathbb{U}$ é **indecomponível** se, para todo o par de módulos $\mathbb{V}$ e $\mathbb{W}$ tais que $\mathbb{U} \simeq \mathbb{V} \oplus \mathbb{W}$, um dos somandos for nulo. Um módulo $\mathbb{V}$ é **decomponível em módulos intervalares** se existe um multiconjunto $\mathcal{I}$ de intervalos de $\mathbb{R}^+$ tal que $\mathbb{V} \simeq \bigoplus_{I \in \mathcal{I}} \mathbb{B}[I]$. O multiconjunto $\mathcal{I}$, garantido pelo Teorema de Azumaya, é denominado **código de barras de persistência** (Barcode) de $\mathbb{V}$.*

Definição 10 (Diagrama de Persistência). *Seja $\text{Barcode}(\mathbb{V})$ o barcode de um módulo decomponível. Para cada intervalo no formato (a, b) no barcode, considere-se o ponto $(a, b) \in \mathbb{R}^2$. A coleção de todos estes pontos forma o multiconjunto chamado **diagrama de persistência**, denotado $\text{Diagram}(\mathbb{V})$.*

Desabstraindo estes conceitos: um ponto (a, b) no diagrama de β_1 indica que um "ciclo de comunicação elástica" nasceu no instante de correlação a e foi engolido por novas conexões no limiar b . A diferença $b - a$ é a sua persistência vital.

1.7.3 Paisagens de Persistência e Espaços Lineares Funcionais

Códigos de barras e diagramas de persistência não formam um espaço vetorial linear, o que inviabiliza ferramentas padrão de *Machine Learning*. Para contornar esta barreira, Bubenik [4] introduziu uma transformação funcional.

Definição 11 (Paisagem de Persistência). *Dado um diagrama de persistência com intervalos $\mathcal{B} = \{(a_i, b_i)\}_{i=1}^m$, define-se para cada ponto a função auxiliar:*

$$f_{(a,b)}(t) = \max(0, \min(t - a, b - t)).$$

A **paisagem de persistência** é a sequência de funções $\lambda_k : \mathbb{R} \rightarrow \mathbb{R}$ definidas por:

$$\lambda_k(t) = k\text{-ésimo maior valor do conjunto } \{f_{(a_i, b_i)}(t)\}_{i=1}^m,$$

adotando $\lambda_k(t) = 0$ caso $k > m$.

Definição 12 (Distância p -Paisagem). *A distância topológica entre duas paisagens λ e λ' é dada pela norma:*

$$\Lambda_p(\lambda, \lambda') = \|\lambda - \lambda'\|_p = \left(\sum_{k=1}^{\infty} \int_{\mathbb{R}} |\lambda_k(t) - \lambda'_k(t)|^p dt \right)^{1/p}. \quad (11)$$

O corolário mais profundo da Paisagem de Persistência é que a função $\lambda(k, t)$ é um elemento do espaço integrável de Lebesgue $L^p(\mathbb{N} \times \mathbb{R})$. Por definição, o espaço L^p é um **Espaço de Banach** (normado e completo).

Particularmente, quando $p = 2$, a distância Λ_2 dota a topologia da estrutura de um **Espaço de Hilbert**. A existência do espaço de Hilbert assegura a formulação de um produto interno rigoroso ($\langle \lambda, \lambda' \rangle_{L^2}$), o que fundamenta a aplicabilidade do "Teorema de Representação de Riesz". É esta transição exata — da combinatória abstrata dos retículos atômicos para a continuidade em Hilbert — que viabiliza a utilização direta de *métodos de Kernel* em Máquinas de Vetores de Suporte (SVM), permitindo calcular o hiperplano ótimo que separa matematicamente os estados dinâmicos da MBP.

2 Inferência Estatística sobre Invariantes Topológicos

O artigo de Kovacev-Nikolic et al. [11] propõe detectar diferenças conformacionais entre as formas *fechada* e *aberta* da Proteína de Ligação à Maltose (MBP) usando os métodos de Análise Topológica de Dados (TDA) fundamentados na Secção anterior. O desafio estatístico central é o seguinte: dado um conjunto de apenas $n = 14$ estruturas proteicas cristalizadas (7 fechadas e 7 abertas), como concluir rigorosamente que as duas classes dinâmicas são *estatisticamente distintas*?

A estratégia metodológica adota três pilares essenciais:

1. Transformar cada estrutura proteica num número real X por meio de um funcional linear aplicado sobre a sua paisagem de persistência.
2. Justificar, via teoria de espaços de Banach, que X admite média e variância finitas — o que legitima a aplicação dos grandes teoremas da probabilidade.
3. Empregar um teste de permutação (não paramétrico) para contornar a limitação imposta pelo tamanho amostral reduzido.

As subsecções seguintes desenvolvem cada um destes pilares com o devido rigor matemático.

2.1 A Variável Aleatória Topológica X

2.1.1 Da Paisagem de Persistência ao Escalar

Para cada estrutura proteica, a filtração do complexo de Vietoris-Rips produz uma *paisagem de persistência* $\lambda(k, t)$, que é uma sequência de funções definida em $\mathbb{N} \times \mathbb{R}$. Formalmente, a paisagem é tratada como um elemento do espaço de Banach separável $L^p(\mathbb{N} \times \mathbb{R})$ munido da norma:

$$\|\lambda\|_p = \left(\sum_{k=1}^{\infty} \int_{\mathbb{R}} |\lambda(k, t)|^p dt \right)^{1/p}, \quad 1 \leq p < \infty.$$

Define-se então uma variável aleatória real X por meio do funcional linear:

$$X = f(\lambda) = \sum_{k=1}^{\infty} \int_{\mathbb{R}} \lambda(k, t) dt,$$

que corresponde à *área total* delimitada por todos os contornos da paisagem de persistência. Este funcional integra as informações topológicas de todos os graus de homologia num único escalar real, permitindo a transição do espaço de formas complexas para o domínio da estatística clássica.

2.1.2 Finitude da Média e da Variância

Para que os grandes teoremas da probabilidade sejam aplicáveis a X , é fundamental provar analiticamente que as suas propriedades estocásticas, $\mathbb{E}[X]$ e $\text{Var}(X)$, são limitadas.

Proposição 1 (Integrabilidade da Área Topológica). *Seja $f : L^2(\mathbb{N} \times \mathbb{R}) \rightarrow \mathbb{R}$ o funcional definido em (2.1.1) e suponha que $\mathbb{E}[\|\lambda\|_2] < \infty$. Então $\mathbb{E}[X] < \infty$ e $\text{Var}(X) < \infty$.*

Demonstração. O funcional f pode ser formulado como um produto interno rigoroso no espaço de Hilbert $L^2(\mathbb{N} \times \mathbb{R})$:

$$f(\lambda) = \langle g, \lambda \rangle_{L^2} = \sum_{k=1}^{\infty} \int_{\mathbb{R}} g(k, t) \lambda(k, t) dt,$$

com a função constante $g \equiv 1$. Pela *Desigualdade de Cauchy-Schwarz* (ou Hölder para $p = q = 2$):

$$|f(\lambda)| \leq \|g\|_2 \|\lambda\|_2.$$

Como a persistência das flutuações atômicas ocorre num intervalo de tempo (distância de filtração) finito e a estrutura proteica possui um número limitado de resíduos, g atua sobre um domínio de medida finita, garantindo que $\|g\|_2 < \infty$. Tomando a esperança matemática em ambos os lados:

$$\mathbb{E}[|X|] = \mathbb{E}[|f(\lambda)|] \leq \|g\|_2 \mathbb{E}[\|\lambda\|_2] < \infty.$$

Relativamente à variância, nota-se que $X^2 = f(\lambda)^2 \leq \|g\|_2^2 \|\lambda\|_2^2$, logo:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \leq \mathbb{E}[X^2] \leq \|g\|_2^2 \mathbb{E}[\|\lambda\|_2^2] < \infty. \quad \square$$

Nota. A hipótese $\mathbb{E}[\|\lambda\|_2] < \infty$ é fisicamente inquestionável: a MBP possui um tamanho geométrico finito e a distância dinâmica D_{ij} é estritamente limitada ao intervalo $[0, 1]$, impedindo o crescimento infinito dos ciclos topológicos.

2.2 Leis Limites e a Necessidade de Testes Não-Paramétricos

Estabelecida a integrabilidade de X , os dois pilares da teoria probabilística tornam-se intrinsecamente aplicáveis às amostras topológicas.

Teorema 1 (Lei dos Grandes Números — LGN). *Sejam $X_1, X_2, \dots$ variáveis aleatórias independentes e identicamente distribuídas (i.i.d.) com média $\mu = \mathbb{E}[X_1] < \infty$. Definindo a média amostral $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, temos que $\bar{X}_n \xrightarrow{q.c.} \mu$ quando $n \rightarrow \infty$.*

Teorema 2 (Teorema Central do Limite — TCL). *Sob as hipóteses do Teorema 1, e assumindo $\sigma^2 = \text{Var}(X_1) < \infty$, o limite da distribuição converge para uma Normal padrão:*

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{quando } n \rightarrow \infty.$$

A independência requerida (X_i e X_j) é garantida metodologicamente, uma vez que as estruturas PDB foram cristalizadas e resolvidas experimentalmente de forma isolada [11]. No entanto, os Teoremas 1 e 2 são resultados *assintóticos*. Num escopo com apenas $n_1 = 7$ (fechadas) e $n_2 = 7$ (abertas), a invocação direta da distribuição Normal para o teste de hipótese clássico (*t-Student*) seria estatisticamente imprudente. O TCL justifica, contudo, que o espaço de paisagens é bem comportado, motivando o uso de métodos de reamostragem.

2.3 Formulação do Teste de Permutação (Valor- p)

2.3.1 Populações e a Estatística t

Define-se a média topológica populacional para as conformações fechadas como $\mu_1 = \mathbb{E}[X \mid \text{fechada}]$ e para as abertas como $\mu_2 = \mathbb{E}[X \mid \text{aberta}]$. O ensaio visa rejeitar a hipótese nula de igualdade (teste bilateral):

$$H_0 : \mu_1 = \mu_2 \quad \text{vs.} \quad H_a : \mu_1 \neq \mu_2.$$

Para quantificar a divergência, utilizam-se os estimadores amostrais não viesados $\bar{X}_1$ e $\bar{X}_2$, bem como as respectivas variâncias corrigidas S_1^2 e S_2^2 . A estatística de teste paramétrica t adimensional é formulada normalizando a diferença de médias pela variância global combinada:

$$t = \frac{|\bar{X}_1 - \bar{X}_2|}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}.$$

2.3.2 Distribuição Nula e Significado Topológico

O princípio de troca de Fischer estabelece que, se H_0 for verdadeira, os rótulos morfológicos “aberta” e “fechada” são estatisticamente insignificantes. O conjunto $\mathcal{P}$ de todas as partições possíveis de 14 proteínas em dois subgrupos de 7 fornece a cardinalidade exata do espaço de permutações:

$$|\mathcal{P}| = \binom{14}{7} = 3432.$$

Descontando a simetria rotacional dos rótulos, existem 1716 permutações únicas. Calculando a estatística t_π para cada permutação $\pi \in \mathcal{P}$, edifica-se a distribuição empírica sob H_0 . O **valor- p** é então a proporção de permutações que geram divergências maiores ou iguais à encontrada na organização biológica verdadeira (t_{obs}):

$$p = \frac{\#\{\pi \in \mathcal{P} : t_\pi \geq t_{\text{obs}}\}}{|\mathcal{P}|}.$$

Segundo a análise conduzida por Kovacev-Nikolic et al. [11], a estatística observada para os graus de homologia H_0 e H_1 atingiu o valor máximo de toda a distribuição permutada ($t_{\text{obs}} = \max(t_\pi)$). Consequentemente, o valor- p obtido foi o mínimo teórico possível:

$$p = \frac{1}{1716} \approx 5,83 \times 10^{-4}.$$

Uma vez que $p \ll \alpha = 0,05$, a hipótese nula H_0 é rejeitada com severidade. Conclui-se, com profundo rigor matemático, que as transições alostéricas e os mecanismos de dobradiça presentes na proteína de ligação à maltose geram **assinaturas topológicas fundamentalmente distintas**, comprovando a aptidão da Homologia Persistente para identificar funções termodinâmicas no espaço macromolecular.

3 A aplicação do Machine-Learning

3.1 Classificação Temática via Máquinas de Vetores de Suporte (SVM)

A projeção contínua das paisagens de persistência no Espaço de Hilbert $L^2(\mathbb{N} \times \mathbb{R})$, detalhada na Subsecção 1.7, fornece a fundamentação algébrica necessária para a aplicação de algoritmos de aprendizado supervisionado estáveis. Para discriminar de forma automatizada as assinaturas topológicas das conformações abertas e fechadas da Proteína de Ligação à Maltose (MBP), implementa-se o formalismo das Máquinas de Vetores de Suporte (*Support Vector Machines* – SVM) [8].

3.1.1 O Hiperplano Separador e a Regra de Decisão

Seja $\mathcal{X}$ o espaço vetorial funcional das características topológicas e $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ o conjunto de treino experimental, onde $\mathbf{x}_i \in \mathcal{X}$ representa a paisagem de persistência da i -ésima estrutura proteica e $y_i \in \{-1, +1\}$ denota o rótulo morfológico binário, convencionando-se $y_i = +1$ para a conformação fechada (*holo*) e $y_i = -1$ para a conformação aberta (*apo*).

Um classificador linear elementar estabelece uma fronteira de partição no espaço de fase através de um hiperplano afim $\mathcal{H}$, definido formalmente por:

$$\mathcal{H} = \{\mathbf{x} \in \mathcal{X} \mid \langle \mathbf{w}, \mathbf{x} \rangle + b = 0\}, \quad (12)$$

onde $\mathbf{w} \in \mathcal{X}$ representa el vetor normal de pesos ortogonal à superfície de decisão e $b \in \mathbb{R}$ constitui o termo de viés (*bias*). A função discriminante preditiva $g(\mathbf{x})$ para a classificação de uma nova estrutura conformacional é dada pela aplicação do operador sinal:

$$g(\mathbf{x}) = \text{sgn}(\langle \mathbf{w}, \mathbf{x} \rangle + b). \quad (13)$$

3.1.2 Maximização da Margem e o Problema Primal Rígido

O princípio de otimização das Máquinas de Vetores de Suporte consiste em selecionar, de entre o infinito conjunto de hiperplanos separadores possíveis, aquele que maximize a margem geométrica de separação entre as classes latentes [8]. Definem-se os hiperplanos de suporte paralelos e canônicos $\mathcal{H}_+$ e $\mathcal{H}_-$ que delimitam as fronteiras das regiões de exclusão de cada classe:

$$\mathcal{H}_+ : \langle \mathbf{w}, \mathbf{x} \rangle + b = +1, \quad \mathcal{H}_- : \langle \mathbf{w}, \mathbf{x} \rangle + b = -1.$$

Proposição 2 (Largura da Margem Geométrica). *A distância geométrica estrita entre os hiperplanos de suporte $\mathcal{H}_+$ e $\mathcal{H}_-$ é dada por $\frac{2}{\|\mathbf{w}\|}$.*

Demonstração. Sejam $\mathbf{x}_+ \in \mathcal{H}_+$ e $\mathbf{x}_- \in \mathcal{H}_-$ dois pontos ótimos pertencentes aos respectivos hiperplanos de suporte. O vetor diferença deslocamento $\mathbf{x}_+ - \mathbf{x}_-$ pode

ser projetado ortogonalmente sobre o vetor unitário normal à superfície de decisão, definido por $\hat{\mathbf{w}} = \mathbf{w}/\|\mathbf{w}\|$:

$$\langle \mathbf{x}_+ - \mathbf{x}_-, \hat{\mathbf{w}} \rangle = \frac{\langle \mathbf{w}, \mathbf{x}_+ \rangle - \langle \mathbf{w}, \mathbf{x}_- \rangle}{\|\mathbf{w}\|} = \frac{(1-b) - (-1-b)}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}.$$

□

Do ponto de vista computacional, maximizar a largura da margem $\frac{2}{\|\mathbf{w}\|}$ é analiticamente equivalente a minimizar o inverso do seu quadrado, $\frac{1}{2}\|\mathbf{w}\|^2$. Para cenários idealizados de separabilidade linear estrita (*margens rígidas*), o problema de otimização primal é formulado sob a seguinte estrutura de programação quadrática convexa:

$$\begin{aligned} & \underset{\mathbf{w}, b}{\text{minimizar}} && \frac{1}{2}\|\mathbf{w}\|^2 \\ & \text{sujeito a} && y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1, \quad \forall i = 1, \dots, n. \end{aligned} \tag{14}$$

3.1.3 Formulação de Margens Suaves e Variáveis de Folga

As matrizes de conectividade biológica obtidas via ANM incorporam flutuações térmicas e ruído estocástico inerentes à mecânica quântica e clássica molecular, fazendo com que os dados reais da MBP raramente manifestem separabilidade linear exata. Para conferir robustez matemática contra sobreajuste (*overfitting*), introduz-se o formalismo de *margens suaves* por meio de variáveis de folga (*slack variables*) $\xi_i \geq 0$, que toleram violações controladas das restrições geométricas [8, 12]:

$$\begin{aligned} & \underset{\mathbf{w}, b, \xi}{\text{minimizar}} && \frac{1}{2}\|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ & \text{sujeito a} && y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad \forall i = 1, \dots, n. \end{aligned} \tag{15}$$

O hiperparâmetro de regularização $C > 0$ governa o compromisso (*trade-off*) mecânico entre a maximização da largura da margem (estabilização do vetor $\|\mathbf{w}\|$) e a minimização do erro de classificação sumado ($\sum \xi_i$). Um valor de C elevado penaliza severamente as infrações lineares, estreitando a margem; inversamente, um C incipiente tolera desalinhamentos locais em favor de uma generalização preditiva superior.

3.1.4 Formulação Dual e o Truque do Kernel no Espaço de Paisagens

Dado que o problema (15) atende às condições de regularidade de Slater, a dualidade forte é verificada. A sua formulação dual, deduzida através da introdução dos multiplicadores de Lagrange $\alpha_i \geq 0$ aplicados sobre as restrições KKT, assume a forma de maximização côncava:

$$\begin{aligned} & \underset{\alpha}{\text{maximizar}} && \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \\ & \text{sujeito a} && \sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C. \end{aligned} \tag{16}$$

A resolução óptima deste sistema dual determina o vetor normal através da combinação linear dos vetores de treino:

$$\mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i. \quad (17)$$

Definição 13 (Vetores de Suporte). *Os **vetores de suporte** constituem o subconjunto crítico de estruturas do conjunto de treino cujos multiplicadores de Lagrange associados são estritamente positivos ($\alpha_i^* > 0$). Geometricamente, correspondem às proteínas cujas assinaturas topológicas se posicionam exatamente sobre os hiperplanos limítrofes $\mathcal{H}_{\pm}$ ou violam as margens estruturais. Pela Equação 17, constata-se que a fronteira de decisão $\mathbf{w}^*$ é governada exclusivamente por estes elementos; a remoção de qualquer outra proteína inerte do conjunto de dados preservará a superfície de separação inalterada.*




Figura 3: Projeção bidimensional do hiperplano ótimo de separação gerado pelo classificador SVM. A margem de decisão ($\mathcal{H}$) discrimina as conformações abertas e fechadas com base nas paisagens de persistência. As anomalias estruturais, como a 2N45 e 1DMB, localizam-se na vizinhança da fronteira, caracterizando estados de transição metaestáveis.

A característica central da formulação dual (16) é que os dados de entrada $\mathbf{x}_i$ emer-

gem unicamente através do produto interno escalar $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$. Isto viabiliza a execução do ****truque do kernel**** (*kernel trick*): substitui-se o produto interno elementar por um operador funcional generalizado $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}}$, permitindo mapear implicitamente as paisagens para um espaço de Hilbert $\mathcal{H}$ de alta dimensão sem computar explicitamente a transformação não-linear ϕ .

No presente arcabouço, os vetores de entrada $\mathbf{x}_i$ residem no espaço funcional das paisagens de persistência de grau 1, elementos nativos de $L^2(\mathbb{N} \times \mathbb{R})$. Como demonstrado analiticamente por Bubenik [4], o produto interno bilinear deste espaço de Lebesgue constitui, por si só, um kernel positivo definido dotado de convergência estrita:

$$\kappa(\mathcal{B}, \mathcal{B}') = \langle \lambda, \lambda' \rangle_{L^2(\mathbb{N} \times \mathbb{R})} = \sum_{k=1}^{\infty} \int_{\mathbb{R}} \lambda_k(t) \lambda'_k(t) dt, \quad (18)$$

onde λ e λ' representam as paisagens associadas aos diagramas de persistência $\mathcal{B}$ e $\mathcal{B}'$. O mapeamento linear aplicado às paisagens de persistência discretizadas e submetidas à redução via PCA constitui uma aproximação finita e computacionalmente estável deste operador funcional contínuo.

3.1.5 Métrica de Confiança e Interpretação Topológico-Termodinâmica

A imersão do classificador no espaço de Hilbert das interações elásticas confere à distância geométrica de uma determinada proteína $\mathbf{x}$ em relação ao hiperplano ótimo $\mathcal{H}$ uma ontologia física e molecular precisa. A distância ortogonal é quantificada por:

$$d(\mathbf{x}, \mathcal{H}) = \frac{|\langle \mathbf{w}^*, \mathbf{x} \rangle + b| \mathbf{1}_{[g(\mathbf{x})=y_i]}}{\|\mathbf{w}^*\|} = \frac{|f(\mathbf{x})|}{\|\mathbf{w}^*\|}, \quad (19)$$

onde $f(\mathbf{x})$ representa a magnitude escalar da função de decisão. Esta distância afim expande-se analiticamente sob duas interpretações biofísicas fundamentais:

- **Alta Distância Geométrica** ($d \gg 0$): A paisagem de persistência da macromolécula exibe de forma inequívoca e canônica a assinatura topológica estável da sua classe. Os ciclos unidimensionais em H_1 (canais de interações coordenadas de dobradiça) encontram-se completamente definidos. Do ponto de vista biofísico, a proteína localiza-se num poço profundo de potencial estável na paisagem de energia livre global, consideravelmente afastada da barreira de transição mecânica conformacional.
- **Baixa Distância Geométrica** ($d \approx 0$): A paisagem de persistência manifesta propriedades estruturais híbridadas e ambíguas. Os seus ciclos topológicos dinâmicos encontram-se numa fase de transição de "nascimento ou morte" ao longo do limiar de filtração ϵ . No espaço conformacional, isto identifica uma proteína que se situa na vizinhança imediata da barreira energética $\Delta G_{A \rightarrow F} \approx 0$, caracterizando um **estado metaestável intermediário de transição** de acordo com o modelo de Seleção Conformacional.

Parametrizando a distância média das 14 estruturas gabarito ao hiperplano como $\bar{d} \approx 1,67$, estabelece-se como candidato a estado intermediário de transição qualquer

conformação macromolecular cuja distância ortogonal satisfaça $d(\mathbf{x}, \mathcal{H}) < \delta$, onde δ constitui um limiar de tolerância topológica a ser calibrado. No presente estudo, conformações críticas como a estrutura livre 2N45 ($d = 0,19$) e a estrutura coordenada 1DMB ($d = 0,76$) enquadram-se nesta região de ambiguidade linear, sendo submetidas a uma validação geométrica ortogonal e direta no espaço cartesiano através do cômputo do RMSD de C_α .

3.2 Validação Estrutural e Comparação Geométrica: RMSD e o Algoritmo de Kabsch

A separação estatística e topológica das conformações proteicas via SVM no espaço de paisagens de persistência sugere uma distinção mecanicista profunda entre as formas aberta e fechada da MBP. Para validar fisicamente esta divergência no espaço real $\mathbb{R}^3$, recorre-se ao "padrão-ouro" da biologia estrutural para comparação tridimensional: o Desvio Quadrático Médio (*Root-Mean-Square Deviation* – RMSD), otimizado analiticamente pelo Algoritmo de Kabsch.

3.2.1 Definição Matemática do RMSD

O RMSD quantifica a similaridade geométrica absoluta entre duas conformações de uma mesma proteína. Sejam $\mathbf{A}$ e $\mathbf{B}$ duas estruturas proteicas (por exemplo, os estados *apo* e *holo*), cada uma representada matematicamente por uma matriz $3 \times N$, cujos vetores colunas $\mathbf{a}_k, \mathbf{b}_k \in \mathbb{R}^3$ contêm as coordenadas espaciais dos $N = 370$ átomos de carbono-alfa (C_α).

A definição formal do RMSD bruto entre estas duas estruturas é a raiz quadrada da média das distâncias euclidianas ao quadrado entre os átomos homólogos:

$$\text{RMSD}(\mathbf{A}, \mathbf{B}) = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{a}_k - \mathbf{b}_k\|^2}. \quad (20)$$

Contudo, como as coordenadas cristalográficas possuem orientações e posições arbitrárias no espaço, a métrica na Equação 20 é geometricamente ingênua. O verdadeiro valor do RMSD estrutural exige a sobreposição ótima de corpo rígido, ou seja, a minimização contínua dessa distância através de uma matriz de rotação apropriada $\mathbf{R}$:

$$D(\mathbf{A}, \mathbf{B}) = \min_{\mathbf{R}} \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{R}\mathbf{a}_k - \mathbf{b}_k\|^2}, \quad (21)$$

onde $\mathbf{a}_k$ e $\mathbf{b}_k$ assumem-se como vetores já centralizados na origem.

3.2.2 O Problema da Sobreposição Ótima (Algoritmo de Kabsch)

A extração da matriz de rotação ótima $\mathbf{R}$ que minimiza a Equação 21 é resolvida de forma exata e determinística pelo Algoritmo de Kabsch. Este método opera em três passos analíticos fundamentais:

1. Translação dos Centroides para a Origem: Primeiramente, elimina-se o vetor de translação espacial. Calculam-se os centroides (vetores médios) $\bar{\mathbf{a}}$ e $\bar{\mathbf{b}}$ geométricos de cada proteína:

$$\bar{\mathbf{a}} = \frac{1}{N} \sum_{k=1}^N \mathbf{a}_k^{\text{orig}}, \quad \bar{\mathbf{b}} = \frac{1}{N} \sum_{k=1}^N \mathbf{b}_k^{\text{orig}}.$$

De seguida, transladam-se rigidamente todos os átomos para que os centroides coincidam na origem $(0, 0, 0)$ do sistema de coordenadas:

$$\mathbf{a}_k = \mathbf{a}_k^{\text{orig}} - \bar{\mathbf{a}}, \quad \mathbf{b}_k = \mathbf{b}_k^{\text{orig}} - \bar{\mathbf{b}}.$$

2. Construção da Matriz de Covariância Cruzada: Expandindo algebricamente o argumento da distância ao quadrado a ser minimizado, obtemos:

$$D^2(\mathbf{A}, \mathbf{B}) = \frac{1}{N} \sum_{k=1}^N (\mathbf{a}_k^T \mathbf{a}_k + \mathbf{b}_k^T \mathbf{b}_k - 2\mathbf{b}_k^T \mathbf{R} \mathbf{a}_k).$$

Uma vez que os termos $\mathbf{a}_k^T \mathbf{a}_k$ e $\mathbf{b}_k^T \mathbf{b}_k$ definem os raios de giração das proteínas (que são propriedades intrínsecas e invariantes sob rotação), o problema de minimização do RMSD torna-se estritamente equivalente à *maximização do termo cruzado*. Para tal, define-se a matriz de covariância cruzada espacial $\mathbf{U} \in \mathbb{R}^{3 \times 3}$:

$$\mathbf{U} = \sum_{k=1}^N \mathbf{b}_k \mathbf{a}_k^T. \quad (22)$$

O nosso objetivo de otimização resume-se agora a encontrar a matriz de rotação $\mathbf{R}$ que maximize o traço do produto matricial: $\max \text{tr}(\mathbf{R}^T \mathbf{U})$.

3. Decomposição em Valores Singulares (SVD) e a Rotação Ótima: Aplica-se a Decomposição em Valores Singulares à matriz de covariância cruzada $\mathbf{U}$:

$$\mathbf{U} = \mathbf{V} \mathbf{\Sigma} \mathbf{W}^T, \quad (23)$$

onde $\mathbf{V}$ e $\mathbf{W}$ são matrizes ortogonais 3×3 , e $\mathbf{\Sigma}$ é a matriz diagonal dos valores singulares ordenados ($\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq 0$).

Para otimizar o alinhamento, a matriz teórica que resolve o problema linear é $\mathbf{R} = \mathbf{V} \mathbf{W}^T$. No entanto, o problema físico de proteínas impõe uma restrição de quiralidade rigorosa. Se o determinante da matriz de covariância for negativo ($\det(\mathbf{U}) < 0$), a solução algébrica pura resultaria numa matriz $\mathbf{R}$ com determinante -1 . Biologicamente, isto corresponderia a uma *reflexão* (inversão no espelho) da proteína, gerando um RMSD falsamente minimizado, porém fisicamente impossível no mundo real.

Para corrigir esta falha tridimensional, introduz-se a matriz de correção quiral $\mathbf{S} = \text{diag}(1, 1, d)$, onde $d = \text{sgn}(\det(\mathbf{V}\mathbf{W}^T)) = \pm 1$. A matriz de rotação ótima irretocável que garante o encaixe perfeito sem inversão de quiralidade é deduzida como:

$$\mathbf{R}^* = \mathbf{V} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & d \end{bmatrix} \mathbf{W}^T. \quad (24)$$

Sob esta rotação geométrica ótima, a forma quadrática final minimizada do RMSD consolida-se em:

$$D^2(\mathbf{A}, \mathbf{B}) = \frac{1}{N} \left(\sum_{k=1}^N \|\mathbf{a}_k\|^2 + \sum_{k=1}^N \|\mathbf{b}_k\|^2 - 2(\lambda_1 + \lambda_2 + d\lambda_3) \right). \quad (25)$$

3.2.3 Interpretação Biofísica da Distância

O escalar obtido através da Equação 25 traduz mecanicamente a disparidade das proteínas. Valores muito reduzidos (ex: $\text{RMSD} \approx 0.5$ a $2.0 \text{ \AA}$) indicam que ambas as cadeias polipeptídicas partilham o exato padrão de dobramento global (*general folding pattern*). Estas ligeiras discrepâncias são mero reflexo do ruído termodinâmico natural da molécula a vibrar em torno da mesma bacia de energia mínima.

A determinação empírica de estados conformacionais distintos (Aberto vs. Fechado) através de RMSD não deve apoiar-se em cortes (*cut-offs*) arbitrários. De acordo com a literatura seminal de validação estrutural, a confirmação de que duas proteínas habitam estados termodinâmicos mecanicamente divergentes pressupõe que o seu RMSD ultrapasse uma curva de limite dependente do número N de resíduos, frequentemente referida como D_0 .

Quando o RMSD estrutural transpassa o limiar significativo de deformação basal, obtém-se a prova empírica inquestionável de que os segmentos interdominiais sofreram rearranjos não-triviais. Na perspetiva da MBP, ultrapassar este limiar (frequentemente registado em valores $\geq 3.5 \text{ \AA}$ para domínios dobradiça completos) atesta geometricamente que o mecanismo alostérico deduzido pela Homologia Persistente H_1 operou fisicamente no espaço cartesiano, transmutando a topologia esparsa da forma livre na conformação densamente empacotada que engolfa o açúcar.

4 Resultados e Discussão

A metodologia híbrida desenvolvida neste estudo, que amalgama Análise Topológica de Dados (TDA), Máquinas de Vetores de Suporte (SVM) e validação geométrica pelo Algoritmo de Kabsch, foi aplicada à Proteína de Ligação à Maltose (MBP). Os resultados obtidos validam a premissa de que a classificação termodinâmica das conformações proteicas transcende a mera presença ou ausência do ligante químico (*apo* versus *holo*).

4.1 O Pipeline Computacional do Estudo

Para garantir a reprodutibilidade e a clareza da transição entre a fundamentação teórica e a experimentação empírica, o fluxo de processamento analítico foi estruturado nas seguintes etapas sequenciais:

1. **Dinâmica e Pseudométrica:** A partir das coordenadas cristalográficas (C_α), constrói-se o Modelo de Rede Anisotrópica (ANM) e deriva-se a matriz de correlação cruzada $\mathbf{C}$, mapeada na pseudométrica dinâmica $\mathbf{D}$.
2. **Homologia Persistente:** Aplica-se a filtração de Vietoris-Rips sobre $\mathbf{D}$, extraindo-se os diagramas de persistência referentes ao grupo de homologia H_1 (ciclos de comunicação alostérica).
3. **Vetorização via Paisagens de Persistência:** Os diagramas são mapeados no espaço funcional de Banach e convertidos em vetores. Empiricamente, o número de características topológicas detetadas ditou o hiperparâmetro estrutural de $k_{\max} = 73$ funções tenda (camadas). Discretizando cada camada em 50 pontos, cada proteína é representada por um vetor em $\mathbb{R}^{3650}$.
4. **Redução de Dimensionalidade Analítica (PCA):** O espaço $\mathbb{R}^{3650}$ é reduzido linearmente através de Análise de Componentes Principais (PCA). Os primeiros 3 componentes, retendo a maior variância do sistema, formam o novo espaço de características.
5. **Classificação (LOO-SVM):** Submete-se o espaço reduzido a um classificador de Máquinas de Vetores de Suporte (SVM) linear, validado estritamente por validação cruzada *Leave-One-Out* devido ao tamanho da amostra ($n = 14$).

4.2 Pipeline Topológico e Aprendizado de Máquina

A matriz de distâncias dinâmicas $\mathbf{D}$ foi computada para o conjunto de referência composto por 14 estruturas da MBP (7 abertas e 7 fechadas). A posterior filtração do complexo de Vietoris-Rips gerou as paisagens de persistência focadas no grupo de homologia H_1 , refletindo os canais de comunicação mecânica (alosteria) da macromolécula. Cada paisagem foi discretizada num vetor de alta dimensionalidade em $\mathbb{R}^{3650}$ (73 camadas $\times$ 50 pontos de resolução).

Para mitigar a maldição da dimensionalidade e permitir a aplicação do classificador, o espaço topológico foi submetido à Análise de Componentes Principais (PCA). Retiveram-se os três primeiros componentes principais ($d = 3$), os quais capturaram **52,79% da variância total** do sistema (CP1: 29,78%; CP2: 14,94%; CP3: 8,06%). Este valor está em estrita concordância com a variância reportada pela literatura original de Kovacev-Nikolic et al. [11] ($\sim 52,50\%$ para grau 1), atestando a fidelidade da extração.

Submetido à validação cruzada *Leave-One-Out* (LOO), o modelo SVM com *kernel* linear operando neste subespaço alcançou uma **acurácia de 100%** na discriminação das 14 proteínas molde. O hiperplano separador ótimo $\mathcal{H}$ foi assim perfeitamente

estabelecido, provando que a forma aberta e fechada são classes topologicamente linearmente separáveis no espaço de Hilbert L^2 .

4.3 Projeção de Novas Estruturas e Distância ao Hiperplano

Com o hiperplano afim de separação fixado ($\langle \mathbf{w}^*, \mathbf{x} \rangle + b = 0$), o modelo foi utilizado para prever a conformação de um conjunto expandido de 29 estruturas cristalográficas independentes (misturando estados *apo* e *holo*).

Para cada nova proteína, computou-se a sua distância geométrica ao hiperplano de decisão, $d(\mathbf{x}, \mathcal{H}) = |f(\mathbf{x})|/\|\mathbf{w}^*\|$. O valor médio obtido para as estruturas com classificação segura foi de $\bar{d} \approx 1,67$. A análise rigorosa destas distâncias revelou duas anomalias biológicas de extrema importância para o modelo de Seleção Conformacional:

1. **A anomalia 1DMB (Holo, prevista como Aberta):** A proteína 1DMB contém o ligante maltose acoplado (estado *holo*), o que convencionalmente a ditaria como fechada no modelo de "Encaixe Induzido". Contudo, o SVM classificou-a inequivocamente como **Aberta**. A sua distância ao hiperplano ($d = 0,7676$) indica uma estrutura moderadamente atípica, evidenciando que a presença mecânica do ligante não foi suficiente para colapsar os domínios para a forma fechada.
2. **A anomalia 2N45 (Apo, prevista como Fechada):** A proteína 2N45 está livre de ligante (estado *apo*), mas o SVM previu-a como **Fechada**. Notavelmente, a sua distância geométrica é incrivelmente baixa ($d = 0,1985$), colocando-a diretamente na margem do hiperplano de decisão (≈ 0). Matematicamente, a 2N45 representa o estado metaestável de transição: uma proteína vazia cujas molas elásticas estão já a transitar espontaneamente para a conformação fechada de captura.

4.4 Validação Estrutural Ortogonal via Algoritmo de Kabsch (RMSD)

Para confirmar se as previsões operadas no espaço funcional L^2 correspondem à realidade cartesiana tridimensional, executou-se a sobreposição rígida ótima dos carbonos-alfa utilizando o Algoritmo de Kabsch. O RMSD das 29 proteínas foi computado em relação aos referenciais estritos fechado (1ANF) e aberto (1OMP). A classificação geométrica do RMSD atestou qual distância era minimizada para cada macromolécula.

Os resultados demonstraram uma **concordância massiva de 89,6% (26 de 29 casos)** entre o modelo geométrico clássico tridimensional e a inteligência artificial topológica abstrata. Destaca-se a proteína 1DMB, cuja anomalia foi confirmada por ambos os métodos: quer por topologia (SVM), quer por métrica estrita (RMSD em relação à Aberta = 0,46 Å; em relação à Fechada = 3,47 Å), ela é uma proteína conformacionalmente Aberta, apesar da sua química *Holo*. Este é o indício definitivo empírico que sustenta o título do presente trabalho.

4.4.1 Análise das Divergências Topológico-Geométricas

As 3 proteínas que divergiram merecem escrutínio biofísico. Quando a Topologia diverge da Geometria (RMSD), revela-se a principal vantagem da Análise Topológica de Dados: a capacidade de "enxergar" a mecânica em vez de apenas a forma.

Tabela 2: Análise das divergências entre o classificador dinâmico (SVM) e o alinhamento estático (RMSD).

PDB	Química	SVM (TDA)	RMSD Mínimo	RMSD vs Aberta	RMSD vs Fechada
2N45	<i>Apo</i>	Fechada	Aberta	2,32 Å	3,51 Å
2MV0	<i>Apo</i>	Aberta	Fechada	4,21 Å	3,92 Å
7Z7H	<i>Apo</i>	Aberta	Fechada	26,84 Å	26,27 Å

- **A transição da 2N45:** O RMSD clássico enquadra-a matematicamente como Aberta ($2,32 < 3,51$). No entanto, a TDA classificou-a como Fechada. Como visto na Subsecção 4.3, ela reside em cima do hiperplano topológico ($d = 0,19$). A TDA capturou a "tensão da rede elástica" dos canais de comunicação da dobradiça que o raio-x estático não consegue mensurar plenamente. A proteína 2N45 está a fechar-se espontaneamente através de Seleção Conformacional, exibindo homologia funcional fechada antes de atingir o encaixe estrutural mínimo.
- **O limite prático do RMSD rígido (7Z7H):** A estrutura 7Z7H acusou um RMSD divergente na ordem de ~ 26 Å. Em biologia estrutural, um desvio desta magnitude não traduz uma mera mudança conformacional funcional, sugerindo antes problemas severos no alinhamento tridimensional (tais como ausência de cadeias homólogas, numeração de resíduos não padrão ou artefatos de resolução espacial profunda). Perante anomalias que inviabilizam o alinhamento de corpo rígido, o algoritmo de Kabsch perde a sua interpretabilidade física. O facto de o modelo SVM ter processado a proteína normalmente, gerando um vetor de distâncias dinâmicas válido baseado na conectividade interna relativa, ilustra uma vantagem mecânica da Topologia: por basear-se em distâncias intra-moleculares (matriz **D**), a TDA mostra-se resiliente a distorções coordenadas extremas que corrompem fatalmente os descritores euclidianos absolutos.

Em suma, a experimentação analítica confirma o poder da matriz Hessiana aliada à Homologia Persistente. O "laço de vida mais longa" na dimensão 1 não representa apenas um espaço vazio; é a assinatura da via alostérica ativa da MBP. Comprovou-se empiricamente que o fechamento proteico é governado pelo equilíbrio dinâmico e pela seleção de paisagens termodinâmicas, rejeitando axiomas rígidos em que os estados conformacionais funcionam como meros recetáculos binários.

Referências

- [1] A. R. Atilgan et al. “Anisotropy of Fluctuation Dynamics of Proteins with an Elastic Network Model”. Em: *Biophysical Journal* 80.1 (2001), pp. 505–515.
- [2] Frances C. Bernstein et al. “The Protein Data Bank: A Computer-based Archival File For Macromolecular Structures”. Em: *Journal of Molecular Biology* 112.3 (1977), pp. 535–542.
- [3] W. Boos e H. Shuman. “Maltose/Maltodextrin System of Escherichia coli: Transport, Metabolism, and Regulation”. Em: *Microbiology and Molecular Biology Reviews* 62.1 (1998), pp. 204–229.
- [4] Peter Bubenik. “Statistical topological data analysis using persistence landscapes”. Em: *Journal of Machine Learning Research* 16.1 (2015), pp. 77–102.
- [5] D. Bucher, Barry J. Grant e J. Andrew McCammon. “Induced Fit or Conformational Selection? The Role of the Semi-closed State in the Maltose Binding Protein”. Em: *Biochemistry* 50 (2011), pp. 10530–10539.
- [6] Zixuan Cang, Lin Mu e Guo-Wei Wei. “Representability of algebraic topology for biomolecules in machine learning based scoring and virtual screening”. Em: *PLoS computational biology* 14.1 (2018). Preprint originalmente submetido em 2015 (arXiv:1510.00953), e1005929.
- [7] Zixuan Cang et al. *A topological approach for protein classification*. Preprint submetido em Outubro de 2015. Out. de 2015.
- [8] Corinna Cortes e Vladimir Vapnik. “Support-Vector Networks”. Em: *Machine Learning* 20.3 (1995), pp. 273–297. DOI: [10.1007/BF00994018](https://doi.org/10.1007/BF00994018).
- [9] Jay L. Devore. *Probabilidade e Estatística para Engenharia e Ciências*. 8ª ed. São Paulo, Brasil: Cengage Learning, 2012.
- [10] S. Hudault, J. Guignot e A. L. Servin. “Escherichia coli strains colonising the gastrointestinal tract protect germfree mice against Salmonella typhimurium infection”. Em: *Gut* 49.1 (2001), pp. 47–55.
- [11] Violeta Kovacev-Nikolic et al. “Using persistent homology and dynamical distances to analyze protein binding”. Em: *Statistical Applications in Genetics and Molecular Biology* 15.1 (2016), pp. 19–38.
- [12] Ana Carolina Lorena e André C. P. L. F. de Carvalho. “Uma Introdução às Support Vector Machines”. Em: *RITA (Revista de Informática Teórica e Aplicada)* 14.2 (2007), pp. 43–67.
- [13] D. Seeliger e B. L. de Groot. “Conformational Transitions upon Ligand Binding: Holo-Structure Prediction from Apo Conformations”. Em: *PLoS Computational Biology* 6.1 (2010), e1000634.
- [14] John C. Spurlino, Guang-Ying Lu e Florante A. Quioco. “The 2.3-Å Resolution Structure of the Maltose- or Maltodextrin-binding Protein, A Primary Receptor of Bacterial Active Transport and Chemotaxis”. Em: *THE JOURNAL OF BIOLOGICAL CHEMISTRY* 266.8 (1991).
- [15] Joshua B. Tenenbaum, Vin de Silva e John C. Langford. “A Global Geometric Framework for Nonlinear Dimensionality Reduction”. Em: *Science* 290.5500 (2000), pp. 2319–2323. DOI: [10.1126/science.290.5500.2319](https://doi.org/10.1126/science.290.5500.2319).

- [16] R. Van Houdt e C. W. Michiels. “Role of bacterial cell surface structures in *Escherichia coli* biofilm formation”. Em: *Research in Microbiology* 156.5-6 (2005), pp. 626–633.