

Monografia

-

10 de junho de 2026

1 Fundamentação Teórica

1.1 Da Estrutura Estática à Dinâmica: Cristalografia e Modelo de Grão Grosso

A proteína de ligação à maltose é uma proteína bacteriana encontrada em *Escherichia coli*, onde sua função primária é ligar e transportar moléculas de açúcar através das membranas celulares, fornecendo energia à bactéria [3]. Embora às vezes cause doenças graves, a maioria das cepas de *E. coli* é não patogênica e, na verdade, benéfica. Essas bactérias colonizam o trato gastrointestinal de humanos e animais e protegem o intestino de bactérias nocivas [10]. Além disso, *E. coli* é o organismo vivo mais bem conhecido e é usado para estudar vários processos celulares [16]. Em nosso artigo, usamos métodos topológicos para estudar a MBP.

Enquanto realiza funções biológicas, a MBP muda sua estrutura. As 14 estruturas cristalográficas da MBP utilizadas como modelo gabarito foram obtidas por cristalografia de raios X e depositadas no *Protein Data Bank* (PDB). A cristalografia de raios X é uma técnica experimental onde a proteína purificada é forçada a precipitar de uma solução até formar um cristal sólido e ordenado [14]. Quando um feixe de raios X é disparado contra esse cristal, os elétrons dos átomos da proteína difratam (espalham) os raios em várias direções. Computadores analisam o padrão e a intensidade desses feixes difratados para reconstruir um "mapa de densidade eletrônica", o que permite aos pesquisadores deduzir as coordenadas espaciais (x, y, z) exatas de quase todos os átomos da biomolécula no espaço tridimensional. É essencialmente uma fotografia de alta resolução, mas estática, da proteína.

Cada estrutura da MBP contém aproximadamente 3000 átomos pesados. Trabalhar diretamente com todos eles implicaria operar num espaço de configurações $\mathbb{R}^{3 \times 3000} \cong \mathbb{R}^{9000}$, tornando inviável tanto a construção computacional do Complexo de Vietoris-Rips quanto a interpretação biológica dos invariantes topológicos obtidos [7]. A solução adotada é o **modelo de grão grosso** (*coarse-grained model*): agrupam-se todos os átomos de cada resíduo de aminoácido num único nó representativo, reduzindo os 3000 átomos a $N = 370$ pontos [11].

Definição 1 (Espaço de Configurações Reduzido). *Seja $N = 370$ o número de resíduos da MBP. Denota-se por $\mathbf{r}_i \in \mathbb{R}^3$ a posição do nó representativo do i -ésimo*

resíduo. Uma conformação da proteína é o vetor de estado espacial:

$$\mathbf{R} = (\mathbf{r}_1, \mathbf{r}_2, \dots, \mathbf{r}_N) \in \mathbb{R}^{3 \times N} \cong \mathbb{R}^{1110}.$$

O espaço de conformações termicamente acessíveis é um subespaço de $\mathbb{R}^{1110}$, e é este subespaço reduzido que a homologia persistente irá caracterizar topologicamente.

O nó representativo escolhido é o **carbono-alfa** (C_α), o átomo central do esqueleto peptídico do qual partem tanto as ligações peptídicas (que unem resíduos consecutivos) quanto as cadeias laterais (que variam entre os 20 aminoácidos). A escolha geométrica é justificada por três razões complementares atestadas na literatura estrutural:

1. **Estabilidade geométrica:** as cadeias laterais apresentam grande mobilidade rotacional (ruído conformacional térmico), enquanto a cadeia principal de C_α forma uma curva contínua e geometricamente estável que define a topologia de contactos essenciais da proteína [6].
2. **Redução de complexidade algorítmica:** ao focar nos C_α , o espaço de trabalho métrico cai de $\mathbb{R}^{9000}$ para $\mathbb{R}^{1110}$, reduzindo drasticamente o custo computacional da matriz de distâncias e da subsequente filtração topológica [6].
3. **Base para a Dinâmica de Redes:** como demonstrado formalmente por Atilgan et al. [1], os átomos C_α funcionam como os *nós* da rede elástica, e as distâncias de equilíbrio entre eles representam os parâmetros geométricos estritamente necessários para construir a Matriz Hessiana do sistema mecânico.

1.2 Termodinâmica do Fechamento Conformacional e Seleção Conformacional

A função biológica da MBP — capturar e transportar moléculas de maltose no espaço periplasmático — é governada por uma arquitetura estrutural altamente flexível. A proteína é composta por dois domínios globulares principais (N-terminal e C-terminal) conectados por uma região de laços flexíveis que actua como uma dobradiça (*hinge*). O mecanismo de captura do ligante assemelha-se ao fechamento de uma armadilha (*Venus flytrap mechanism*), resultando em alterações geométricas macroscópicas na estrutura da macromolécula [14].

Estudos baseados em cristalografia de raios X e dinâmica molecular, como os conduzidos por Bucher et al. [5], classificam as conformações da MBP em três macroestados estruturais principais (ver Figura 1):

1. **Estado Aberto (*Open*):** Caracteriza-se por uma grande separação angular e espacial entre os dois domínios globulares. É a forma predominante da proteína no estado *apo* (livre de ligante), representando o mínimo global de energia do sistema na ausência do açúcar.
2. **Estado Semi-fechado (*Semi-closed*):** Um estado intermediário transiente. A estrutura apresenta um fechamento parcial da fenda interdominial.

3. **Estado Fechado (*Closed*):** Os domínios globulares aproximam-se significativamente, engolfando completamente o ligante na fenda catalítica. Este é o estado funcional ativo, frequentemente associado à forma *holo* (ligada à maltose).




Figura 1: Representação das transições conformacionais da MBP. Da esquerda para a direita: Estado Aberto, Semi-fechado transiente e Fechado estabilizado pelo ligante (em vermelho). Fonte: Adaptado de Bucher et al. [5].

Historicamente, assumia-se que a transição do estado aberto para o fechado era estritamente induzida pelo impacto mecânico da entrada da maltose na fenda (modelo de *Encaixe Induzido*). Contudo, a biofísica estrutural contemporânea demonstra que a MBP opera sob o princípio da **Seleção Conformacional** [13]. Segundo este modelo, a proteína não é estática; ela "respira" e oscila naturalmente entre as formas aberta e semi-fechada através de flutuações térmicas, mesmo sem a presença do ligante.

O papel da maltose, portanto, não é forçar o fechamento da dobradiça, mas sim *estabilizar* a forma fechada pré-existente. Quando o ligante se aloja na fenda, ele estabelece uma rede complexa de ligações de hidrogénio que compensa a tensão elástica da proteína, tornando a conformação fechada termodinamicamente favorável [5].

É precisamente esta vasta gama de flutuações e movimentos cooperativos de dobradiça — que ocorrem independentemente da presença do açúcar — que torna a geometria euclidiana estática insuficiente para classificar as proteínas. Para mapear com rigor estes padrões de oscilação em trajetórias matemáticas, o sistema deve ser modelado através das suas interações de rede elástica.

Em [11] é coletado um conjunto de 14 proteínas, separadas em: sete conformações fechadas e sete conformações abertas. Há uma diferença entre elas usando energias de deformação; a conformação fechada energeticamente mais favorável liga uma molécula de açúcar, enquanto sua contraparte aberta requer maiores energias de deformação e pode ou não se envolver no processo de ligação. A lista das quatorze estruturas da MBP que foram investigadas é mostrada na Tabela 1.

Nº	Código PDB	Nome do Ligante	Estrutura da Proteína	Referência
1	1ANF	maltose	fechada- <i>holo</i>	Quiocho et al. (1997)
2	1FQC	maltotriitol	fechada- <i>holo</i>	Duan et al. (2001)
3	1FQD	maltotetraitol	fechada- <i>holo</i>	Duan et al. (2001)
4	1MPD	maltose	fechada- <i>holo</i>	Shilton et al. (1996)
5	3HPI	sacarose	fechada- <i>holo</i>	Gould & Shilton (2010)
6	3MBP	maltotriose	fechada- <i>holo</i>	Quiocho et al. (1997)
7	4MBP	maltotetraose	fechada- <i>holo</i>	Quiocho et al. (1997)
8	1EZ9	maltotetraitol	aberta- <i>holo</i>	Duan & Quiocho (2002)
9	1FQA	maltotetraitol	aberta- <i>holo</i>	Duan et al. (2001)
10	1FQB	maltotetraitol	aberta- <i>holo</i>	Duan et al. (2001)
11	1JW4	—	aberta- <i>apo</i>	Duan & Quiocho (2002)
12	1JW5	maltose	aberta- <i>holo</i>	Duan & Quiocho (2002)
13	1LLS	—	aberta- <i>apo</i>	Rubin et al. (2002)
14	1OMP	—	aberta- <i>apo</i>	Sharff et al. (1992)

Tabela 1: Tabela retirada de [11]. Quatorze estruturas da MBP com os nomes dos ligantes para as formas *holo*. Cada estrutura é identificada por um código de quatro letras do Protein Data Bank [2].

1.3 O Formalismo da Rede Anisotrópica (ANM) e a Matriz Hessiana Estrutural

Para mapear com rigor analítico as flutuações e os movimentos cooperativos de dobradiça da MBP, faz-se necessário transcender as descrições estáticas e adotar um modelo mecânico das interações moleculares. O fundamento teórico para modelar as flutuações direcionais tridimensionais repousa sobre o formalismo do Modelo de Rede Anisotrópica (*Anisotropic Network Model* – ANM), introduzido pelo estudo seminal de Atilgan et al. [1]. Este modelo supera as limitações topológicas clássicas do Modelo de Rede Gaussiana (*Gaussian Network Model* – GNM) o qual, por ser puramente escalar, pressupõe flutuações isotrópicas e omite as preferências direcionais dos resíduos ao longo dos eixos cartesianos.

1.3.1 Formulação Tridimensional da Energia Potencial Elástica

No âmbito do ANM, a arquitetura estrutural da MBP ($N = 370$ resíduos) é convertida num sistema mecânico de grão grosso. Pares de nós (carbonos-alfa) cujas distâncias geométricas na estrutura cristalográfica de equilíbrio sejam inferiores a um raio de corte termodinâmico (r_c , tipicamente parametrizado entre 13 e 15 Å) são modelados como se estivessem conectados por molas harmônicas virtuais submetidas a uma constante de força fenomenológica uniforme γ .

Sejam $\mathbf{r}_i = (X_i, Y_i, Z_i)^T$ e $\mathbf{r}_j = (X_j, Y_j, Z_j)^T$ os vetores posição instantâneos dos resíduos i e j sob agitação térmica, e $\mathbf{r}_i^0, \mathbf{r}_j^0$ as suas respectivas coordenadas de relaxamento (equilíbrio) obtidas via cristalografia. A distância instantânea é definida pela norma euclidiana $s_{ij} = |\mathbf{r}_{ij}| = |\mathbf{r}_j - \mathbf{r}_i|$, enquanto a distância de relaxamento elástico é dada por $s_{ij}^0 = |\mathbf{r}_{ij}^0| = |\mathbf{r}_j^0 - \mathbf{r}_i^0|$.

Sob a aproximação harmônica para pequenas flutuações, a energia potencial total

de deformação do sistema mecânico, V_{total} , é expressa pelo somatório escalar das contribuições elásticas par a par:

$$V_{\text{total}} = \frac{\gamma}{2} \sum_{i=1}^{N-1} \sum_{j=i+1}^N \left[\sqrt{(X_j - X_i)^2 + (Y_j - Y_i)^2 + (Z_j - Z_i)^2} - s_{ij}^0 \right]^2 \mathbf{1}_{[(i,j) \in \mathcal{E}]}, \quad (1)$$

onde $\mathcal{E}$ define o conjunto de contactos topológicos intrínsecos determinado pelo raio de corte, de modo que a função indicadora $\mathbf{1}_{[(i,j) \in \mathcal{E}]} = 1$ se, e somente se, $s_{ij}^0 \leq r_c$, assumindo o valor 0 caso contrário.

1.3.2 Construção Analítica da Matriz Hessiana

O comportamento dinâmico e as forças de restituição do sistema linearizado em torno do mínimo global de energia elástica são inteiramente mapeados pela matriz Hessiana estrutural, denotada por $\mathbf{H} \in \mathbb{R}^{3N \times 3N}$. A matriz $\mathbf{H}$ é construída através da expansão em série de Taylor de segunda ordem do potencial V_{total} e é estruturada matematicamente em $N \times N$ sub-blocos (ou super-elementos) de dimensão 3×3 .

Cada sub-bloco $\mathbf{H}_{ij}$ encapsula as segundas derivadas parciais do potencial elástico em relação às componentes cartesianas dos deslocamentos espaciais dos nós i e j . Para os super-elementos *fora da diagonal principal* ($i \neq j$), que calculam o acoplamento mecânico direcional da mola entre dois resíduos distintos, a diferenciação analítica da Equação (1) avaliada na configuração de equilíbrio resulta na seguinte matriz Jacobiana de interações:

$$\mathbf{H}_{ij} = \begin{bmatrix} \frac{\partial^2 V}{\partial X_i \partial X_j} & \frac{\partial^2 V}{\partial X_i \partial Y_j} & \frac{\partial^2 V}{\partial X_i \partial Z_j} \\ \frac{\partial^2 V}{\partial Y_i \partial X_j} & \frac{\partial^2 V}{\partial Y_i \partial Y_j} & \frac{\partial^2 V}{\partial Y_i \partial Z_j} \\ \frac{\partial^2 V}{\partial Z_i \partial X_j} & \frac{\partial^2 V}{\partial Z_i \partial Y_j} & \frac{\partial^2 V}{\partial Z_i \partial Z_j} \end{bmatrix} \quad (2)$$

A expressão (2) pode ser escrita de forma elegante através do produto externo (*outer product*) do vetor de distância geométrica $\mathbf{r}_{ij}^0$:

$$\mathbf{H}_{ij} = -\frac{\gamma}{(s_{ij}^0)^2} (\mathbf{r}_{ij}^0) (\mathbf{r}_{ij}^0)^T \mathbf{1}_{[(i,j) \in \mathcal{E}]}. \quad (3)$$

Inversamente, os super-elementos localizados na *diagonal principal* da Hessiana ($\mathbf{H}_{ii}$) não modelam uma interação individual, mas sim a soma vetorial das forças de reação elástica exercidas por todas as molas conectadas ao i -ésimo nó. Por imperativo da terceira lei de Newton e da conservação do momento linear (invariância translacional), a diagonal é rigorosamente definida pelo balanço negativo das interações circundantes:

$$\mathbf{H}_{ii} = -\sum_{j \neq i}^N \mathbf{H}_{ij}. \quad (4)$$

A matriz global $\mathbf{H}$ assim construída é simétrica e semidefinida positiva, abrigando toda a topologia de conectividade e as anisotropias mecânicas que definem o estado termodinâmico da MBP.

1.4 Decomposição Espectral, Truncamento e a Correlação Cruzada

A matriz Hessiana $\mathbf{H} \in \mathbb{R}^{3N \times 3N}$, derivada na secção anterior, contém a totalidade da informação sobre o panorama de flutuações da proteína ao redor do seu estado de equilíbrio. Sendo $\mathbf{H}$ uma matriz real, simétrica e semidefinida positiva, o seu comportamento termodinâmico pode ser dissecado resolvendo o problema de autovalores, o que equivale a realizar uma transformação ortogonal de coordenadas conhecida como decomposição espectral.

1.4.1 Modos Normais e Truncamento de Baixa Frequência

A diagonalização da matriz Hessiana fornece um conjunto completo de $3N$ autovalores λ_k e os seus respetivos autovetores ortonormais $\mathbf{u}_k \in \mathbb{R}^{3N}$:

$$\mathbf{H} = \sum_{k=1}^{3N} \lambda_k \mathbf{u}_k \mathbf{u}_k^T. \quad (5)$$

Fisicamente, os autovalores estão diretamente relacionados com a rigidez direcional e são proporcionais ao quadrado das frequências vibracionais dos modos normais ($\lambda_k \propto \omega_k^2$). Os autovetores $\mathbf{u}_k$ descrevem a forma geométrica (direção e amplitude) do deslocamento coletivo dos resíduos sob aquele específico modo de vibração.

Devido à invariância translacional e rotacional da molécula inteira como um corpo rígido livre no espaço tridimensional, os primeiros seis autovalores ($k = 1, \dots, 6$) são estritamente nulos ($\lambda_k = 0$). Restam, portanto, $3N - 6 = 1104$ modos físicos não-triviais de oscilação interna.

A conexão matemática entre este arcabouço biofísico e a metodologia estatística delineada por Kovacev-Nikolic et al. [11] estabelece-se por meio do **truncamento espectral**. Autovalores de grande magnitude correspondem a movimentos rápidos, locais e de alta frequência (tais como estiramentos de ligações covalentes pontuais), que representam mero ruído termodinâmico na perspetiva da transição funcional da proteína.

Para capturar exclusivamente a mecânica cooperativa global — isto é, o movimento de dobradiça (*hinge-bending*) essencial para a captura da maltose —, opera-se uma restrição do espaço dimensional. Filtram-se as vibrações atômicas de alta frequência e retêm-se apenas os primeiros $M = 20$ modos não-triviais de menor autovalor ($k = 7, \dots, 26$). A matriz pseudoinversa de Moore-Penrose truncada, $\mathbf{H}_{\text{trunc}}^+$, é reconstruída estritamente sobre este subespaço funcional de baixa frequência:

$$\mathbf{H}_{\text{trunc}}^+ = \sum_{k=7}^{7+M-1} \frac{1}{\lambda_k} \mathbf{u}_k \mathbf{u}_k^T. \quad (6)$$

1.4.2 Derivação da Matriz de Correlação Cruzada

Sob a aproximação de que as flutuações conformacionais ($\Delta \mathbf{R}$) seguem uma distribuição multivariada exata de Boltzmann, Atilgan et al. [1] demonstram que a covariância termodinâmica entre as flutuações espaciais dos resíduos i e j é diretamente proporcional aos sub-blocos 3×3 da matriz pseudoinversa.

O produto interno termodinâmico (covariância cruzada) é obtido calculando o traço (Tr), ou seja, a soma dos elementos da diagonal principal, do respectivo sub-bloco $[\mathbf{H}_{\text{trunc}}^+]_{ij}$:

$$\langle \Delta \mathbf{r}_i \cdot \Delta \mathbf{r}_j \rangle = k_B T \text{Tr} \left([\mathbf{H}_{\text{trunc}}^+]_{ij} \right), \quad (7)$$

onde k_B é a constante de Boltzmann e T a temperatura absoluta. Para isolar a pureza direcional do movimento e anular as diferenças de magnitude absoluta das flutuações, normaliza-se esta covariância. Define-se assim a **correlação cruzada dinâmica normalizada** (C_{ij}) entre qualquer par de resíduos na proteína:

$$C_{ij} = \frac{\text{Tr} \left([\mathbf{H}_{\text{trunc}}^+]_{ij} \right)}{\sqrt{\text{Tr} \left([\mathbf{H}_{\text{trunc}}^+]_{ii} \right) \text{Tr} \left([\mathbf{H}_{\text{trunc}}^+]_{jj} \right)}}, \quad C_{ij} \in [-1, 1]. \quad (8)$$

Esta matriz de correlação $\mathbf{C} \in \mathbb{R}^{N \times N}$ destila a totalidade da coreografia mecânica da MBP: valores positivos próximos de 1 denotam resíduos que se deslocam de forma coordenada na mesma direção; valores negativos próximos de -1 identificam resíduos em oposição de fase (anticorrelação, agindo como os braços opostos de uma alavanca); e valores nulos indicam independência cinemática e ausência de comunicação alostérica.

1.5 Transição Métrica: Da Geometria Euclidiana à Topologia Dinâmica

O emprego clássico da Análise Topológica de Dados (TDA) em biologia estrutural baseia-se frequentemente nas coordenadas espaciais cartesianas (X, Y, Z) para construir o espaço métrico subjacente. Contudo, como estabelecido nas secções anteriores, as coordenadas obtidas por cristalografia de raios X fornecem apenas uma estrutura média termodinâmica da molécula. Visto que a função de captura do ligante pela MBP depende intrinsecamente das flutuações ao longo do tempo, o descarte deliberado da distância euclidiana pura em favor de um descritor dinâmico é estritamente necessário [11].

Para preparar os dados das flutuações para a construção do complexo de Vietoris-Rips, utiliza-se a transformação linear da matriz de correlação cruzada normalizada $\mathbf{C}$ (Equação 8) na matriz de distâncias dinâmicas $\mathbf{D}$ (Equação 9). Esta nova matriz é definida elemento a elemento pela relação:

$$D_{ij} = 1 - |C_{ij}|. \quad (9)$$

Esta conversão mapeia o domínio de $[-1, 1]$ da correlação para um espaço pseudo-métrico rigoroso $[0, 1]$, carregando implicações estatísticas e topológicas profundas.

1.5.1 O Significado Probabilístico e a Pseudométrica

Sob a óptica da teoria das probabilidades [9], o coeficiente de correlação é um estimador paramétrico que quantifica a força e a direção da dependência linear entre duas variáveis aleatórias. A aplicação do valor absoluto acoplada ao deslocamento linear em (9) promove um reescalonamento probabilístico exacto:

- **Alta Dependência Cinemática** ($|C_{ij}| \rightarrow 1$): A operação de módulo confere o mesmo peso analítico tanto à correlação perfeitamente positiva (movimento uníssono no mesmo sentido) quanto à anticorrelação extrema (movimento em sentidos opostos, como as alavancas de uma tesoura). Neste limite, a distância atribuída tende a zero ($D_{ij} \rightarrow 0$). Probabilisticamente, isto atesta um elevado grau de determinismo: conhecer o vetor de deslocamento termodinâmico do resíduo i determina de forma perfeitamente previsível a resposta mecânica do resíduo j .
- **Independência e Ruído Térmico** ($C_{ij} \rightarrow 0$): Se as vibrações mecânicas de dois resíduos são ortogonais ou governadas por ruído térmico aleatório e independente, a relação linear anula-se. Consequentemente, a equação devolve a distância matemática máxima estipulada pelo modelo ($D_{ij} \rightarrow 1$).

A matriz $\mathbf{D}$ satisfaz as propriedades de não-negatividade ($D_{ij} \geq 0$), simetria ($D_{ij} = D_{ji}$) e identidade dos indiscerníveis ($D_{ii} = 0$). A desigualdade triangular ($D_{ik} \leq D_{ij} + D_{jk}$) é matematicamente garantida pelo facto de $|C_{ij}|$ derivar de um produto interno num espaço de Hilbert de flutuações, decorrendo assim da desigualdade de Cauchy-Schwarz. Estas propriedades validam $\mathbf{D}$ como uma pseudométrica fidedigna.

1.6 Redução de Dimensionalidade e Visualização do Espaço de Comunicação: ISOMAP

A construção da matriz de distâncias dinâmicas $\mathbf{D} \in \mathbb{R}^{N \times N}$ (onde $N = 370$ resíduos) dota a proteína de uma nova geometria topológica, fundamentalmente distinta da sua estrutura física. Neste novo espaço métrico de dimensão N , os resíduos que se movem de forma termodinamicamente coordenada estão próximos (distância tendendo a zero), independentemente de quão distantes estejam na estrutura cristalográfica original em $\mathbb{R}^3$.

Contudo, $\mathbf{D}$ é um objeto de alta dimensionalidade. Para que seja possível inspecionar visualmente este “espaço de comunicação” e extrair a sua estrutura global latente, é imperativo aplicar técnicas de redução de dimensionalidade. O objetivo matemático subjacente é encontrar um conjunto de coordenadas de baixa dimensão $\mathbf{Y} = \{\mathbf{y}_1, \dots, \mathbf{y}_N\} \subset \mathbb{R}^d$ (com $d \ll N$) de modo que a distância euclidiana neste novo subespaço mapeie o mais fielmente possível a distância dinâmica original, ou seja, $\|\mathbf{y}_i - \mathbf{y}_j\|_{\mathbb{R}^d} \approx D_{ij}$.

1.6.1 A Limitação do MDS Clássico

A abordagem analítica padrão para este problema de imersão métrica é o *Multidimensional Scaling* Clássico (MDS). O MDS opera transformando a matriz de distâncias ao quadrado $\mathbf{D}^{(2)}$ numa matriz de produtos internos (matriz de Gram) através de um operador de dupla centralização (*double centering*):

$$\mathbf{B} = -\frac{1}{2}\mathbf{H}\mathbf{D}^{(2)}\mathbf{H}, \quad \text{onde } \mathbf{H} = \mathbf{I} - \frac{1}{N}\mathbf{1}\mathbf{1}^T, \quad (10)$$

sendo $\mathbf{I}$ a matriz identidade de ordem N e $\mathbf{1}$ um vetor coluna de uns. Em seguida, realiza-se a decomposição espectral $\mathbf{B} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T$ e retêm-se os d maiores autovalores para construir as coordenadas projetadas.

No entanto, conforme reportado por Kovacev-Nikolic et al. [11], o MDS apresenta erros residuais elevados ao lidar com a dinâmica da MBP. A justificativa rigorosa para esta falha reside no facto de o MDS assumir que os dados residem num subespaço global *linear* (um hiperplano rígido). A dinâmica conformacional de uma proteína, guiada por potenciais harmónicos locais e barreiras estéricas, desenvolve-se sobre uma *variedade não-linear* (*manifold*) intrincada e curva no espaço de fase. Ao tentar preservar todas as distâncias globais por meio de linhas retas euclidianas intrínsecas ao modelo linear, o MDS cria "curtos-circuitos" através de regiões do espaço que são termodinamicamente inatingíveis para a estrutura real da proteína.

1.6.2 A Solução via ISOMAP e Distâncias Geodésicas

Para mitigar a distorção imposta pelas projeções lineares, o estudo adota o **ISOMAP** (*Isometric Mapping*) [15]. O ISOMAP é uma técnica de *manifold learning* que generaliza o MDS clássico, substituindo as métricas euclidianas diretas por **distâncias geodésicas** — isto é, as distâncias medidas estritamente *ao longo da superfície* curvada da variedade dos dados. O rigor do algoritmo ISOMAP desdobra-se em três etapas computacionais:

1. **Construção do Grafo de Vizinhança Local:** Define-se um grafo ponderado $G = (V, E)$, onde os vértices são os N resíduos. Uma aresta conecta o nó i ao nó j apenas se estes forem vizinhos próximos sob a matriz dinâmica $\mathbf{D}$ (por norma, através do algoritmo dos k -vizinhos mais próximos ou de uma bola limitante de raio ϵ). O peso da aresta é o próprio valor D_{ij} . Esta etapa captura a topologia local onde o espaço pode ser aproximado por um plano linear.

2. **Cálculo Global das Geodésicas:** Para resíduos distantes, a separação não é ditada pela matriz original $\mathbf{D}$ (que poderia causar um curto-circuito não-linear), mas sim pela acumulação dos caminhos mais curtos através do grafo local G . Recorrendo a algoritmos de otimização em grafos (como Dijkstra ou Floyd-Warshall), constrói-se a matriz de distâncias geodésicas $\mathbf{D}^{(G)}$:

$$D_{ij}^{(G)} = \min_{\text{caminho } p} \left(\sum_{e \in p} \text{peso}(e) \right).$$

3. **Imersão Métrica (MDS Geodésico):** O operador do MDS Clássico (Equação 10) é, por fim, aplicado estritamente sobre a matriz geodésica não-linear $\mathbf{D}^{(G)}$, gerando o espectro de coordenadas de baixa dimensão $\mathbf{Y}$ que desdobra (*unfolds*) e preserva a topologia curva intrínseca.

O ISOMAP exhibe erros residuais substancialmente menores que o MDS porque respeieta a continuidade dos movimentos biológicos: a correlação alostérica entre domínios distantes da MBP é forçada a fluir através da malha de aminoácidos intermédios conectados.

1.6.3 Dimensionalidade Intrínseca e o Gráfico Scree (Cotovelo)

A determinação empírica da dimensão alvo d para a projeção final $\mathbf{Y} \in \mathbb{R}^d$ exige a avaliação da **dimensionalidade intrínseca** da variedade subjacente — o número mínimo de eixos latentes indispensáveis para encapsular a totalidade da informação estrutural sem introduzir ruído ou aglomeração espúria (*crowding problem*).

Para avaliar a fidelidade da redução, quantifica-se o *stress* topológico, formulado pela variância residual do mapeamento. Trata-se de uma função estritamente decrescente da dimensão d , dada por:

$$\text{Variância Residual}(d) = 1 - R^2 \left(\text{vec}(\mathbf{D}^{(G)}), \text{vec}(\mathbf{D}_{\mathbf{Y}}^{(d)}) \right),$$

onde R^2 representa o coeficiente de correlação linear (o quadrado da correlação de Pearson) calculado entre o vetor de distâncias geodésicas originais e as distâncias euclidianas estimadas no subespaço de dimensão d ($\mathbf{D}_{\mathbf{Y}}^{(d)}$).

A análise do comportamento assintótico desta métrica em função do número sucessivo de dimensões d projeta-se visualmente no designado **Gráfico Scree** (*Scree Plot*). A extração da dimensão ótima assenta no **Crítério do Cotovelo** (*Elbow Method*). Este critério geométrico identifica o hiperparâmetro de transição (o "cotovelo" da curva) onde a taxa de mitigação do erro residual sofre uma flexão abrupta e passa a assemelhar-se a um platô assintótico horizontal.

Conforme evidenciado pelas matrizes dinâmicas da MBP estudadas por Kovacev-Nikolic et al. [11] (Figura 3 do respetivo artigo), o declínio acentuado das distorções de mapeamento termina precisamente quando $d = 3$. A incorporação de autovetores sucessivos para gerar uma quarta ou quinta dimensão induz ganhos marginais

e irrisórios no coeficiente de determinação R^2 . Esta observação matemática corrobora a tese de que a imensa complexidade dinâmica estabelecida pelos 370 resíduos macromoleculares pode ser otimizadamente embutida num subespaço denso de três dimensões ($\mathbb{R}^3$). É neste prisma reduzido e fiel à mecânica da proteína que as nuvens de pontos de interações se revelam preparadas para a subsequente análise de agrupamentos de classes (*apo* versus *holo*).




Figura 2: Redução de dimensão via Isomap para a estrutura 1OMP. A flexão abrupta no parâmetro $d = 3$ (Critério do Cotovelo) indica a dimensionalidade intrínseca ideal para a representação das flutuações dinâmicas da MBP.

1.7 Definições Topológicas e a Geometria da Comunicação Dinâmica

O emprego clássico da Análise Topológica de Dados (TDA) em biologia estrutural baseia-se frequentemente nas coordenadas espaciais cartesianas (X, Y, Z) para construir o espaço métrico subjacente. Contudo, visto que a função de captura do ligante pela MBP depende intrinsecamente das flutuações térmicas ao longo do tempo, a distância euclidiana pura fornece apenas um instantâneo estático. Torna-se, portanto, estritamente necessário substituir essa geometria por um descritor dinâmico [11].

1.7.1 Fundamentos de Topologia Algébrica

Para extrair a arquitectura de comunicação da biomolécula a partir desta pseudo-métrica, traduzimos este espaço num objecto combinatório. Seja K um complexo simplicial abstracto. Para $n \geq 0$, definimos os conjuntos

$$K_n = \{\sigma \in K \mid \dim(\sigma) \leq n\}$$

$$K_{(n)} = \{\sigma \in K \mid \dim(\sigma) = n\}.$$

O primeiro conjunto é um complexo simplicial, chamado de n -esqueleto de K . O segundo não é um complexo simplicial em geral.

Definição 2 (Complexo Simplicial). *Seja V um conjunto (chamado de conjunto de vértices). Um **complexo simplicial** sobre V é um conjunto K de subconjuntos de V (chamados de **simplexos**) tal que, para todo $\sigma \in K$ e todo $\tau \subset \sigma$ não-vazio, temos $\tau \in K$.*

Definição 3 (n -Cadeias). *Seja K um complexo simplicial e $n \geq 0$. O conjunto de n -cadeias de K , denotado $C_n(K)$, é o conjunto cujos elementos são as somas formais:*

$$\sum_{\sigma \in K_{(n)}} \epsilon_\sigma \cdot \sigma, \quad \text{onde } \forall \sigma \in K_{(n)}, \epsilon_\sigma \in \mathbb{Z}/2\mathbb{Z}.$$

Este conjunto possui estrutura de espaço vetorial sobre o corpo $\mathbb{Z}/2\mathbb{Z}$, com a adição a ocorrer componente a componente.

Definição 4 (Operador de Fronteira). *Seja $n \geq 1$ e $\sigma = [x_0, \dots, x_n] \in K_{(n)}$ um simplex de dimensão n . A **fronteira** de σ é o elemento de $C_{n-1}(K)$ definido por:*

$$\partial_n \sigma = \sum_{\substack{\tau \subset \sigma \\ |\tau|=|\sigma|-1}} \tau.$$

O operador ∂_n estende-se por linearidade a uma aplicação linear $\partial_n : C_n(K) \rightarrow C_{n-1}(K)$. Para $n = 0$, define-se ∂_0 como a aplicação nula.

Definição 5 (Ciclos e Fronteiras). *Sejam K um complexo simplicial e $n \geq 0$. Definimos:*

- *Os n -ciclos: $Z_n(K) = \ker(\partial_n) \subset C_n(K)$,*
- *As n -fronteiras: $B_n(K) = \text{Im}(\partial_{n+1}) \subset C_n(K)$.*

Definição 6 (Grupo de Homologia e Números de Betti). *Seja K um complexo simplicial. O n -ésimo grupo de homologia de K é o quociente:*

$$H_n(K) = Z_n(K) / B_n(K).$$

A dimensão deste espaço vetorial é o n -ésimo número de Betti, dado por $\beta_n(K) = \dim H_n(K) = \dim Z_n(K) - \dim B_n(K)$. Geometricamente, β_0 conta o número de componentes conexas, β_1 o número de "buracos" ou ciclos unidimensionais, e β_2 o número de cavidades fechadas.

1.7.2 Filtração e Persistência no Espaço Dinâmico

Para que a topologia seja computável a partir da matriz de distâncias dinâmicas, constrói-se o complexo a partir de um parâmetro de limiar evolutivo:

Definição 7 (Complexo de Rips). *Sejam $X = \{x_1, \dots, x_N\} \subset \mathbb{R}^n$ um conjunto finito e $t \geq 0$. O **complexo de Rips** de X no instante t , denotado $\text{Rips}^t(X)$, é o complexo do grafo G^t cujo conjunto de vértices é $\{1, \dots, N\}$ e cujas arestas são os pares (i, j) tais que a distância entre eles obedece a $\|x_i - x_j\| \leq 2t$.*

No contexto deste estudo, substituímos o espaço euclidiano $\mathbb{R}^3$ pelo espaço probabilístico das interações dinâmicas da MBP. Assim, o complexo $\text{Rips}^t(X)$ instanciará um 1-simplexo (aresta) entre dois resíduos sse a distância dinâmica $D_{ij} \leq 2t$. Conforme demonstrado por Cang et al. [6], esta substituição dota os invariantes de uma ontologia puramente mecanicista:

1. **Arestas como Interação:** Se dois resíduos operam em uníssono termodinâmico para fechar a fenda, $D_{ij} \approx 0$, e uma aresta conectá-los-á nos primeiros instantes da filtração, mesmo que estejam fisicamente distantes na proteína.
2. **Laços de Homologia (β_1) como Comunicação:** Os "buracos" abstraídos sobre a matriz $\mathbf{D}$ não são espaços vazios na matéria, mas sim *circuitos elásticos fechados* e *vias alostéricas* de propagação de força [11].

Ao fazer t crescer de 0 até ao máximo, obtemos uma filtração. O rastreamento de H_n ao longo desta filtração gera um módulo de persistência.

Definição 8 (Decomponibilidade e Barcode). *Um módulo de persistência $\mathbb{U}$ é **indecomponível** se, para todo o par de módulos $\mathbb{V}$ e $\mathbb{W}$ tais que $\mathbb{U} \simeq \mathbb{V} \oplus \mathbb{W}$, um dos somandos for nulo. Um módulo $\mathbb{V}$ é **decomponível em módulos intervalares** se existe um multiconjunto $\mathcal{I}$ de intervalos de $\mathbb{R}^+$ tal que $\mathbb{V} \simeq \bigoplus_{I \in \mathcal{I}} \mathbb{B}[I]$. O multiconjunto $\mathcal{I}$, garantido pelo Teorema de Azumaya, é denominado **código de barras de persistência** (Barcode) de $\mathbb{V}$.*

Definição 9 (Diagrama de Persistência). *Seja $\text{Barcode}(\mathbb{V})$ o barcode de um módulo decomponível. Para cada intervalo no formato (a, b) no barcode, considere-se o ponto $(a, b) \in \mathbb{R}^2$. A coleção de todos estes pontos forma o multiconjunto chamado **diagrama de persistência**, denotado $\text{Diagram}(\mathbb{V})$.*

Desabstraindo estes conceitos: um ponto (a, b) no diagrama de β_1 indica que um "ciclo de comunicação elástica" nasceu no instante de correlação a e foi engolfado por novas conexões no limiar b . A diferença $b - a$ é a sua persistência vital.

1.7.3 Paisagens de Persistência e Espaços Lineares Funcionais

Códigos de barras e diagramas de persistência não formam um espaço vetorial linear, o que inviabiliza ferramentas padrão de *Machine Learning*. Para contornar esta barreira, Bubenik [4] introduziu uma transformação funcional.

Definição 10 (Paisagem de Persistência). *Dado um diagrama de persistência com intervalos $\mathcal{B} = \{(a_i, b_i)\}_{i=1}^m$, define-se para cada ponto a função auxiliar:*

$$f_{(a,b)}(t) = \max(0, \min(t - a, b - t)).$$

A **paisagem de persistência** é a sequência de funções $\lambda_k : \mathbb{R} \rightarrow \mathbb{R}$ definidas por:

$$\lambda_k(t) = k\text{-ésimo maior valor do conjunto } \{f_{(a_i, b_i)}(t)\}_{i=1}^m,$$

adotando $\lambda_k(t) = 0$ caso $k > m$.

Definição 11 (Distância p -Paisagem). *A distância topológica entre duas paisagens λ e λ' é dada pela norma:*

$$\Lambda_p(\lambda, \lambda') = \|\lambda - \lambda'\|_p = \left(\sum_{k=1}^{\infty} \int_{\mathbb{R}} |\lambda_k(t) - \lambda'_k(t)|^p dt \right)^{1/p}. \quad (11)$$

O corolário mais profundo da Paisagem de Persistência é que a função $\lambda(k, t)$ é um elemento do espaço integrável de Lebesgue $L^p(\mathbb{N} \times \mathbb{R})$. Por definição, o espaço L^p é um **Espaço de Banach** (normado e completo).

Particularmente, quando $p = 2$, a distância Λ_2 dota a topologia da estrutura de um **Espaço de Hilbert**. A existência do espaço de Hilbert assegura a formulação de um produto interno rigoroso ($\langle \lambda, \lambda' \rangle_{L^2}$), o que fundamenta a aplicabilidade do "Teorema de Representação de Riesz". É esta transição exata — da combinatória abstrata dos retículos atômicos para a continuidade em Hilbert — que viabiliza a utilização direta de *métodos de Kernel* em Máquinas de Vetores de Suporte (SVM), permitindo calcular o hiperplano ótimo que separa matematicamente os estados dinâmicos da MBP.

2 Inferência Estatística sobre Invariantes Topológicos

O artigo de Kovacev-Nikolic et al. [11] propõe detectar diferenças conformacionais entre as formas *fechada* e *aberta* da Proteína de Ligação à Maltose (MBP) usando os métodos de Análise Topológica de Dados (TDA) fundamentados na Secção anterior. O desafio estatístico central é o seguinte: dado um conjunto de apenas $n = 14$ estruturas proteicas cristalizadas (7 fechadas e 7 abertas), como concluir rigorosamente que as duas classes dinâmicas são *estatisticamente distintas*?

A estratégia metodológica adota três pilares essenciais:

1. Transformar cada estrutura proteica num número real X por meio de um funcional linear aplicado sobre a sua paisagem de persistência.
2. Justificar, via teoria de espaços de Banach, que X admite média e variância finitas — o que legitima a aplicação dos grandes teoremas da probabilidade.
3. Empregar um teste de permutação (não paramétrico) para contornar a limitação imposta pelo tamanho amostral reduzido.

As subsecções seguintes desenvolvem cada um destes pilares com o devido rigor matemático.

2.1 A Variável Aleatória Topológica X

2.1.1 Da Paisagem de Persistência ao Escalar

Para cada estrutura proteica, a filtração do complexo de Vietoris-Rips produz uma *paisagem de persistência* $\lambda(k, t)$, que é uma sequência de funções definida em $\mathbb{N} \times \mathbb{R}$. Formalmente, a paisagem é tratada como um elemento do espaço de Banach separável $L^p(\mathbb{N} \times \mathbb{R})$ munido da norma:

$$\|\lambda\|_p = \left(\sum_{k=1}^{\infty} \int_{\mathbb{R}} |\lambda(k, t)|^p dt \right)^{1/p}, \quad 1 \leq p < \infty.$$

Define-se então uma variável aleatória real X por meio do funcional linear:

$$X = f(\lambda) = \sum_{k=1}^{\infty} \int_{\mathbb{R}} \lambda(k, t) dt,$$

que corresponde à *área total* delimitada por todos os contornos da paisagem de persistência. Este funcional integra as informações topológicas de todos os graus de homologia num único escalar real, permitindo a transição do espaço de formas complexas para o domínio da estatística clássica.

2.1.2 Finitude da Média e da Variância

Para que os grandes teoremas da probabilidade sejam aplicáveis a X , é fundamental provar analiticamente que as suas propriedades estocásticas, $\mathbb{E}[|X|]$ e $\text{Var}(X)$, são limitadas.

Proposição 1 (Integrabilidade da Área Topológica). *Seja $f : L^2(\mathbb{N} \times \mathbb{R}) \rightarrow \mathbb{R}$ o funcional definido em (2.1.1) e suponha que $\mathbb{E}[\|\lambda\|_2] < \infty$. Então $\mathbb{E}[|X|] < \infty$ e $\text{Var}(X) < \infty$.*

Demonstração. O funcional f pode ser formulado como um produto interno rigoroso no espaço de Hilbert $L^2(\mathbb{N} \times \mathbb{R})$:

$$f(\lambda) = \langle g, \lambda \rangle_{L^2} = \sum_{k=1}^{\infty} \int_{\mathbb{R}} g(k, t) \lambda(k, t) dt,$$

com a função constante $g \equiv 1$. Pela *Desigualdade de Cauchy-Schwarz* (ou Hölder para $p = q = 2$):

$$|f(\lambda)| \leq \|g\|_2 \|\lambda\|_2.$$

Como a persistência das flutuações atômicas ocorre num intervalo de tempo (distância de filtração) finito e a estrutura proteica possui um número limitado de resíduos, g atua sobre um domínio de medida finita, garantindo que $\|g\|_2 < \infty$. Tomando a esperança matemática em ambos os lados:

$$\mathbb{E}[|X|] = \mathbb{E}[|f(\lambda)|] \leq \|g\|_2 \mathbb{E}[\|\lambda\|_2] < \infty.$$

Relativamente à variância, nota-se que $X^2 = f(\lambda)^2 \leq \|g\|_2^2 \|\lambda\|_2^2$, logo:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \leq \mathbb{E}[X^2] \leq \|g\|_2^2 \mathbb{E}[\|\lambda\|_2^2] < \infty. \quad \square$$

Nota. A hipótese $\mathbb{E}[\|\lambda\|_2] < \infty$ é fisicamente inquestionável: a MBP possui um tamanho geométrico finito e a distância dinâmica D_{ij} é estritamente limitada ao intervalo $[0, 1]$, impedindo o crescimento infinito dos ciclos topológicos.

2.2 Leis Limites e a Necessidade de Testes Não-Paramétricos

Estabelecida a integrabilidade de X , os dois pilares da teoria probabilística tornam-se intrinsecamente aplicáveis às amostras topológicas.

Teorema 1 (Lei dos Grandes Números — LGN). *Sejam $X_1, X_2, \dots$ variáveis aleatórias independentes e identicamente distribuídas (i.i.d.) com média $\mu = \mathbb{E}[X_1] < \infty$. Definindo a média amostral $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, temos que $\bar{X}_n \xrightarrow{q.c.} \mu$ quando $n \rightarrow \infty$.*

Teorema 2 (Teorema Central do Limite — TCL). *Sob as hipóteses do Teorema 1, e assumindo $\sigma^2 = \text{Var}(X_1) < \infty$, o limite da distribuição converge para uma Normal padrão:*

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad \text{quando } n \rightarrow \infty.$$

A independência requerida (X_i e X_j) é garantida metodologicamente, uma vez que as estruturas PDB foram cristalizadas e resolvidas experimentalmente de forma isolada [11]. No entanto, os Teoremas 1 e 2 são resultados *assintóticos*. Num escopo com apenas $n_1 = 7$ (fechadas) e $n_2 = 7$ (abertas), a invocação direta da distribuição Normal para o teste de hipótese clássico (*t-Student*) seria estatisticamente imprudente. O TCL justifica, contudo, que o espaço de paisagens é bem comportado, motivando o uso de métodos de reamostragem.

2.3 Formulação do Teste de Permutação (Valor- p)

2.3.1 Populações e a Estatística t

Define-se a média topológica populacional para as conformações fechadas como $\mu_1 = \mathbb{E}[X \mid \text{fechada}]$ e para as abertas como $\mu_2 = \mathbb{E}[X \mid \text{aberta}]$. O ensaio visa rejeitar a hipótese nula de igualdade (teste bilateral):

$$H_0 : \mu_1 = \mu_2 \quad \text{vs.} \quad H_a : \mu_1 \neq \mu_2.$$

Para quantificar a divergência, utilizam-se os estimadores amostrais não viesados $\bar{X}_1$ e $\bar{X}_2$, bem como as respectivas variâncias corrigidas S_1^2 e S_2^2 . A estatística de teste paramétrica t adimensional é formulada normalizando a diferença de médias pela variância global combinada:

$$t = \frac{|\bar{X}_1 - \bar{X}_2|}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}.$$

2.3.2 Distribuição Nula e Significado Topológico

O princípio de troca de Fischer estabelece que, se H_0 for verdadeira, os rótulos morfológicos “aberta” e “fechada” são estatisticamente insignificantes. O conjunto $\mathcal{P}$ de todas as partições possíveis de 14 proteínas em dois subgrupos de 7 fornece a cardinalidade exata do espaço de permutações:

$$|\mathcal{P}| = \binom{14}{7} = 3432.$$

Descontando a simetria rotacional dos rótulos, existem 1716 permutações únicas. Calculando a estatística t_π para cada permutação $\pi \in \mathcal{P}$, edifica-se a distribuição empírica sob H_0 . O **valor-p** é então a proporção de permutações que geram divergências maiores ou iguais à encontrada na organização biológica verdadeira (t_{obs}):

$$p = \frac{\#\{\pi \in \mathcal{P} : t_\pi \geq t_{\text{obs}}\}}{|\mathcal{P}|}.$$

Segundo a análise conduzida por Kovacev-Nikolic et al. [11], a estatística observada para os graus de homologia H_0 e H_1 atingiu o valor máximo de toda a distribuição permutada ($t_{\text{obs}} = \max(t_\pi)$). Consequentemente, o valor-p obtido foi o mínimo teórico possível:

$$p = \frac{1}{1716} \approx 5,83 \times 10^{-4}.$$

Uma vez que $p \ll \alpha = 0,05$, a hipótese nula H_0 é rejeitada com severidade. Conclui-se, com profundo rigor matemático, que as transições alostéricas e os mecanismos de dobradiça presentes na proteína de ligação à maltose geram **assinaturas topológicas fundamentalmente distintas**, comprovando a aptidão da Homologia Persistente para identificar funções termodinâmicas no espaço macromolecular.

3 A aplicação do Machine-Learning

3.1 Classificação Temática via Máquinas de Vetores de Suporte (SVM)

A projeção contínua das paisagens de persistência no Espaço de Hilbert $L^2(\mathbb{N} \times \mathbb{R})$, detalhada na Subsecção 1.7, fornece a fundamentação algébrica necessária para a aplicação de algoritmos de aprendizado supervisionado estáveis. Para discriminar de forma automatizada as assinaturas topológicas das conformações abertas e fechadas da Proteína de Ligação à Maltose (MBP), implementa-se o formalismo das Máquinas de Vetores de Suporte (*Support Vector Machines* – SVM) [8].

3.1.1 O Hiperplano Separador e a Regra de Decisão

Seja $\mathcal{X}$ o espaço vetorial funcional das características topológicas e $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ o conjunto de treino experimental, onde $\mathbf{x}_i \in \mathcal{X}$ representa a paisagem de persistência da i -ésima estrutura proteica e $y_i \in \{-1, +1\}$ denota o rótulo morfológico binário, convencionando-se $y_i = +1$ para a conformação fechada (*holo*) e $y_i = -1$ para a conformação aberta (*apo*).

Um classificador linear elementar estabelece uma fronteira de partição no espaço de fase através de um hiperplano afim $\mathcal{H}$, definido formalmente por:

$$\mathcal{H} = \{\mathbf{x} \in \mathcal{X} \mid \langle \mathbf{w}, \mathbf{x} \rangle + b = 0\}, \quad (12)$$

onde $\mathbf{w} \in \mathcal{X}$ representa el vetor normal de pesos ortogonal à superfície de decisão e $b \in \mathbb{R}$ constitui o termo de viés (*bias*). A função discriminante preditiva $g(\mathbf{x})$ para a classificação de uma nova estrutura conformacional é dada pela aplicação do operador sinal:

$$g(\mathbf{x}) = \text{sgn}(\langle \mathbf{w}, \mathbf{x} \rangle + b). \quad (13)$$

3.1.2 Maximização da Margem e o Problema Primal Rígido

O princípio de otimização das Máquinas de Vetores de Suporte consiste em selecionar, de entre o infinito conjunto de hiperplanos separadores possíveis, aquele que maximize a margem geométrica de separação entre as classes latentes [8]. Definem-se os hiperplanos de suporte paralelos e canônicos $\mathcal{H}_+$ e $\mathcal{H}_-$ que delimitam as fronteiras das regiões de exclusão de cada classe:

$$\mathcal{H}_+ : \langle \mathbf{w}, \mathbf{x} \rangle + b = +1, \quad \mathcal{H}_- : \langle \mathbf{w}, \mathbf{x} \rangle + b = -1.$$

Proposição 2 (Largura da Margem Geométrica). *A distância geométrica estrita entre os hiperplanos de suporte $\mathcal{H}_+$ e $\mathcal{H}_-$ é dada por $\frac{2}{\|\mathbf{w}\|}$.*

Demonstração. Sejam $\mathbf{x}_+ \in \mathcal{H}_+$ e $\mathbf{x}_- \in \mathcal{H}_-$ dois pontos ótimos pertencentes aos respetivos hiperplanos de suporte. O vetor diferença deslocamento $\mathbf{x}_+ - \mathbf{x}_-$ pode ser projetado ortogonalmente sobre o vetor unitário normal à superfície de decisão, definido por $\hat{\mathbf{w}} = \mathbf{w}/\|\mathbf{w}\|$:

$$\langle \mathbf{x}_+ - \mathbf{x}_-, \hat{\mathbf{w}} \rangle = \frac{\langle \mathbf{w}, \mathbf{x}_+ \rangle - \langle \mathbf{w}, \mathbf{x}_- \rangle}{\|\mathbf{w}\|} = \frac{(1 - b) - (-1 - b)}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}.$$

□

Do ponto de vista computacional, maximizar a largura da margem $\frac{2}{\|\mathbf{w}\|}$ é analiticamente equivalente a minimizar o inverso do seu quadrado, $\frac{1}{2}\|\mathbf{w}\|^2$. Para cenários idealizados de separabilidade linear estrita (*margens rígidas*), o problema de otimização primal é formulado sob a seguinte estrutura de programação quadrática convexa:

$$\begin{aligned} & \underset{\mathbf{w}, b}{\text{minimizar}} && \frac{1}{2}\|\mathbf{w}\|^2 \\ & \text{sujeito a} && y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1, \quad \forall i = 1, \dots, n. \end{aligned} \quad (14)$$

3.1.3 Formulação de Margens Suaves e Variáveis de Folga

As matrizes de conectividade biológica obtidas via ANM incorporam flutuações térmicas e ruído estocástico inerentes à mecânica quântica e clássica molecular, fazendo com que os dados reais da MBP raramente manifestem separabilidade linear exata. Para conferir robustez matemática contra sobreajuste (*overfitting*), introduz-se o formalismo de *margens suaves* por meio de variáveis de folga (*slack variables*) $\xi_i \geq 0$, que toleram violações controladas das restrições geométricas [8, 12]:

$$\begin{aligned} & \underset{\mathbf{w}, b, \xi}{\text{minimizar}} && \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ & \text{sujeito a} && y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad \forall i = 1, \dots, n. \end{aligned} \quad (15)$$

O hiperparâmetro de regularização $C > 0$ governa o compromisso (*trade-off*) mecânico entre a maximização da largura da margem (estabilização do vetor $\|\mathbf{w}\|$) e a minimização do erro de classificação sumado ($\sum \xi_i$). Um valor de C elevado penaliza severamente as infrações lineares, estreitando a margem; inversamente, um C incipiente tolera desalinhamentos locais em favor de uma generalização preditiva superior.

3.1.4 Formulação Dual e o Truque do Kernel no Espaço de Paisagens

Dado que o problema (15) atende às condições de regularidade de Slater, a dualidade forte é verificada. A sua formulação dual, deduzida através da introdução dos multiplicadores de Lagrange $\alpha_i \geq 0$ aplicados sobre as restrições KKT, assume a forma de maximização côncava:

$$\begin{aligned} & \underset{\alpha}{\text{maximizar}} && \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \\ & \text{sujeito a} && \sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C. \end{aligned} \quad (16)$$

A resolução ótima deste sistema dual determina o vetor normal através da combinação linear dos vetores de treino:

$$\mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \mathbf{x}_i. \quad (17)$$

Definição 12 (Vetores de Suporte). *Os **vetores de suporte** constituem o subconjunto crítico de estruturas do conjunto de treino cujos multiplicadores de Lagrange associados são estritamente positivos ($\alpha_i^* > 0$). Geometricamente, correspondem às proteínas cujas assinaturas topológicas se posicionam exatamente sobre os hiperplanos limítrofes $\mathcal{H}_{\pm}$ ou violam as margens estruturais. Pela Equação 17, constata-se que a fronteira de decisão $\mathbf{w}^*$ é governada exclusivamente por estes elementos; a remoção de qualquer outra proteína inerte do conjunto de dados preservará a superfície de separação inalterada.*




Figura 3: Projeção bidimensional do hiperplano ótimo de separação gerado pelo classificador SVM. A margem de decisão ($\mathcal{H}$) discrimina as conformações abertas e fechadas com base nas paisagens de persistência. As anomalias estruturais, como a 2N45 e 1DMB, localizam-se na vizinhança da fronteira, caracterizando estados de transição metaestáveis.

A característica central da formulação dual (16) é que os dados de entrada $\mathbf{x}_i$ emergem unicamente através do produto interno escalar $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$. Isto viabiliza a execução do ****truque do kernel**** (*kernel trick*): substitui-se o produto interno elementar por um operador funcional generalizado $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle_{\mathcal{H}}$, permitindo mapear implicitamente as paisagens para um espaço de Hilbert $\mathcal{H}$ de alta dimensão sem computar explicitamente a transformação não-linear ϕ .

No presente arcabouço, os vetores de entrada $\mathbf{x}_i$ residem no espaço funcional das paisagens de persistência de grau 1, elementos nativos de $L^2(\mathbb{N} \times \mathbb{R})$. Como demonstrado analiticamente por Bubenik [4], o produto interno bilinear deste espaço de Lebesgue constitui, por si só, um kernel positivo definido dotado de convergência estrita:

$$\kappa(\mathcal{B}, \mathcal{B}') = \langle \lambda, \lambda' \rangle_{L^2(\mathbb{N} \times \mathbb{R})} = \sum_{k=1}^{\infty} \int_{\mathbb{R}} \lambda_k(t) \lambda'_k(t) dt, \quad (18)$$

onde λ e λ' representam as paisagens associadas aos diagramas de persistência $\mathcal{B}$ e

$\mathcal{B}'$. O mapeamento linear aplicado às paisagens de persistência discretizadas e submetidas à redução via PCA constitui uma aproximação finita e computacionalmente estável deste operador funcional contínuo.

3.1.5 Métrica de Confiança e Interpretação Topológico-Termodinâmica

A imersão do classificador no espaço de Hilbert das interações elásticas confere à distância geométrica de uma determinada proteína $\mathbf{x}$ em relação ao hiperplano ótimo $\mathcal{H}$ uma ontologia física e molecular precisa. A distância ortogonal é quantificada por:

$$d(\mathbf{x}, \mathcal{H}) = \frac{|\langle \mathbf{w}^*, \mathbf{x} \rangle + b| \mathbf{1}_{[g(\mathbf{x})=y_i]}}{\|\mathbf{w}^*\|} = \frac{|f(\mathbf{x})|}{\|\mathbf{w}^*\|}, \quad (19)$$

onde $f(\mathbf{x})$ representa a magnitude escalar da função de decisão. Esta distância afim expande-se analiticamente sob duas interpretações biofísicas fundamentais:

- **Alta Distância Geométrica** ($d \gg 0$): A paisagem de persistência da macromolécula exibe de forma inequívoca e canônica a assinatura topológica estável da sua classe. Os ciclos unidimensionais em H_1 (canais de interações coordenadas de dobradiça) encontram-se completamente definidos. Do ponto de vista biofísico, a proteína localiza-se num poço profundo de potencial estável na paisagem de energia livre global, consideravelmente afastada da barreira de transição mecânica conformacional.
- **Baixa Distância Geométrica** ($d \approx 0$): A paisagem de persistência manifesta propriedades estruturais híbridas e ambíguas. Os seus ciclos topológicos dinâmicos encontram-se numa fase de transição de "nascimento ou morte" ao longo do limiar de filtração ϵ . No espaço conformacional, isto identifica uma proteína que se situa na vizinhança imediata da barreira energética $\Delta G_{A \rightarrow F} \approx 0$, caracterizando um **estado metaestável intermediário de transição** de acordo com o modelo de Seleção Conformacional.

Parametrizando a distância média das 14 estruturas gabarito ao hiperplano como $\bar{d} \approx 1,67$, estabelece-se como candidato a estado intermediário de transição qualquer conformação macromolecular cuja distância ortogonal satisfaça $d(\mathbf{x}, \mathcal{H}) < \delta$, onde δ constitui um limiar de tolerância topológica a ser calibrado. No presente estudo, conformações críticas como a estrutura livre 2N45 ($d = 0,19$) e a estrutura coordenada 1DMB ($d = 0,76$) enquadram-se nesta região de ambiguidade linear, sendo submetidas a uma validação geométrica ortogonal e direta no espaço cartesiano através do cômputo do RMSD de C_α .

3.2 Validação Estrutural e Comparação Geométrica: RMSD e o Algoritmo de Kabsch

A separação estatística e topológica das conformações proteicas via SVM no espaço de paisagens de persistência sugere uma distinção mecanicista profunda entre as formas aberta e fechada da MBP. Para validar fisicamente esta divergência no espaço

real $\mathbb{R}^3$, recorre-se ao "padrão-ouro" da biologia estrutural para comparação tridimensional: o Desvio Quadrático Médio (*Root-Mean-Square Deviation* – RMSD), otimizado analiticamente pelo Algoritmo de Kabsch.

3.2.1 Definição Matemática do RMSD

O RMSD quantifica a similaridade geométrica absoluta entre duas conformações de uma mesma proteína. Sejam $\mathbf{A}$ e $\mathbf{B}$ duas estruturas proteicas (por exemplo, os estados *apo* e *holo*), cada uma representada matematicamente por uma matriz $3 \times N$, cujos vetores colunas $\mathbf{a}_k, \mathbf{b}_k \in \mathbb{R}^3$ contêm as coordenadas espaciais dos $N = 370$ átomos de carbono-alfa (C_α).

A definição formal do RMSD bruto entre estas duas estruturas é a raiz quadrada da média das distâncias euclidianas ao quadrado entre os átomos homólogos:

$$\text{RMSD}(\mathbf{A}, \mathbf{B}) = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{a}_k - \mathbf{b}_k\|^2}. \quad (20)$$

Contudo, como as coordenadas cristalográficas possuem orientações e posições arbitrárias no espaço, a métrica na Equação 20 é geometricamente ingênua. O verdadeiro valor do RMSD estrutural exige a sobreposição ótima de corpo rígido, ou seja, a minimização contínua dessa distância através de uma matriz de rotação apropriada $\mathbf{R}$:

$$D(\mathbf{A}, \mathbf{B}) = \min_{\mathbf{R}} \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{R}\mathbf{a}_k - \mathbf{b}_k\|^2}, \quad (21)$$

onde $\mathbf{a}_k$ e $\mathbf{b}_k$ assumem-se como vetores já centralizados na origem.

3.2.2 O Problema da Sobreposição Ótima (Algoritmo de Kabsch)

A extração da matriz de rotação ótima $\mathbf{R}$ que minimiza a Equação 21 é resolvida de forma exata e determinística pelo Algoritmo de Kabsch. Este método opera em três passos analíticos fundamentais:

1. Translação dos Centroides para a Origem: Primeiramente, elimina-se o vetor de translação espacial. Calculam-se os centroides (vetores médios) $\bar{\mathbf{a}}$ e $\bar{\mathbf{b}}$ geométricos de cada proteína:

$$\bar{\mathbf{a}} = \frac{1}{N} \sum_{k=1}^N \mathbf{a}_k^{\text{orig}}, \quad \bar{\mathbf{b}} = \frac{1}{N} \sum_{k=1}^N \mathbf{b}_k^{\text{orig}}.$$

De seguida, transladam-se rigidamente todos os átomos para que os centroides coincidam na origem $(0, 0, 0)$ do sistema de coordenadas:

$$\mathbf{a}_k = \mathbf{a}_k^{\text{orig}} - \bar{\mathbf{a}}, \quad \mathbf{b}_k = \mathbf{b}_k^{\text{orig}} - \bar{\mathbf{b}}.$$

2. Construção da Matriz de Covariância Cruzada: Expandindo algebricamente o argumento da distância ao quadrado a ser minimizado, obtemos:

$$D^2(\mathbf{A}, \mathbf{B}) = \frac{1}{N} \sum_{k=1}^N (\mathbf{a}_k^T \mathbf{a}_k + \mathbf{b}_k^T \mathbf{b}_k - 2\mathbf{b}_k^T \mathbf{R} \mathbf{a}_k).$$

Uma vez que os termos $\mathbf{a}_k^T \mathbf{a}_k$ e $\mathbf{b}_k^T \mathbf{b}_k$ definem os raios de giração das proteínas (que são propriedades intrínsecas e invariantes sob rotação), o problema de minimização do RMSD torna-se estritamente equivalente à *maximização do termo cruzado*. Para tal, define-se a matriz de covariância cruzada espacial $\mathbf{U} \in \mathbb{R}^{3 \times 3}$:

$$\mathbf{U} = \sum_{k=1}^N \mathbf{b}_k \mathbf{a}_k^T. \quad (22)$$

O nosso objetivo de otimização resume-se agora a encontrar a matriz de rotação $\mathbf{R}$ que maximize o traço do produto matricial: $\max \text{tr}(\mathbf{R}^T \mathbf{U})$.

3. Decomposição em Valores Singulares (SVD) e a Rotação Ótima: Aplica-se a Decomposição em Valores Singulares à matriz de covariância cruzada $\mathbf{U}$:

$$\mathbf{U} = \mathbf{V} \mathbf{\Sigma} \mathbf{W}^T, \quad (23)$$

onde $\mathbf{V}$ e $\mathbf{W}$ são matrizes ortogonais 3×3 , e $\mathbf{\Sigma}$ é a matriz diagonal dos valores singulares ordenados ($\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq 0$).

Para otimizar o alinhamento, a matriz teórica que resolve o problema linear é $\mathbf{R} = \mathbf{V} \mathbf{W}^T$. No entanto, o problema físico de proteínas impõe uma restrição de quiralidade rigorosa. Se o determinante da matriz de covariância for negativo ($\det(\mathbf{U}) < 0$), a solução algébrica pura resultaria numa matriz $\mathbf{R}$ com determinante -1 . Biologicamente, isto corresponderia a uma *reflexão* (inversão no espelho) da proteína, gerando um RMSD falsamente minimizado, porém fisicamente impossível no mundo real.

Para corrigir esta falha tridimensional, introduz-se a matriz de correção quiral $\mathbf{S} = \text{diag}(1, 1, d)$, onde $d = \text{sgn}(\det(\mathbf{V} \mathbf{W}^T)) = \pm 1$. A matriz de rotação ótima irretocável que garante o encaixe perfeito sem inversão de quiralidade é deduzida como:

$$\mathbf{R}^* = \mathbf{V} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & d \end{bmatrix} \mathbf{W}^T. \quad (24)$$

Sob esta rotação geométrica ótima, a forma quadrática final minimizada do RMSD consolida-se em:

$$D^2(\mathbf{A}, \mathbf{B}) = \frac{1}{N} \left(\sum_{k=1}^N \|\mathbf{a}_k\|^2 + \sum_{k=1}^N \|\mathbf{b}_k\|^2 - 2(\lambda_1 + \lambda_2 + d\lambda_3) \right). \quad (25)$$

3.2.3 Interpretação Biofísica da Distância

O escalar obtido através da Equação 25 traduz mecanicamente a disparidade das proteínas. Valores muito reduzidos (ex: $\text{RMSD} \approx 0.5$ a $2.0 \text{ \AA}$) indicam que ambas as

cadeias polipeptídicas partilham o exato padrão de dobramento global (*general folding pattern*). Estas ligeiras discrepâncias são mero reflexo do ruído termodinâmico natural da molécula a vibrar em torno da mesma bacia de energia mínima.

A determinação empírica de estados conformacionais distintos (Aberto vs. Fechado) através de RMSD não deve apoiar-se em cortes (*cut-offs*) arbitrários. De acordo com a literatura seminal de validação estrutural, a confirmação de que duas proteínas habitam estados termodinâmicos mecanicamente divergentes pressupõe que o seu RMSD ultrapasse uma curva de limite dependente do número N de resíduos, frequentemente referida como D_0 .

Quando o RMSD estrutural transpassa o limiar significativo de deformação basal, obtém-se a prova empírica inquestionável de que os segmentos interdominiais sofreram rearranjos não-triviais. Na perspetiva da MBP, ultrapassar este limiar (frequentemente registado em valores ≥ 3.5 Å para domínios dobradiça completos) atesta geometricamente que o mecanismo alostérico deduzido pela Homologia Persistente H_1 operou fisicamente no espaço cartesiano, transmutando a topologia esparsa da forma livre na conformação densamente empacotada que engolfa o açúcar.

4 Resultados e Discussão

A metodologia híbrida desenvolvida neste estudo, que amalgama Análise Topológica de Dados (TDA), Máquinas de Vetores de Suporte (SVM) e validação geométrica pelo Algoritmo de Kabsch, foi aplicada à Proteína de Ligação à Maltose (MBP). Os resultados obtidos validam a premissa de que a classificação termodinâmica das conformações proteicas transcende a mera presença ou ausência do ligante químico (*apo* versus *holo*).

4.1 Pipeline Topológico e Aprendizado de Máquina

A matriz de distâncias dinâmicas $\mathbf{D}$ foi computada para o conjunto de referência composto por 14 estruturas da MBP (7 abertas e 7 fechadas). A posterior filtração do complexo de Vietoris-Rips gerou as paisagens de persistência focadas no grupo de homologia H_1 , refletindo os canais de comunicação mecânica (alosteria) da macromolécula. Cada paisagem foi discretizada num vetor de alta dimensionalidade em $\mathbb{R}^{3650}$ (73 camadas $\times$ 50 pontos de resolução).

Para mitigar a maldição da dimensionalidade e permitir a aplicação do classificador, o espaço topológico foi submetido à Análise de Componentes Principais (PCA). Retiveram-se os três primeiros componentes principais ($d = 3$), os quais capturaram **52,79% da variância total** do sistema (CP1: 29,78%; CP2: 14,94%; CP3: 8,06%). Este valor está em estrita concordância com a variância reportada pela literatura original de Kovacev-Nikolic et al. [11] ($\sim 52,50\%$ para grau 1), atestando a fidelidade da extração.

Submetido à validação cruzada *Leave-One-Out* (LOO), o modelo SVM com *kernel* linear operando neste subespaço alcançou uma **acurácia de 100%** na discriminação das 14 proteínas molde. O hiperplano separador ótimo $\mathcal{H}$ foi assim perfeitamente

estabelecido, provando que a forma aberta e fechada são classes topologicamente linearmente separáveis no espaço de Hilbert L^2 .

4.2 Projeção de Novas Estruturas e Distância ao Hiperplano

Com o hiperplano afim de separação fixado ($\langle \mathbf{w}^*, \mathbf{x} \rangle + b = 0$), o modelo foi utilizado para prever a conformação de um conjunto expandido de 29 estruturas cristalográficas independentes (misturando estados *apo* e *holo*).

Para cada nova proteína, computou-se a sua distância geométrica ao hiperplano de decisão, $d(\mathbf{x}, \mathcal{H}) = |f(\mathbf{x})|/\|\mathbf{w}^*\|$. O valor médio obtido para as estruturas com classificação segura foi de $\bar{d} \approx 1,67$. A análise rigorosa destas distâncias revelou duas anomalias biológicas de extrema importância para o modelo de Seleção Conformacional:

1. **A anomalia 1DMB (Holo, prevista como Aberta):** A proteína 1DMB contém o ligante maltose acoplado (estado *holo*), o que convencionalmente a ditaria como fechada no modelo de "Encaixe Induzido". Contudo, o SVM classificou-a inequivocamente como **Aberta**. A sua distância ao hiperplano ($d = 0,7676$) indica uma estrutura moderadamente atípica, evidenciando que a presença mecânica do ligante não foi suficiente para colapsar os domínios para a forma fechada.
2. **A anomalia 2N45 (Apo, prevista como Fechada):** A proteína 2N45 está livre de ligante (estado *apo*), mas o SVM previu-a como **Fechada**. Notavelmente, a sua distância geométrica é incrivelmente baixa ($d = 0,1985$), colocando-a diretamente na margem do hiperplano de decisão (≈ 0). Matematicamente, a 2N45 representa o estado metaestável de transição: uma proteína vazia cujas molas elásticas estão já a transitar espontaneamente para a conformação fechada de captura.

4.3 Validação Estrutural Ortogonal via Algoritmo de Kabsch (RMSD)

Para confirmar se as previsões operadas no espaço funcional L^2 correspondem à realidade cartesiana tridimensional, executou-se a sobreposição rígida ótima dos carbonos-alfa utilizando o Algoritmo de Kabsch. O RMSD das 29 proteínas foi computado em relação aos referenciais estritos fechado (1ANF) e aberto (10MP). A classificação geométrica do RMSD atestou qual distância era minimizada para cada macromolécula.

Os resultados demonstraram uma **concordância massiva de 89,6% (26 de 29 casos)** entre o modelo geométrico clássico tridimensional e a inteligência artificial topológica abstrata. Destaca-se a proteína 1DMB, cuja anomalia foi confirmada por ambos os métodos: quer por topologia (SVM), quer por métrica estrita (RMSD em relação à Aberta = 0,46 Å; em relação à Fechada = 3,47 Å), ela é uma proteína conformacionalmente Aberta, apesar da sua química *Holo*. Este é o indício definitivo empírico que sustenta o título do presente trabalho.

4.3.1 Análise das Divergências Topológico-Geométricas

As 3 proteínas que divergiram merecem escrutínio biofísico. Quando a Topologia diverge da Geometria (RMSD), revela-se a principal vantagem da Análise Topológica de Dados: a capacidade de "enxergar" a mecânica em vez de apenas a forma.

Tabela 2: Análise das divergências entre o classificador dinâmico (SVM) e o alinhamento estático (RMSD).

PDB	Química	SVM (TDA)	RMSD Mínimo	RMSD vs Aberta	RMSD vs Fechada
2N45	<i>Apo</i>	Fechada	Aberta	2,32 Å	3,51 Å
2MV0	<i>Apo</i>	Aberta	Fechada	4,21 Å	3,92 Å
7Z7H	<i>Apo</i>	Aberta	Fechada	26,84 Å	26,27 Å

- **A transição da 2N45:** O RMSD clássico enquadra-a matematicamente como Aberta ($2,32 < 3,51$). No entanto, a TDA classificou-a como Fechada. Como visto na Subsecção 4.2, ela reside em cima do hiperplano topológico ($d = 0,19$). A TDA capturou a "tensão da rede elástica" dos canais de comunicação da dobradiça que o raio-x estático não consegue mensurar plenamente. A proteína 2N45 está a fechar-se espontaneamente através de Seleção Conformacional, exibindo homologia funcional fechada antes de atingir o encaixe estrutural mínimo.
- **O limite do RMSD rígido (7Z7H):** A estrutura 7Z7H acusa um RMSD absurdo de ~ 26 Å, um valor impraticável para sobreposição de corpo rígido. Tais desvios gigantescos mascaram completamente a função proteica aos olhos da geometria cartesiana do Algoritmo de Kabsch. O SVM, por basear-se na métrica intrínseca das flutuações relativas (D_{ij}), revelou-se imune à distorção espacial cartesiana e classificou a proteína adequadamente segundo os seus ciclos de comunicação H_1 , ilustrando a robustez e superioridade da Topologia Algébrica na presença de perturbações massivas nas coordenadas.

Em suma, a experimentação analítica confirma o poder da matriz Hessiana aliada à Homologia Persistente. O "laço de vida mais longa" na dimensão 1 não representa apenas um espaço vazio; é a assinatura da via alostérica ativa da MBP. Comprovou-se empiricamente que o fechamento proteico é governado pelo equilíbrio dinâmico e pela seleção de paisagens termodinâmicas, rejeitando axiomas rígidos em que os estados conformacionais funcionam como meros recetáculos binários.

Referências

- [1] A. R. Atilgan et al. “Anisotropy of Fluctuation Dynamics of Proteins with an Elastic Network Model”. Em: *Biophysical Journal* 80.1 (2001), pp. 505–515.
- [2] Frances C. Bernstein et al. “The Protein Data Bank: A Computer-based Archival File For Macromolecular Structures”. Em: *Journal of Molecular Biology* 112.3 (1977), pp. 535–542.
- [3] W. Boos e H. Shuman. “Maltose/Maltodextrin System of Escherichia coli: Transport, Metabolism, and Regulation”. Em: *Microbiology and Molecular Biology Reviews* 62.1 (1998), pp. 204–229.
- [4] Peter Bubenik. “Statistical topological data analysis using persistence landscapes”. Em: *Journal of Machine Learning Research* 16.1 (2015), pp. 77–102.
- [5] D. Bucher, Barry J. Grant e J. Andrew McCammon. “Induced Fit or Conformational Selection? The Role of the Semi-closed State in the Maltose Binding Protein”. Em: *Biochemistry* 50 (2011), pp. 10530–10539.
- [6] Zixuan Cang, Lin Mu e Guo-Wei Wei. “Representability of algebraic topology for biomolecules in machine learning based scoring and virtual screening”. Em: *PLoS computational biology* 14.1 (2018). Preprint originalmente submetido em 2015 (arXiv:1510.00953), e1005929.
- [7] Zixuan Cang et al. *A topological approach for protein classification*. Preprint submetido em Outubro de 2015. Out. de 2015.
- [8] Corinna Cortes e Vladimir Vapnik. “Support-Vector Networks”. Em: *Machine Learning* 20.3 (1995), pp. 273–297. DOI: [10.1007/BF00994018](https://doi.org/10.1007/BF00994018).
- [9] Jay L. Devore. *Probabilidade e Estatística para Engenharia e Ciências*. 8ª ed. São Paulo, Brasil: Cengage Learning, 2012.
- [10] S. Hudault, J. Guignot e A. L. Servin. “Escherichia coli strains colonising the gastrointestinal tract protect germfree mice against Salmonella typhimurium infection”. Em: *Gut* 49.1 (2001), pp. 47–55.
- [11] Violeta Kovacev-Nikolic et al. “Using persistent homology and dynamical distances to analyze protein binding”. Em: *Statistical Applications in Genetics and Molecular Biology* 15.1 (2016), pp. 19–38.
- [12] Ana Carolina Lorena e André C. P. L. F. de Carvalho. “Uma Introdução às Support Vector Machines”. Em: *RITA (Revista de Informática Teórica e Aplicada)* 14.2 (2007), pp. 43–67.
- [13] D. Seeliger e B. L. de Groot. “Conformational Transitions upon Ligand Binding: Holo-Structure Prediction from Apo Conformations”. Em: *PLoS Computational Biology* 6.1 (2010), e1000634.
- [14] John C. Spurlino, Guang-Ying Lu e Florante A. Quioco. “The 2.3-Å Resolution Structure of the Maltose- or Maltodextrin-binding Protein, A Primary Receptor of Bacterial Active Transport and Chemotaxis”. Em: *THE JOURNAL OF BIOLOGICAL CHEMISTRY* 266.8 (1991).
- [15] Joshua B. Tenenbaum, Vin de Silva e John C. Langford. “A Global Geometric Framework for Nonlinear Dimensionality Reduction”. Em: *Science* 290.5500 (2000), pp. 2319–2323. DOI: [10.1126/science.290.5500.2319](https://doi.org/10.1126/science.290.5500.2319).

- [16] R. Van Houdt e C. W. Michiels. “Role of bacterial cell surface structures in *Escherichia coli* biofilm formation”. Em: *Research in Microbiology* 156.5-6 (2005), pp. 626–633.