



UNIVERSIDADE FEDERAL DE SERGIPE
CENTRO DE CIÊNCIAS E TECNOLOGIA
DEPARTAMENTO DE MATEMÁTICA
CURSO BACHARELADO EM MATEMÁTICA
APLICADA E COMPUTACIONAL



Análise Topológica de Dados Aplicada a dados de Biologia

Autor: Anthony dos Anjos Marques

São Cristóvão - SE

Julho, 2026



UNIVERSIDADE FEDERAL DE SERGIPE
CENTRO DE CIÊNCIAS E TECNOLOGIA
DEPARTAMENTO DE MATEMÁTICA
CURSO BACHARELADO EM MATEMÁTICA
APLICADA E COMPUTACIONAL



Análise Topológica de Dados Aplicada a dados de Biologia

Autor: Anthony dos Anjos Marques

Orientador: Prof. Dr. Danilo Dias da Silva

Trabalho de Conclusão de Curso apresentado como requisito parcial de avaliação, da disciplina Monografia II, orientado pelo Prof. Dr. Danilo Dias da Silva, no Curso de Bacharelado em Matemática Aplicada e Computacional, da Universidade Federal de Sergipe - UFS, no segundo semestre letivo de 2026.

São Cristóvão - SE

Julho, 2026

Análise Topológica de Dados Aplicada a dados de Biologia

Trabalho de Conclusão de Curso apresentado pelo aluno Anthony dos Anjos Marques ao curso de Bacharelado em Matemática Aplicada e Computacional/DMA/UFS em 24/07/2026, como requisito de avaliação final do Trabalho de Conclusão de Curso, sob a avaliação da Banca Examinadora constituída pelos seguintes professores:

Nome completo com titulação (orientador/a)

Nome completo com titulação (examinador/a convidado/a interno/a)

Nome completo com titulação (examinador/a convidado/a externo/a)

Nome completo com titulação (examinador/a suplente)

Sumário

1	Introdução	1
2	Contexto Biológico e Extração da Dinâmica Estrutural	2
2.1	A Proteína de Ligação à Maltose (MBP)	2
2.2	O Modelo de Rede Anisotrópica (ANM)	3
2.3	Construção do Espaço Métrico	3
3	Fundamentos de Topologia Algébrica e Homologia Persistente	4
3.1	Complexos Simpliciais e Grupos de Homologia	4
3.2	Inferência Topológica	5
3.3	Módulos de Persistência	6
4	Inferência Estatística sobre Invariantes Topológicos	7
4.1	A Variável Aleatória Topológica	7
4.2	Formulação das Hipóteses	7
4.3	O Teste de Permutação Não-Paramétrico	8
	Referências	10

1 Introdução

A biologia estrutural tem passado por uma revolução quantitativa nas últimas décadas, impulsionada pela necessidade de compreender não apenas a estrutura estática das macromoléculas, mas também a sua dinâmica e flexibilidade funcional. Proteínas não são entidades rígidas; elas operam como nanomáquinas complexas que transitam entre diferentes estados conformacionais para exercerem suas funções biológicas, como a catálise enzimática e o transporte de ligantes. A distinção entre as teorias clássicas de interação proteína-ligante — do modelo rígido de chave-fechadura aos modelos modernos de encaixe induzido (*induced fit*) e seleção conformacional (*conformational selection*) — evidencia a necessidade de ferramentas matemáticas capazes de capturar a essência da dinâmica molecular.

Neste contexto, a Proteína de Ligação à Maltose (MBP — *Maltose-Binding Protein*), encontrada na bactéria *Escherichia coli*, apresenta-se como um modelo de estudo ideal. A MBP atua no transporte de maltodextrinas e transita fundamentalmente entre duas conformações: o estado *Apo* (aberto e livre de ligante) e o estado *Holo* (fechado e associado ao ligante). A compreensão e a distinção exata desses estados desafiam as métricas geométricas tradicionais, como o Desvio Quadrático Médio (RMSD), que frequentemente falham em capturar correlações não-lineares sutis ou variações dinâmicas globais na estrutura da proteína.

Para contornar as limitações da análise puramente geométrica, modelos baseados na física estatística e em simulações de grão grosso (*coarse-grained*), como o Modelo de Rede Anisotrópica (ANM — *Anisotropic Network Model*), tornaram-se cruciais. Ao modelar a proteína como um sistema de massas e molas, o ANM permite a construção de uma Matriz Hessiana que, após decomposição espectral e foco nos modos normais de baixa frequência, gera uma Matriz de Correlação Cruzada. Essa matriz quantifica como as flutuações de diferentes resíduos de aminoácidos estão acopladas dinamicamente, fornecendo uma “assinatura física” do comportamento global da macromolécula.

O ponto central deste trabalho reside na transição do domínio da biofísica para o da matemática pura e aplicada, especificamente através da Análise Topológica de Dados (TDA — *Topological Data Analysis*). A partir da matriz de correlação cruzada, define-se uma pseudométrica que transforma a dinâmica da proteína em um espaço métrico. Utilizando o ferramental da Homologia Persistente, filtrações de complexos simpliciais (como o Complexo de Vietoris-Rips) são construídas para acompanhar a evolução das características topológicas — componentes conexas e ciclos unidimensionais — ao longo de diferentes escalas de distância.

Diferente das abordagens clássicas, a topologia se preocupa com a forma e a conectividade intrínseca dos dados, sendo invariante a deformações contínuas. Extraímos essas assinaturas topológicas por meio de Paisagens de Persistência (*Persistence Landscapes*), que mapeiam os dados topológicos, originalmente discretos e de difícil manipulação algébrica, em um espaço de funções de Banach. Esta transformação garante a estabilidade dos dados e permite a integração direta com métodos de estatística clássica e algoritmos de *Machine Learning*.

Por fim, com as representações topológicas traduzidas para o escopo numérico,

aplica-se o Teste de Permutação para validação estatística da separabilidade das conformações, além do treinamento de um classificador supervisionado baseado em Máquinas de Vetores de Suporte (SVM — *Support Vector Machines*).

Portanto, o objetivo fundamental deste trabalho é investigar, fundamentar e aplicar a Análise Topológica de Dados e a Homologia Persistente na extração de características dinâmicas de estruturas biomoleculares, utilizando a MBP como caso prático. Busca-se demonstrar que a união entre a teoria de grafos físicos (ANM) e os invariantes topológicos fornece um arcabouço rigoroso e superior para a classificação de estados proteicos.

2 Contexto Biológico e Extração da Dinâmica Estrutural

Para que as ferramentas da Análise Topológica de Dados (TDA) possam ser aplicadas com rigor, é necessário primeiramente traduzir o comportamento físico do objeto de estudo em um espaço métrico bem definido. Nesta seção, apresentamos o sistema biológico sob análise — a Proteína de Ligação à Maltose (MBP) — e descrevemos como o Modelo de Rede Anisotrópica (ANM) é utilizado para mapear suas flutuações dinâmicas, culminando na construção de uma matriz de distâncias que servirá como substrato para as filtrações topológicas subsequentes.

2.1 A Proteína de Ligação à Maltose (MBP)

A *Maltose-Binding Protein* (MBP) é uma macromolécula essencial no sistema de captação e transporte de maltodextrinas na bactéria *Escherichia coli*. Estruturalmente, a MBP é dividida em dois domínios globulares principais interconectados por uma região de dobradiça flexível (*hinge*).

A relevância da MBP para este estudo reside na sua mecânica funcional: ela atua transitando predominantemente entre dois estados conformacionais. Na ausência de um ligante, a proteína adota uma conformação *Apo* (aberta). Quando há a presença e ligação do açúcar (como a maltose), ela transita para a conformação *Holo* (fechada), aprisionando o substrato. Historicamente, a transição entre esses estados gerou debates entre modelos clássicos, como o Encaixe Induzido (*Induced Fit*), onde o ligante força o fechamento, e a Seleção Conformacional (*Conformational Selection*), onde a proteína já oscila naturalmente para a forma fechada e o ligante apenas estabiliza essa forma.

Independentemente do modelo biológico exato, o desafio matemático é claro: diferenciar essas duas classes (Aberta e Fechada) com base em suas propriedades estruturais e dinâmicas, superando métricas de alinhamento puramente rígidas e geométricas que não capturam as complexas correlações espaciais das macromoléculas em movimento.

2.2 O Modelo de Rede Anisotrópica (ANM)

Para capturar a dinâmica intrínseca da MBP sem o custo computacional proibitivo das simulações completas de Dinâmica Molecular, adota-se uma abordagem de grão grosso (*coarse-grained*) baseada em física estatística: o Modelo de Rede Anisotrópica (ANM).

No ANM, a estrutura tridimensional da proteína é abstraída como um grafo espacial. Cada resíduo de aminoácido é representado unicamente por seu átomo de Carbono-alfa (C_α), que atua como um nó neste grafo. Interações interatômicas são modeladas como um sistema de molas elásticas que conectam nós localizados dentro de um raio de corte predefinido.

O comportamento deste sistema de massas e molas é governado por uma aproximação harmônica do potencial elástico da rede. A topologia física dessa rede é codificada na matriz de segundas derivadas do potencial, conhecida como Matriz Hessiana (H).

Nota. *A dedução analítica detalhada da energia potencial, a formulação tridimensional da Matriz Hessiana H e sua decomposição espectral (cálculo dos autovalores e autovetores associados aos modos normais de vibração) envolvem um forte arcabouço de física mecânica e estatística que foge ao escopo puramente topológico do texto principal. Portanto, toda a fundamentação física e algébrica do ANM encontra-se detalhada no **Apêndice A**.*

Do ponto de vista matemático para a classificação estrutural, o resultado fundamental do modelo ANM repousa na inversa pseudogeneralizada da Matriz Hessiana. A partir dos modos de baixa frequência (geralmente os 20 primeiros modos não triviais, que ditam os movimentos globais da proteína), constrói-se a **Matriz de Correlação Cruzada** (C).

Cada elemento C_{ij} desta matriz quantifica a correlação entre as flutuações vectoriais do resíduo i e do resíduo j . Valores de C_{ij} próximos a 1 indicam movimentos altamente correlacionados (na mesma direção), próximos a -1 indicam movimentos anticorrelações (direções opostas), e valores próximos a 0 indicam ausência de correlação dinâmica.

2.3 Construção do Espaço Métrico

A Análise Topológica de Dados opera sobre espaços de pontos equipados com uma noção formal de distância. A Matriz de Correlação Cruzada C é rica em informação dinâmica, mas não satisfaz os axiomas de uma métrica geométrica. Para viabilizar a análise topológica, aplica-se uma transformação que mapeia correlações em distâncias.

Definimos a distância dinâmica D_{ij} entre os resíduos i e j através da relação:

$$D_{ij} = 1 - |C_{ij}| \quad (1)$$

Com esta formulação, resíduos que possuem comportamentos dinâmicos altamente acoplados ($|C_{ij}| \rightarrow 1$) apresentarão uma distância dinâmica próxima a zero

($D_{ij} \rightarrow 0$), indicando que, topologicamente e funcionalmente, eles estão “próximos”. Inversamente, resíduos com dinâmicas independentes estarão distantes neste novo espaço métrico.

A matriz de distâncias dinâmicas D constitui o ponto de partida matemático deste trabalho. Ela nos permite abandonar as coordenadas euclidianas estáticas (x, y, z) da biologia clássica e passar a tratar a proteína como um espaço métrico discreto, sobre o qual definiremos complexos simpliciais e calcularemos grupos de homologia persistente nos próximos capítulos. É crucial notar que $\mathbf{D}$ não é estritamente uma métrica, mas sim uma pseudométrica. Isto ocorre porque a identidade dos indiscerníveis não se verifica rigorosamente: dois resíduos distintos ($i \neq j$) podem oscilar de forma perfeitamente correlacionada ($|C_{ij}| = 1$), resultando numa distância $D_{ij} = 0$. A Topologia Algébrica, contudo, é perfeitamente bem definida sobre espaços pseudométricos, permitindo a construção de complexos simpliciais sem perda de generalidade teórica.

3 Fundamentos de Topologia Algébrica e Homologia Persistente

O estabelecimento de uma matriz de distâncias (ou pseudodistâncias) a partir de um sistema dinâmico fornece um espaço métrico discreto. Para extrair a arquitetura de comunicação global da biomolécula a partir desta pseudométrica, traduzimos este espaço num objeto combinatório contínuo. Nesta seção, fundamentamos o arcabouço matemático necessário para essa transição, introduzindo conceitos da Topologia Algébrica e da Homologia Persistente, usando como base o conteúdo de Tinarrage [16].

3.1 Complexos Simpliciais e Grupos de Homologia

O bloco construtor fundamental na Análise Topológica de Dados é o complexo simplicial, uma generalização de grafos para dimensões superiores que permite a representação de espaços topológicos de forma combinatorial.

Seja K um complexo simplicial abstrato. Para $n \geq 0$, definimos os conjuntos:

$$K_n = \{\sigma \in K \mid \dim(\sigma) \leq n\}$$

$$K_{(n)} = \{\sigma \in K \mid \dim(\sigma) = n\}.$$

O primeiro conjunto é um complexo simplicial, chamado de n -esqueleto de K . O segundo não é um complexo simplicial em geral.

Definição 3.1 (Complexo Simplicial). *Seja V um conjunto (chamado de conjunto de vértices). Um **complexo simplicial** sobre V é um conjunto K de subconjuntos de V (chamados de **simplexos**) tal que, para todo $\sigma \in K$ e todo $\tau \subset \sigma$ não-vazio, temos $\tau \in K$.*

Para extrair invariantes topológicos de um complexo simplicial, é necessário

dotá-lo de uma estrutura algébrica que nos permita operar formalmente sobre os seus símplexos.

Definição 3.2 (n-Cadeias). *Seja K um complexo simplicial e $n \geq 0$. O conjunto de **n-cadeias** de K , denotado $C_n(K)$, é o conjunto cujos elementos são as somas formais:*

$$\sum_{\sigma \in K_{(n)}} \epsilon_\sigma \cdot \sigma, \quad \text{onde } \forall \sigma \in K_{(n)}, \epsilon_\sigma \in \mathbb{Z}/2\mathbb{Z}.$$

Este conjunto possui estrutura de espaço vetorial sobre o corpo $\mathbb{Z}/2\mathbb{Z}$, com a adição a ocorrer componente a componente.

Definição 3.3 (Operador de Fronteira). *Seja $n \geq 1$ e $\sigma = [x_0, \dots, x_n] \in K_{(n)}$ um símplexo de dimensão n . A **fronteira** de σ é o elemento de $C_{n-1}(K)$ definido por:*

$$\partial_n \sigma = \sum_{\substack{\tau \subset \sigma \\ |\tau|=|\sigma|-1}} \tau.$$

O operador ∂_n estende-se por linearidade a uma aplicação linear $\partial_n : C_n(K) \rightarrow C_{n-1}(K)$. Para $n = 0$, define-se ∂_0 como a aplicação nula.

A aplicação linear de fronteira ∂_n satisfaz a propriedade fundamental da topologia algébrica: $\partial_{n-1} \circ \partial_n = 0$. Esta identidade categórica permite-nos definir subespaços cruciais para o estudo das formas.

Definição 3.4 (Ciclos e Fronteiras). *Sejam K um complexo simplicial e $n \geq 0$. Definimos:*

- *Os **n-ciclos**: $Z_n(K) = \ker(\partial_n) \subset C_n(K)$,*
- *As **n-fronteiras**: $B_n(K) = \text{Im}(\partial_{n+1}) \subset C_n(K)$.*

Definição 3.5 (Grupo de Homologia e Números de Betti). *Seja K um complexo simplicial. O **n-ésimo grupo de homologia** de K é o quociente:*

$$H_n(K) = Z_n(K) / B_n(K).$$

*A dimensão deste espaço vetorial é o **n-ésimo número de Betti**, dado por $\beta_n(K) = \dim H_n(K) = \dim Z_n(K) - \dim B_n(K)$. Geometricamente, β_0 conta o número de componentes conexas, β_1 o número de "buracos" ou ciclos unidimensionais, e β_2 o número de cavidades fechadas.*

3.2 Inferência Topológica

Na prática computacional, os dados raramente se apresentam nativamente como um complexo simplicial. Em vez disso, dispomos de nuvens de pontos em um espaço métrico. Para conectar a geometria dos dados com a topologia, utilizamos coberturas abertas e o Teorema do Nervo.

Definição 3.6. *Seja X um espaço topológico e $\mathcal{U} = \{U_i\}_{1 \leq i \leq N}$ uma cobertura de X . O **nervo** de $\mathcal{U}$ é o complexo simplicial com conjunto de vértices $\{1, \dots, N\}$ cujos m -símplices são os subconjuntos $\{i_1, \dots, i_m\} \subset \{1, \dots, N\}$ tais que $\bigcap_{k=1}^m U_{i_k} \neq \emptyset$. É denotado $\mathcal{N}(\mathcal{U})$.*

Definição 3.7 (Complexo de Čech). *Sejam $X \subset \mathbb{R}^n$ finito e $t \geq 0$. Considere a coleção $\mathcal{V}^t = \{\bar{\mathcal{B}}(x, t) \mid x \in X\}$. O nervo desta coleção é denotado $\check{\text{Cech}}^t(X)$ e é chamado de **complexo de Čech** de X no instante t .*

Explicitamente, $\check{\text{Cech}}^t(X)$ é o complexo simplicial sobre os vértices X cujos simplices são os subconjuntos $\{x_{i_1}, \dots, x_{i_m}\}$ tais que $\bigcap_{k=1}^m \bar{\mathcal{B}}(x_{i_k}, t) \neq \emptyset$.

Embora o complexo de Čech capture perfeitamente a topologia da união das bolas de raio t , a verificação de interseções múltiplas é computacionalmente custosa. Como alternativa tratável, foca-se nas interações aos pares.

Definição 3.8 (Complexo de Rips). *Sejam $X = \{x_1, \dots, x_N\} \subset \mathbb{R}^n$ um conjunto finito e $t \geq 0$. O **complexo de Rips** de X no instante t , denotado $\text{Rips}^t(X)$, é o complexo do grafo $G^t = (\check{\text{Cech}}^t(X))$ cujo conjunto de vértices é $\{1, \dots, N\}$ e cujas arestas são os pares (i, j) tais que a distância entre eles obedece a $\|x_i - x_j\| \leq 2t$.*

3.3 Módulos de Persistência

A fixação de um limiar único t para a construção dos complexos impõe um viés metodológico forte, pois não há uma escala natural única para investigar dados do mundo real. A Homologia Persistente soluciona esse problema ao variar continuamente o parâmetro t , gerando uma filtração de complexos aninhados. Ao aplicarmos o functor de homologia a essa filtração, obtemos um *módulo de persistência*.

Definição 3.9 (Decomponibilidade e Barcode). *Um módulo de persistência $\mathbb{U}$ é **indecomponível** se, para todo o par de módulos $\mathbb{V}$ e $\mathbb{W}$ tais que $\mathbb{U} \simeq \mathbb{V} \oplus \mathbb{W}$, um dos somandos for nulo. Um módulo $\mathbb{V}$ é **decomponível em módulos intervalares** se existe um multiconjunto $\mathcal{I}$ de intervalos de $\mathbb{R}^+$ tal que $\mathbb{V} \simeq \bigoplus_{I \in \mathcal{I}} \mathbb{B}[I]$. O multiconjunto $\mathcal{I}$, garantido pelo Teorema de Azumaya, é denominado **código de barras de persistência** (Barcode) de $\mathbb{V}$.*

Definição 3.10 (Diagrama de Persistência). *Seja $\text{Barcode}(\mathbb{V})$ o barcode de um módulo decomponível. Para cada intervalo no formato (a, b) no barcode, considere-se o ponto $(a, b) \in \mathbb{R}^2$. A coleção de todos estes pontos forma o multiconjunto chamado **diagrama de persistência**, denotado $\text{Diagram}(\mathbb{V})$.*

Embora os Diagramas de Persistência resumam o ciclo de vida das classes de homologia (nascimento a e morte b), eles habitam um espaço métrico não-linear. Para que possamos calcular médias, variâncias e aplicar algoritmos de Machine Learning diretamente nestes invariantes, utilizamos a vetorização contínua idealizada por Bubenik [4].

Definição 3.11 (Paisagem de Persistência). *Dado um diagrama de persistência com intervalos $\mathcal{B} = \{(a_i, b_i)\}_{i=1}^m$, define-se para cada ponto a função auxiliar:*

$$f_{(a,b)}(t) = \max(0, \min(t - a, b - t)).$$

A **paisagem de persistência** é a sequência de funções $\lambda_k : \mathbb{R} \rightarrow \mathbb{R}$ definidas por:

$$\lambda_k(t) = k\text{-ésimo maior valor do conjunto } \{f_{(a_i, b_i)}(t)\}_{i=1}^m,$$

adotando $\lambda_k(t) = 0$ caso $k > m$.

Definição 3.12 (Distância p -Paisagem). *A distância topológica entre duas paisagens λ e λ' é dada pela norma em espaços de Banach L^p :*

$$\Lambda_p(\lambda, \lambda') = \|\lambda - \lambda'\|_p = \left(\sum_{k=1}^{\infty} \int_{\mathbb{R}} |\lambda_k(t) - \lambda'_k(t)|^p dt \right)^{1/p}. \quad (2)$$

4 Inferência Estatística sobre Invariantes Topológicos

O desenvolvimento da Homologia Persistente e, em particular, das Paisagens de Persistência, forneceu-nos um espaço funcional contínuo para representar os dados. No entanto, o objetivo fundamental deste trabalho exige que avaliemos, com significância estatística, se a dinâmica estrutural da proteína MBP no seu estado *Apo* (aberta) diverge da sua dinâmica no estado *Holo* (fechada). Para tal, é necessário traduzir o espaço de Banach num domínio probabilístico clássico [9].

4.1 A Variável Aleatória Topológica

A fim de aplicar os métodos de inferência estatística tradicional, precisamos de reduzir a representação funcional da topologia a um escalar real que capture a magnitude global da persistência [11].

Seja $\lambda_k(t)$ a k -ésima função da paisagem de persistência gerada a partir da matriz de distâncias dinâmicas de uma dada conformação proteica. Definimos uma variável aleatória contínua X como a área total sob todas as curvas da paisagem de persistência:

$$X = \sum_{k=1}^{\infty} \int_{\mathbb{R}} \lambda_k(t) dt \quad (3)$$

Ao integrarmos as funções de paisagem no domínio real, a variável X corresponde à área total abrangida por todos os contornos $\lambda(k, t)$, $k \in \mathbb{N}$, de uma paisagem de persistência. [4]. Como as flutuações atômicas oriundas do Modelo de Rede Anisotrópica (ANM) possuem natureza estocástica, a paisagem gerada por cada amostra proteica é, conseqüentemente, uma realização empírica de um processo estocástico. Assim, X herda as propriedades de uma variável aleatória com uma distribuição de probabilidade subjacente (e desconhecida) com esperança matemática μ e variância σ^2 [9].

4.2 Formulação das Hipóteses

Consideremos duas populações teóricas independentes: a população das conformações fechadas da MBP, cuja variável aleatória topológica denotaremos por X_1 (com média μ_1), e a população das conformações abertas, denotada por X_2 (com média μ_2).

O nosso objetivo é determinar se a diferença observada nas áreas das paisagens de persistência entre os dois grupos reflete uma verdadeira divergência na dinâmica biomolecular ou se resulta de mero ruído amostral. Formulamos, assim, o seguinte teste de hipóteses [11]:

$$\begin{aligned} H_0 : \mu_1 = \mu_2 & \quad \left(\begin{array}{l} \text{A hipótese nula: as topologias médias são} \\ \text{idênticas} \end{array} \right) \\ H_a : \mu_1 \neq \mu_2 & \quad \left(\begin{array}{l} \text{A hipótese alternativa: as topologias mé-} \\ \text{dias diferem significativamente} \end{array} \right) \end{aligned}$$

Devido à estrutura do espaço de Banach, a variável X satisfaz a Lei dos Grandes Números e o Teorema Central do Limite [4]. Isso implica que, para uma amostra suficientemente grande ($n \rightarrow \infty$), a distribuição da média amostral $\bar{X}$ aproximar-se-ia de uma distribuição Normal. Contudo, em contextos biológicos e cristalográficos, o número de estruturas resolvidas com alta qualidade é frequentemente limitado.

4.3 O Teste de Permutação Não-Paramétrico

No estudo de Kovacev-Nikolic et al. (2016), a amostra disponível continha apenas $n = 14$ estruturas de MBP (sendo sete na forma aberta e sete na fechada) [11]. Com amostras tão diminutas, a suposição de normalidade exigida por testes paramétricos clássicos (como o teste t de Student) não pode ser garantida com rigor [9].

Para contornar esta limitação de forma matematicamente exata, emprega-se o **Teste de Permutação**. Este é um método de inferência não-paramétrico que não assume qualquer distribuição prévia (como a gaussiana) para os dados [9]. O procedimento lógico do teste baseia-se na combinatória dos rótulos das classes sob a validade da hipótese nula H_0 .

O algoritmo estatístico prossegue da seguinte forma:

1. **Estatística Observada:** Calcula-se a diferença absoluta entre as médias amostrais originais dos dois grupos: $T_{\text{obs}} = |\bar{X}_1 - \bar{X}_2|$.
2. **Permutação sob H_0 :** Se a hipótese nula for verdadeira, o facto de uma proteína ser categorizada como "Apo" ou "Holo" é irrelevante para o valor de X . Portanto, agrupam-se todas as observações numa única amostra de tamanho $N = n_1 + n_2$.
3. **Distribuição Empírica:** Permutam-se (embaralham-se) os rótulos originais de todas as formas possíveis. Para cada permutação i , calcula-se a nova estatística de teste T_i . No caso de $N = 14$ com grupos de 7, existem $\binom{14}{7} = 3432$ permutações distintas (ou 1716 combinações absolutas de divisão).
4. **Cálculo do Valor- p :** O valor- p empírico é a proporção de permutações que produzem uma diferença de médias tão ou mais extrema do que a diferença originalmente observada:

$$\text{Valor-}p = \frac{1}{M} \sum_{i=1}^M I(T_i \geq T_{\text{obs}}) \quad (4)$$

onde M é o número total de permutações e $I(\cdot)$ é a função indicadora, que assume o valor 1 se a condição for satisfeita e 0 caso contrário.

Se o valor- p calculado for inferior ao nível de significância adotado (tradicionalmente $\alpha = 0,05$), rejeitamos H_0 . No contexto do nosso problema biológico, uma rejeição de H_0 prova de forma cabal que a distinção topológica entre os estados da MBP é real e inerente à sua matriz de dinâmica [11], validando assim a eficácia das Paisagens de Persistência como método discriminatório.

A fundamentação deste teste serve como o selo de validação estatística da nossa modelagem. No entanto, a análise não se esgota na inferência estática. Ao comprovar que as distribuições são separáveis, o próximo passo lógico é extrair as variáveis topológicas vetorizadas e introduzi-las num ambiente de Aprendizagem de Máquina (Machine Learning), com o intuito de construir fronteiras de decisão preditivas para classificar novas estruturas moleculares.

Referências

- [1] A. R. Atilgan et al. “Anisotropy of Fluctuation Dynamics of Proteins with an Elastic Network Model”. Em: *Biophysical Journal* 80.1 (2001), pp. 505–515.
- [2] Frances C. Bernstein et al. “The Protein Data Bank: A Computer-based Archival File For Macromolecular Structures”. Em: *Journal of Molecular Biology* 112.3 (1977), pp. 535–542.
- [3] W. Boos e H. Shuman. “Maltose/Maltodextrin System of Escherichia coli: Transport, Metabolism, and Regulation”. Em: *Microbiology and Molecular Biology Reviews* 62.1 (1998), pp. 204–229.
- [4] Peter Bubenik. “Statistical topological data analysis using persistence landscapes”. Em: *Journal of Machine Learning Research* 16.1 (2015), pp. 77–102.
- [5] D. Bucher, Barry J. Grant e J. Andrew McCammon. “Induced Fit or Conformational Selection? The Role of the Semi-closed State in the Maltose Binding Protein”. Em: *Biochemistry* 50 (2011), pp. 10530–10539.
- [6] Zixuan Cang, Lin Mu e Guo-Wei Wei. “Representability of algebraic topology for biomolecules in machine learning based scoring and virtual screening”. Em: *PLoS computational biology* 14.1 (2018). Preprint originalmente submetido em 2015 (arXiv:1510.00953), e1005929.
- [7] Zixuan Cang et al. *A topological approach for protein classification*. Preprint submetido em Outubro de 2015. Out. de 2015.
- [8] Corinna Cortes e Vladimir Vapnik. “Support-Vector Networks”. Em: *Machine Learning* 20.3 (1995), pp. 273–297. DOI: [10.1007/BF00994018](https://doi.org/10.1007/BF00994018).
- [9] Jay L. Devore. *Probabilidade e Estatística para Engenharia e Ciências*. 8ª ed. São Paulo, Brasil: Cengage Learning, 2012.
- [10] S. Hudault, J. Guignot e A. L. Servin. “Escherichia coli strains colonising the gastrointestinal tract protect germfree mice against Salmonella typhimurium infection”. Em: *Gut* 49.1 (2001), pp. 47–55.
- [11] Violeta Kovacev-Nikolic et al. “Using persistent homology and dynamical distances to analyze protein binding”. Em: *Statistical Applications in Genetics and Molecular Biology* 15.1 (2016), pp. 19–38.
- [12] Ana Carolina Lorena e André C. P. L. F. de Carvalho. “Uma Introdução às Support Vector Machines”. Em: *RITA (Revista de Informática Teórica e Aplicada)* 14.2 (2007), pp. 43–67.
- [13] D. Seeliger e B. L. de Groot. “Conformational Transitions upon Ligand Binding: Holo-Structure Prediction from Apo Conformations”. Em: *PLoS Computational Biology* 6.1 (2010), e1000634.
- [14] John C. Spurlino, Guang-Ying Lu e Florante A. Quioco. “The 2.3-Å Resolution Structure of the Maltose- or Maltodextrin-binding Protein, A Primary Receptor of Bacterial Active Transport and Chemotaxis”. Em: *THE JOURNAL OF BIOLOGICAL CHEMISTRY* 266.8 (1991).
- [15] Joshua B. Tenenbaum, Vin de Silva e John C. Langford. “A Global Geometric Framework for Nonlinear Dimensionality Reduction”. Em: *Science* 290.5500 (2000), pp. 2319–2323. DOI: [10.1126/science.290.5500.2319](https://doi.org/10.1126/science.290.5500.2319).

- [16] R. Tinarrage. *Topological Data Analysis: A Summer Course*. Material de curso, notas de aula sobre Homologia Persistente e Complexos Simpliciais. 2021.
- [17] R. Van Houdt e C. W. Michiels. “Role of bacterial cell surface structures in *Escherichia coli* biofilm formation”. Em: *Research in Microbiology* 156.5-6 (2005), pp. 626–633.