



UNIVERSIDADE FEDERAL DE SERGIPE  
CENTRO DE CIÊNCIAS E TECNOLOGIA  
DEPARTAMENTO DE MATEMÁTICA  
CURSO BACHARELADO EM MATEMÁTICA  
APLICADA E COMPUTACIONAL



## Análise Topológica de Dados Aplicada a dados de Biologia

Autor: Anthony dos Anjos Marques

São Cristóvão - SE

Julho, 2026



UNIVERSIDADE FEDERAL DE SERGIPE  
CENTRO DE CIÊNCIAS E TECNOLOGIA  
DEPARTAMENTO DE MATEMÁTICA  
CURSO BACHARELADO EM MATEMÁTICA  
APLICADA E COMPUTACIONAL



## Análise Topológica de Dados Aplicada a dados de Biologia

**Autor:** Anthony dos Anjos Marques

**Orientador:** Prof. Dr. Danilo Dias da Silva

Trabalho de Conclusão de Curso apresentado como requisito parcial de avaliação, da disciplina Monografia II, orientado pelo Prof. Dr. Danilo Dias da Silva, no Curso de Bacharelado em Matemática Aplicada e Computacional, da Universidade Federal de Sergipe - UFS, no segundo semestre letivo de 2026.

São Cristóvão - SE

Julho, 2026

## Análise Topológica de Dados Aplicada a dados de Biologia

Trabalho de Conclusão de Curso apresentado pelo aluno Anthony dos Anjos Marques ao curso de Bacharelado em Matemática Aplicada e Computacional/DMA/UFS em 24/07/2026, como requisito de avaliação final do Trabalho de Conclusão de Curso, sob a avaliação da Banca Examinadora constituída pelos seguintes professores:

---

Nome completo com titulação (orientador/a)

---

Nome completo com titulação (examinador/a convidado/a interno/a)

---

Nome completo com titulação (examinador/a convidado/a externo/a)

---

Nome completo com titulação (examinador/a suplente)


# Sumário

|          |                                                                    |           |
|----------|--------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introdução</b>                                                  | <b>1</b>  |
| <b>2</b> | <b>Contexto Biológico e Extração da Dinâmica Estrutural</b>        | <b>2</b>  |
| 2.1      | A Proteína de Ligação à Maltose (MBP) . . . . .                    | 2         |
| 2.2      | O Modelo de Rede Anisotrópica (ANM) . . . . .                      | 4         |
| 2.3      | Construção do Espaço Métrico . . . . .                             | 5         |
| <b>3</b> | <b>Fundamentos de Topologia Algébrica e Homologia Persistente</b>  | <b>6</b>  |
| 3.1      | Complexos Simpliciais . . . . .                                    | 6         |
| 3.2      | Grupos de Homologia . . . . .                                      | 8         |
| 3.3      | Inferência Topológica . . . . .                                    | 12        |
| 3.4      | Módulos de Persistência . . . . .                                  | 15        |
| <b>4</b> | <b>Inferência Estatística sobre Invariantes Topológicos</b>        | <b>16</b> |
| 4.1      | A Variável Aleatória Topológica . . . . .                          | 16        |
| 4.2      | Formulação das Hipóteses . . . . .                                 | 17        |
| 4.3      | O Teste de Permutação Não-Paramétrico . . . . .                    | 17        |
| <b>5</b> | <b>Redução de dimensionalidade e Aprendizado de Máquina</b>        | <b>18</b> |
| 5.1      | Visualização Não-Linear: ISOMAP e Gráfico Scree . . . . .          | 18        |
| 5.2      | Classificação com SVM . . . . .                                    | 20        |
| 5.3      | Validação Cruzada . . . . .                                        | 21        |
| <b>6</b> | <b>O Desvio Quadrático Médio (RMSD)</b>                            | <b>21</b> |
| 6.1      | Formulações Algébricas e o Algoritmo de Kabsch . . . . .           | 22        |
| <b>7</b> | <b>Metodologia</b>                                                 | <b>23</b> |
| 7.1      | Aquisição e Preparação do Conjunto de Dados . . . . .              | 24        |
| 7.2      | Extração da Dinâmica Estrutural e Construção do Espaço Métrico . . | 24        |
| 7.3      | Filtragem de Vietoris-Rips e Paisagens de Persistência . . . . .   | 26        |
|          | <b>Referências</b>                                                 | <b>28</b> |

# 1 Introdução

A biologia estrutural tem passado por uma revolução quantitativa nas últimas décadas, impulsionada pela necessidade de compreender não apenas a estrutura estática das macromoléculas, mas também a sua dinâmica e flexibilidade funcional. Nesse contexto, proteínas não são entidades rígidas; elas operam como nanomáquinas complexas que transitam entre diferentes estados conformacionais para exercerem suas funções biológicas, como a catálise enzimática e o transporte de ligantes. A distinção entre as teorias clássicas de interação proteína-ligante — do modelo rígido de chave-fechadura aos modelos modernos de encaixe induzido (*induced fit*) e seleção conformacional (*conformational selection*) — evidencia a necessidade de ferramentas matemáticas capazes de capturar a essência da dinâmica molecular.

Neste contexto, a Proteína de Ligação à Maltose (MBP — *Maltose-Binding Protein*), encontrada na bactéria *Escherichia coli*, apresenta-se como um modelo de estudo ideal. A MBP atua no transporte de maltodextrinas e transita fundamentalmente entre duas conformações: o estado *Apo* (aberto e livre de ligante) e o estado *Holo* (fechado e associado ao ligante). A compreensão e a distinção exata desses estados desafiam as métricas geométricas tradicionais, como o Desvio Quadrático Médio (RMSD), que frequentemente falham em capturar correlações não-lineares sutis ou variações dinâmicas globais na estrutura da proteína.



**Figura 1:** Representação das conformidades da MBP. Fonte: Adaptado de Bucher et al. [5].

Para contornar as limitações da análise puramente geométrica, modelos baseados na física estatística e em simulações de grão grosso (*coarse-grained*), como o Modelo de Rede Anisotrópica (ANM — *Anisotropic Network Model*), tornaram-se cruciais. Ao modelar a proteína como um sistema de massas e molas, o ANM permite a construção de uma Matriz Hessiana que, após decomposição espectral e foco nos modos normais de baixa frequência, gera uma Matriz de Correlação Cruzada. Essa matriz quantifica como as flutuações de diferentes resíduos de aminoácidos estão acopladas dinamicamente, fornecendo uma “assinatura física” do comportamento global da macromolécula.

O ponto central deste trabalho reside na transição do domínio da biofísica para o da matemática pura e aplicada, especificamente através da Análise Topológica de Dados (TDA — *Topological Data Analysis*). A partir da matriz de correlação cruzada, define-se uma pseudométrica que transforma a dinâmica da proteína em

um espaço métrico. Utilizando o ferramental da Homologia Persistente, filtrações de complexos simpliciais (como o Complexo de Vietoris-Rips) são construídas para acompanhar a evolução das características topológicas — componentes conexas e ciclos unidimensionais — ao longo de diferentes escalas de distância.

Diferente das abordagens clássicas, a topologia se preocupa com a forma e a conectividade intrínseca dos dados, sendo invariante a deformações contínuas. Extraímos essas assinaturas topológicas por meio de Paisagens de Persistência (*Persistence Landscapes*), que mapeiam os dados topológicos, originalmente discretos e de difícil manipulação algébrica, em um espaço de funções de Banach. Esta transformação garante a estabilidade dos dados e permite a integração direta com métodos de estatística clássica e algoritmos de *Machine Learning*.

Por fim, com as representações topológicas traduzidas para o escopo numérico, aplica-se o Teste de Permutação para validação estatística da separabilidade das conformações, além do treinamento de um classificador supervisionado baseado em Máquinas de Vetores de Suporte (SVM — *Support Vector Machines*).

Portanto, o objetivo fundamental deste trabalho é investigar, fundamentar e aplicar a Análise Topológica de Dados e a Homologia Persistente na extração de características dinâmicas de estruturas biomoleculares, utilizando a MBP como caso prático. Busca-se demonstrar que a união entre a teoria de grafos físicos (ANM) e os invariantes topológicos fornece um arcabouço rigoroso e superior para a classificação de estados proteicos.

## 2 Contexto Biológico e Extração da Dinâmica Estrutural


Para que as ferramentas da Análise Topológica de Dados (TDA) possam ser aplicadas com rigor, é necessário primeiramente traduzir o comportamento físico do objeto de estudo em um espaço métrico bem definido. Nesta seção, apresentamos o sistema biológico sob análise — a Proteína de Ligação à Maltose (MBP) — e descrevemos como o Modelo de Rede Anisotrópica (ANM) é utilizado para mapear suas flutuações dinâmicas, culminando na construção de uma matriz de distâncias que servirá como substrato para as filtrações topológicas subsequentes.

### 2.1 A Proteína de Ligação à Maltose (MBP)

A *Maltose-Binding Protein* (MBP) é uma macromolécula essencial no sistema de captação e transporte de maltodextrinas na bactéria *Escherichia coli* [3, 14]. Estruturalmente, a MBP é dividida em dois domínios globulares principais interconectados por uma região de dobradiça flexível (*hinge*).


A relevância da MBP para este estudo reside na sua mecânica funcional: ela atua transitando predominantemente entre dois estados conformacionais. Na ausência de um ligante, a proteína adota uma conformação *Apo* (aberta). Quando há a presença e ligação do açúcar (como a maltose), ela transita para a conformação *Holo*

(fechada), aprisionando o substrato. Historicamente, a transição entre esses estados gerou debates entre modelos clássicos, como o Encaixe Induzido (*Induced Fit*), onde o ligante força o fechamento, e a Seleção Conformacional (*Conformational Selection*) [5], onde a proteína já oscila naturalmente para a forma fechada e o ligante apenas estabiliza essa forma.



**Figura 2:** Representação das transições conformacionais da MBP. Da esquerda para a direita: Estado Aberto, Semi-fechado transitente e Fechado estabilizado pelo ligante (em vermelho). (A) A apoproteína é suficientemente flexível para exibir movimentos de abertura para fechamento, e o papel do ligante é estabilizar a forma fechada. (B) A proteína não ligada é incapaz de atingir a forma fechada, e a plasticidade estrutural é dependente do ligante. (C) Uma combinação das etapas A e B é necessária para atingir a conformação fechada. Fonte: Adaptado de Bucher et al. [5].

Independentemente do modelo biológico exato, o desafio matemático é claro: diferenciar essas duas classes (Aberta e Fechada) com base em suas propriedades estruturais e dinâmicas, superando métricas de alinhamento puramente rígidas e geométricas que não capturam as complexas correlações espaciais das macromoléculas em movimento.



**Figura 3:** Vistas lateral e superior da MBP, mostrando o tamanho e a forma do sítio de ligação que é modulado pelo estado conformacional da proteína. A cor vermelha indica que os resíduos estão próximos ao centro de massa da proteína, onde o sítio de ligação está localizado. As estruturas de raios X são mostradas para o estado aberto não ligado (entrada PDB 1OMP) e para o estado fechado ligado (entrada PDB 3MBP). Fonte: Adaptado de Bucher et al. [5].

## 2.2 O Modelo de Rede Anisotrópica (ANM)

Para capturar a dinâmica intrínseca da MBP sem o custo computacional proibitivo das simulações completas de Dinâmica Molecular, adota-se uma abordagem de grão grosso (*coarse-grained*) baseada em física estatística: o Modelo de Rede Anisotrópica (ANM) [1].

No ANM, a estrutura tridimensional da proteína é abstraída como um grafo espacial. Cada resíduo de aminoácido é representado unicamente por seu átomo de Carbono-alfa ( $C_\alpha$ ), que atua como um nó neste grafo. Interações interatômicas são modeladas como um sistema de molas elásticas que conectam nós localizados dentro de um raio de corte predefinido [1].

O comportamento deste sistema de massas e molas é governado por uma aproximação harmônica do potencial elástico da rede. A topologia física dessa rede é codificada na matriz de segundas derivadas do potencial, conhecida como Matriz Hessiana ( $H$ ).

*Nota.* A dedução analítica detalhada da energia potencial, a formulação tridimensional da Matriz Hessiana  $H$  e sua decomposição espectral (cálculo dos autovalores e



autovetores associados aos modos normais de vibração) envolvem um forte arcabouço de física mecânica e estatística que foge ao escopo puramente topológico do texto principal. Portanto, toda a fundamentação física e algébrica do ANM encontra-se detalhada no **Apêndice A**.

Do ponto de vista matemático para a classificação estrutural, o resultado fundamental do modelo ANM repousa na inversa pseudogeneralizada da Matriz Hessiana. A partir dos modos de baixa frequência (geralmente os 20 primeiros modos não triviais, que ditam os movimentos globais da proteína [1, 11]), constrói-se a **Matriz de Correlação Cruzada** ( $C$ ).

Cada elemento  $C_{ij}$  desta matriz quantifica a correlação entre as flutuações vectoriais do resíduo  $i$  e do resíduo  $j$ . Valores de  $C_{ij}$  próximos a 1 indicam movimentos altamente correlacionados (na mesma direção), próximos a  $-1$  indicam movimentos anticorrelações (direções opostas), e valores próximos a 0 indicam ausência de correlação dinâmica [11].

## 2.3 Construção do Espaço Métrico

A Análise Topológica de Dados opera sobre espaços de pontos equipados com uma noção formal de distância. A Matriz de Correlação Cruzada  $C$  é rica em informação dinâmica, mas não satisfaz os axiomas de uma métrica geométrica. Para viabilizar a análise topológica, aplica-se uma transformação que mapeia correlações em distâncias.

Definimos a distância dinâmica  $D_{ij}$  entre os resíduos  $i$  e  $j$  através da relação:

$$D_{ij} = 1 - |C_{ij}| \quad (1)$$

Com esta formulação, resíduos que possuem comportamentos dinâmicos altamente acoplados ( $|C_{ij}| \rightarrow 1$ ) apresentarão uma distância dinâmica próxima a zero ( $D_{ij} \rightarrow 0$ ), indicando que, topologicamente e funcionalmente, eles estão “próximos”. Inversamente, resíduos com dinâmicas independentes estarão distantes neste novo espaço métrico.

A matriz de distâncias dinâmicas  $D$  constitui o ponto de partida matemático deste trabalho. Ela nos permite abandonar as coordenadas euclidianas estáticas  $(x, y, z)$  da biologia clássica e passar a tratar a proteína como um espaço métrico discreto, sobre o qual definiremos complexos simpliciais e calcularemos grupos de homologia persistente nos próximos capítulos. É crucial notar que  $\mathbf{D}$  não é estritamente uma métrica, mas sim uma pseudométrica. Isto ocorre porque a identidade dos indiscerníveis não se verifica rigorosamente: dois resíduos distintos ( $i \neq j$ ) podem oscilar de forma perfeitamente correlacionada ( $|C_{ij}| = 1$ ), resultando numa distância  $D_{ij} = 0$ . Por outro lado, é possível demonstrar a desigualdade triangular é satisfeita, isto é,  $D_{ij} \leq D_{ik} + D_{kj}$ . A Topologia Algébrica, contudo, é perfeitamente bem definida sobre espaços pseudométricos, permitindo a construção de complexos simpliciais sem perda de generalidade teórica.

### 3 Fundamentos de Topologia Algébrica e Homologia Persistente

O estabelecimento de uma matriz de distâncias (ou pseudodistâncias) a partir de um sistema dinâmico fornece um espaço métrico discreto. Para extrair a arquitetura de comunicação global da biomolécula a partir desta pseudométrica, traduzimos este espaço num objeto combinatório contínuo. Nesta seção, fundamentamos o arcabouço matemático necessário para essa transição, introduzindo conceitos da Topologia Algébrica e da Homologia Persistente, usando como base o conteúdo de Tinarrage [16].

#### 3.1 Complexos Simpliciais

Espaços topológicos, como subconjuntos de  $\mathbb{R}^n$ , podem ser difíceis de manipular computacionalmente. Para descrevê-los de forma adequada, podemos tentar decompô-los em partes mais simples, uma generalização de grafos para dimensões superiores que permite a representação de espaços topológicos de forma combinatorial. As partes que consideraremos são os *simplexos padrão*. Lembramos que o simplexo padrão de dimensão  $n$  é o seguinte subconjunto de  $\mathbb{R}^{n+1}$ .

$$\Delta_n = \left\{ x = (x_1, \dots, x_{n+1}) \in \mathbb{R}^{n+1} \mid x_i \geq 0 \text{ e } \sum_{i=1}^{n+1} x_i = 1 \right\}.$$

**Definição 3.1.** Para qualquer conjunto de pontos  $a_1, \dots, a_k \in \mathbb{R}^n$ , definimos seu **fecho convexo** como:


$$\text{conv}(a_1, \dots, a_k) = \left\{ \sum_{i=1}^k t_i a_i \mid \sum_{j=1}^k t_j = 1, t_j \geq 0 \right\}.$$

Portanto, podemos dizer que  $\Delta_n$  é o fecho convexo dos vetores  $e_1, \dots, e_{n+1} \in \mathbb{R}^{n+1}$ , onde

$$e_i = (0, \dots, 1, 0, \dots, 0) \quad (\text{i-ésima coordenada igual a 1, as demais iguais 0}).$$

**Definição 3.2** (Complexo Simplicial). Seja  $V$  um conjunto (chamado de conjunto de vértices). Um **complexo simplicial** sobre  $V$  é um conjunto  $K$  de subconjuntos de  $V$  (chamados de **simplexos**) tal que, para todo  $\sigma \in K$  e todo  $\tau \subset \sigma$  não-vazio, temos  $\tau \in K$ .

Atualmente, um complexo simplicial não possui topologia. É um objeto puramente combinatório. No entanto, para representá-lo, podemos desenhá-lo da seguinte forma: coloque os pontos  $V$  no plano ou no espaço e, para cada simplexo de  $K$ , preencha o casco convexo de seus vértices. Podemos visualizar os simplexos das seguintes formas geométricas:



**Figura 4:** Representação dos simplexos: 0-Simplexo (Ponto ou vértice), 1-Simplexo (Segmento ou aresta), 2-Simplexo (Triângulo com face preenchida) e 3-Simplexo (Tetraedro preenchido).

Note que o simplexo  $\Delta_n$  é descrito por  $n + 1$  vértices. Vamos manter essa imagem geométrica em mente no que se segue.


Por convenção, ao falar de simplexos, usamos colchetes em vez de chaves. Por exemplo, o simplexo 0, 1 será denotado por  $[0, 1]$ .

Se  $\sigma \in K$  é um simplexo, seus subconjuntos não vazios  $\tau \subset \sigma$  são chamados de faces de  $\sigma$ , e  $\sigma$  é chamado de coface de  $\tau$ . Por exemplo,  $[0, 1]$  é uma face de  $[0, 1, 2]$ , e  $[0, 1, 2]$  é uma coface de  $[0, 1]$ .

**Exemplo 3.1.** Seja  $V = \{0, 1, 2\}$  e

$$K = \{[0], [1], [2], [0, 1], [1, 2], [2, 0]\}.$$

É um complexo simplicial de dimensão 1, onde todos os vértices se ligam. Pode ser representado dessa forma:



**Figura 5:** Simplexo de dimensão 1

**Exemplo 3.2.** Seja  $V = \{0, 1, 2\}$  e

$$K = \{[0], [1], [2], [0, 1], [1, 2], [0, 1, 2]\}.$$

Este não é um complexo simplicial. De fato, o simplexo  $[0, 1, 2]$  admite uma face  $[2, 0]$  que não está incluída em  $V$ .

Se  $\sigma$  é um simplexo, sua dimensão é definida como  $|\sigma| - 1$  (cardinalidade de  $\sigma$  menos 1). Se  $K$  é um complexo simplicial, sua dimensão é definida como a dimensão máxima de seus simplíces.

*Nota.* Ao desenhar um complexo simplicial, os s mplices n o devem se cruzar. No entanto, nem sempre   poss vel desenhar um complexo simplicial no plano (ou espa o) dessa maneira. Como exemplo, o grafo bipartido  $K_{3,3}$    um complexo simplicial de dimens o 1 (um grafo) que n o pode ser desenhado no plano sem se cruzar.

**Defini  o 3.3.** *Seja  $K$  um complexo simplicial com conjunto de v rtices  $V = \llbracket 1, \dots, n \rrbracket$ . Em  $\mathbb{R}^{n+1}$ , considere, para cada  $i \in \llbracket 0, n \rrbracket$ , o vetor  $e_i = (0, \dots, 1, 0, \dots, 0)$  (com a  $i$ - sima coordenada igual a 1 e as demais iguais a 0). Seja  $|K|$  o subconjunto de  $\mathbb{R}^{n+1}$  definido por:*


$$|K| = \bigcup_{\sigma \in K} \text{conv}(\{e_j, j \in \sigma\})$$

onde  $\text{conv}$  representa o fecho convexo (Defini  o 3.1). Munido da topologia de subespa o,  $(|K|, \tau_{|K|})$    um espa o topol gico, que denominamos *realiza  o topol gica de  $K$* .

**Defini  o 3.4.** *Seja  $(X, \mathcal{T})$  um espa o topol gico. Uma triangula  o de  $X$    um complexo simplicial  $K$  tal que sua realiza  o topol gica  $(|K|, \tau_{|K|})$    homeomorfa a  $(X, \mathcal{T})$ .*

**Exemplo 3.3.** Seguindo exemplo 3.1, o complexo simplicial  $K$    a triangula  o de um c rculo.

Dado um espa o topol gico, nem sempre   poss vel obter sua triangula  o. No entanto, quando isso   poss vel, existem muitas triangula  es diferentes. Por exemplo, todos os seguintes complexos simpliciais s o triangula  es equivalentes de um c rculo.



**Figura 6:** Triangula  es de um c rculo


## 3.2 Grupos de Homologia

Seja  $K$  um complexo simplicial abstrato. Para  $n \geq 0$ , definimos os conjuntos:

$$K_n = \{\sigma \in K \mid \dim(\sigma) \leq n\}$$

$$K_{(n)} = \{\sigma \in K \mid \dim(\sigma) = n\}.$$

O primeiro conjunto   um complexo simplicial, chamado de  $n$ -esqueleto de  $K$ . O segundo n o   um complexo simplicial em geral.



**Figura 7:** Exemplo do complexo simplicial  $K_n$  e o conjunto  $K_{(n)}$

Para extrair invariantes topológicos de um complexo simplicial, é necessário dotá-lo de uma estrutura algébrica que nos permita operar formalmente sobre os seus simplexos.

**Definição 3.5** ( $n$ -Cadeias). *Seja  $K$  um complexo simplicial e  $n \geq 0$ . O conjunto de  $n$ -cadeias de  $K$ , denotado  $C_n(K)$ , é o conjunto cujos elementos são as somas formais:*

$$\sum_{\sigma \in K_{(n)}} \epsilon_{\sigma} \cdot \sigma, \quad \text{onde } \forall \sigma \in K_{(n)}, \epsilon_{\sigma} \in \mathbb{Z}/2\mathbb{Z}.$$


*Este conjunto possui estrutura de espaço vetorial sobre o corpo  $\mathbb{Z}/2\mathbb{Z}$ , com a adição a ocorrer componente a componente.*

**Exemplo 3.4.** Considere o complexo simplicial

$$K = \{[0], [1], [2], [0, 1], [0, 2]\}.$$

As 0-cadeias  $C_0(K)$  consistem em 8 elementos:

$$C_0(K) = \{0, [0], [1], [2], [0] + [1], [0] + [2], [1] + [2], [0] + [1] + [2]\}$$




Por exemplo, em  $C_0(K)$ , temos

$$([0] + [1]) + ([0] + [2]) = [0] + [0] + [1] + [2] = [1] + [2].$$

Além disso, as 1-cadeias  $C_1(K)$  consistem em 4 elementos:

$$C_1(K) = \{0, [0, 1], [0, 2], [0, 1] + [0, 2]\}.$$



**Definição 3.6** (Operador de Fronteira). *Seja  $n \geq 1$  e  $\sigma = [x_0, \dots, x_n] \in K_{(n)}$  um simplexo de dimensão  $n$ . A **fronteira** de  $\sigma$  é o elemento de  $C_{n-1}(K)$  definido por:*

$$\partial_n \sigma = \sum_{\substack{\tau \subset \sigma \\ |\tau|=|\sigma|-1}} \tau.$$


O operador  $\partial_n$  estende-se por linearidade a uma aplicação linear  $\partial_n : C_n(K) \rightarrow C_{n-1}(K)$ . Para  $n = 0$ , define-se  $\partial_0$  como a aplicação nula.

**Exemplo 3.5.** Considere o complexo simplicial

$$K = \{[0], [1], [2], [3], [0, 1], [0, 2], [1, 2], [1, 3], [2, 3], [0, 1, 2]\}.$$

O simplexo  $[0, 1]$  tem as faces  $[0]$  e  $[1]$ . Logo,


$$\partial_1 [0, 1] = [0] + [1].$$



De modo semelhante, a fronteira da 1-cadeia  $[0, 1] + [1, 2] + [2, 0]$  é


$$\begin{aligned} \partial_1 ([0, 1] + [1, 2] + [2, 0]) &= \partial_1 [0, 1] + \partial_1 [1, 2] + \partial_1 [2, 0] \\ &= [0] + [1] + [0] + [2] + [2] + [0] \\ &= 0 \end{aligned}$$

uma vez que  $[0] + [0] = [1] + [1] = [2] + [2] = 0$  em  $C_0(K)$ .



O simplexo  $[0, 1, 2]$  possui as faces  $[0, 1]$ ,  $[1, 2]$  e  $[2, 0]$ . Logo,

$$\partial_2[0, 1, 2] = [0, 1] + [1, 2] + [2, 0].$$



A aplicação linear de fronteira  $\partial_n$  satisfaz a propriedade fundamental da topologia algébrica:  $\partial_{n-1} \circ \partial_n = 0$ . Esta identidade categórica permite-nos definir subespaços cruciais para o estudo das formas.

**Definição 3.7** (Ciclos e Fronteiras). *Sejam  $K$  um complexo simplicial e  $n \geq 0$ . Definimos:*

- *Os  $n$ -ciclos:*  $Z_n(K) = \ker(\partial_n) \subset C_n(K)$ ,
- *As  $n$ -fronteiras:*  $B_n(K) = \text{Im}(\partial_{n+1}) \subset C_n(K)$ .

**Exemplo 3.6.** Considere o complexo simplicial do Exemplo 3.5. O conjunto de ciclos  $Z_1(K)$  consiste nas cadeias


$$0, \quad [0, 1] + [1, 2] + [0, 2], \quad [0, 2] + [2, 3] + [0, 3] \quad \text{e} \quad [0, 1] + [1, 2] + [2, 3] + [0, 3].$$

As únicas fronteiras  $B_1(K)$  são dadas por

$$\partial_2(0) = 0 \quad \text{and} \quad \partial_2([0, 1, 2]) = [0, 1] + [0, 2] + [1, 2].$$

Vemos que as cadeias  $[0, 2] + [2, 3] + [0, 3]$  e  $[0, 1] + [1, 2] + [2, 3] + [0, 3]$  são homólogas. De fato,

$$[0, 2] + [2, 3] + [0, 3] = [0, 1] + [1, 2] + [2, 3] + [0, 3] + [0, 1] + [0, 2] + [1, 2].$$



**Corolário 3.1.** *Temos  $B_n(K) \subset Z_n(K)$ . Em outras palavras, toda fronteira é um ciclo.*

Demonstração em Tinarrage [16].


**Definição 3.8** (Grupo de Homologia e Números de Betti). *Seja  $K$  um complexo simplicial. O  $n$ -ésimo grupo de homologia de  $K$  é o quociente:*

$$H_n(K) = Z_n(K)/B_n(K).$$

*A dimensão deste espaço vetorial é o  $n$ -ésimo número de Betti, dado por  $\beta_n(K) = \dim H_n(K) = \dim Z_n(K) - \dim B_n(K)$ . Geometricamente,  $\beta_0$  conta o número de componentes conexas,  $\beta_1$  o número de "buracos" ou ciclos unidimensionais, e  $\beta_2$  o número de cavidades fechadas.*

### 3.3 Inferência Topológica

Na prática computacional, os dados raramente se apresentam nativamente como um complexo simplicial. Em vez disso, dispomos de nuvens de pontos em um espaço métrico. Para conectar a geometria dos dados com a topologia, utilizamos coberturas abertas e o Teorema do Nervo. Pensemos em subconjunto euclidiano finito  $X \subset \mathbb{R}^n$  como sendo uma amostra de um objeto contínuo,  $\mathcal{M} \subset \mathbb{R}^n$ . Compreender a topologia de  $\mathcal{M}$  nos daria um conhecimento interessante sobre o conjunto de dados  $X$ .



Seja  $\mathcal{M} \subset \mathbb{R}^n$  um subconjunto limitado, suponha que tenhamos uma amostra finita  $X \subset \mathcal{M}$ . Com a Homologia Persistente, pretendemos compreender a topologia




de  $\mathcal{M}$  através da sua homologia. Tentaremos estimar os grupos de homologia de  $\mathcal{M}$  para  $X$ . Infelizmente, a homologia de  $X$  está muito longe da homologia de  $\mathcal{M}$ . No entanto, se é amostrado perto o suficiente de  $\mathcal{M}$ , existe uma construção que permite recuperar o tipo de homotopia de  $\mathcal{M}$  para  $X$ , daí também seus grupos de homologia. Esta construção consiste no espessamento de  $X$ .

**Definição 3.9** ( $t$ -espessamento). *Seja  $X \subset \mathbb{R}^n$  e  $t \geq 0$ . O  $t$ -espessamento de  $X$ , denotado  $X^t$ , é o conjunto de pontos do espaço ambiente com o máximo de distância  $t$  de  $X$ :*

$$X^t = \{y \in \mathbb{R}^n \mid \exists x \in X, \|x - y\| \leq t\} = \bigcup_{x \in X} \bar{B}(x, t).$$

*Lê-se que  $X^t$  é uma união de bolas fechadas centradas em cada ponto de  $X$ .*



Observe que a última figura é um espessamento que possui o tipo de homotopia de um círculo:  $X^t \approx \mathcal{M}$ . Se pudermos selecionar tal  $t$ , então teremos acesso aos grupos de homologia de  $\mathcal{M}$ :

$$\forall i \geq 0, H_i(\mathcal{M}) \simeq H_i(X).$$


Se  $X \subset \mathbb{R}^n$  é um subconjunto finito e  $t \geq 0$ , queremos calcular os grupos de homologia  $H_0(X^t), \dots, H_n(X^t)$ . Para fazer isso, temos que encontrar uma triangulação de  $X^t$ , isto é, um complexo simplicial  $K$  homeomorfo a  $X$ . Na verdade, vamos procurar algo um pouco mais fraco: queremos um complexo simplicial  $K$  que seja equivalente homotopicamente a  $X$ .

É fácil representar os espessamentos  $X^t$  como complexos simpliciais, através da noção de coberturas.

**Definição 3.10.** *Seja  $X$  um espaço topológico, uma cobertura de  $X$  é a coleção  $\mathcal{U} = \{U_i\}_{1 \leq i \leq N}$  de subconjuntos  $U_i \subset X$  tal que*

$$\bigcup_{1 \leq i \leq N} U_i = X.$$

**Definição 3.11.** *Seja  $X$  um espaço topológico e  $\mathcal{U} = \{U_i\}_{1 \leq i \leq N}$  uma cobertura de  $X$ . O **nervo** de  $\mathcal{U}$  é o complexo simplicial com conjunto de vértices  $\{1, \dots, N\}$  cujos  $m$ -símplices são os subconjuntos  $\{i_1, \dots, i_m\} \subset \{1, \dots, N\}$  tais que  $\bigcap_{k=1}^m U_{i_k} \neq \emptyset$ . É denotado  $\mathcal{N}(\mathcal{U})$ .*



**Figura 8:** Representação da cobertura  $\mathcal{U}$  e do nervo  $\mathcal{N}(\mathcal{U})$

Note que a coleção  $\mathcal{V}^t = \{\bar{\mathcal{B}}(x, t) \mid x \in X\}$  é uma cobertura do espessamento  $X^t$  e cada componente são bolas fechadas. Consequentemente, podemos considerar seu nervo  $\mathcal{N}(\mathcal{V}^t)$ . Com isso, segue-se o teorema:

**Teorema 3.1.** *Suponha que  $Y$  seja um subconjunto de  $\mathbb{R}^n$ . Considere uma cobertura  $\mathcal{U} = \{U_i\}_{1 \leq i \leq N}$  de  $Y$  tal que cada um dos  $U_i$  são bolas fechadas e convexas. Então  $\mathcal{N}(\mathcal{U})$  é homotopia equivalente a  $Y$ . (Ver figura 8).*


Demonstração em Tinarrage [16].

**Definição 3.12** (Complexo de Čech). *Sejam  $X \subset \mathbb{R}^n$  finito e  $t \geq 0$ . Considere a coleção  $\mathcal{V}^t = \{\bar{\mathcal{B}}(x, t) \mid x \in X\}$ . O nervo desta coleção é denotado  $\check{\text{Cech}}^t(X)$  e é chamado de **complexo de Čech** de  $X$  no instante  $t$ . Explicitamente,  $\check{\text{Cech}}^t(X)$  é o complexo simplicial sobre os vértices  $X$  cujos simplices são os subconjuntos  $\{x_{i_1}, \dots, x_{i_m}\}$  tais que  $\bigcap_{k=1}^m \bar{\mathcal{B}}(x_{i_k}, t) \neq \emptyset$ .*

Como o complexo  $\check{\text{Cech}}^t(X)$  é homotopicamente equivalente ao espessamento  $X^t$ , o Teorema do Nervo garante que os seus respectivos grupos de homologia,  $H_i(\check{\text{Cech}}^t(X))$  e  $H_i(X^t)$ , são isomorfos. Consequentemente, torna-se viável calcular e acompanhar a evolução da homologia persistente do espessamento computacional  $X^t$  por meio do seu equivalente simplicial estruturado.

Embora o complexo de Čech capture perfeitamente a topologia da união das bolas de raio  $t$ , a verificação de interseções múltiplas é computacionalmente custosa. Como alternativa tratável, foca-se nas interações aos pares.

**Definição 3.13** (Complexo de Rips). *Sejam  $X = \{x_1, \dots, x_N\} \subset \mathbb{R}^n$  um conjunto finito e  $t \geq 0$ . O **complexo de Rips** de  $X$  no instante  $t$ , denotado  $\text{Rips}^t(X)$ , é o complexo do grafo  $G^t = (\check{\text{Cech}}^t(X))$  cujo conjunto de vértices é  $\{1, \dots, N\}$  e cujas arestas são os pares  $(i, j)$  tais que a distância entre eles obedece a  $\|x_i - x_j\| \leq 2t$ .*



**Figura 9:** Representação da diferença entre o grafo  $G^t$ , o complexo de Čech e o de Rips. Note que o complexo de Čech só possui 1 simplexo de dimensão 2, pois só há uma interseção entre 3 bolas, já o complexo de Rips, há 2 simplexos de dimensão 2, pois basta que as bolas possuam interseções dois a dois.

Observe que o complexo de Rips pode não ser homotopicamente equivalente ao correspondente Complexo Čech. No entanto, eles não estão ligados pela seguinte relação:

**Proposição 3.1.** *Let  $X \subset \mathbb{R}^n$  um conjunto finito. Seja  $X \subset \mathbb{R}^n$  um subconjunto finito. Para todo  $t \geq 0$ , temos*

$$\check{C}ech^t(X) \subset Rips^t(X) \subset \check{C}ech^{2t}(X).$$

Demonstração em Tinarrage [16].

### 3.4 Módulos de Persistência

A fixação de um limiar único  $t$  para a construção dos complexos impõe um viés metodológico forte, pois não há uma escala natural única para investigar dados do mundo real. A Homologia Persistente soluciona esse problema ao variar continuamente o parâmetro  $t$ , gerando uma filtração de complexos aninhados. Ao aplicarmos o functor de homologia a essa filtração, obtemos um *módulo de persistência*.

**Definição 3.14** (Decomponibilidade e Barcode). *Um módulo de persistência  $\mathbb{U}$  é **indecomponível** se, para todo o par de módulos  $\mathbb{V}$  e  $\mathbb{W}$  tais que  $\mathbb{U} \simeq \mathbb{V} \oplus \mathbb{W}$ , um dos somandos for nulo. Um módulo  $\mathbb{V}$  é **decomponível em módulos intervalares** se existe um multiconjunto  $\mathcal{I}$  de intervalos de  $\mathbb{R}^+$  tal que  $\mathbb{V} \simeq \bigoplus_{I \in \mathcal{I}} \mathbb{B}[I]$ . O multiconjunto  $\mathcal{I}$ , garantido pelo Teorema de Azumaya, é denominado **código de barras de persistência** (Barcode) de  $\mathbb{V}$ .*

**Definição 3.15** (Diagrama de Persistência). *Seja  $\text{Barcode}(\mathbb{V})$  o barcode de um módulo decomponível. Para cada intervalo no formato  $(a, b)$  no barcode, considere-se o ponto  $(a, b) \in \mathbb{R}^2$ . A coleção de todos estes pontos forma o multiconjunto chamado **diagrama de persistência**, denotado  $\text{Diagram}(\mathbb{V})$ .*

Embora os Diagramas de Persistência resumam o ciclo de vida das classes de homologia (nascimento  $a$  e morte  $b$ ), eles habitam um espaço métrico não-linear.

Para que possamos calcular médias, variâncias e aplicar algoritmos de Machine Learning diretamente nestes invariantes, utilizamos a vetorização contínua idealizada por Bubenik [4].

**Definição 3.16** (Paisagem de Persistência). *Dado um diagrama de persistência com intervalos  $\mathcal{B} = \{(a_i, b_i)\}_{i=1}^m$ , define-se para cada ponto a função auxiliar:*

$$f_{(a,b)}(t) = \max(0, \min(t - a, b - t)).$$

A **paisagem de persistência** é a sequência de funções  $\lambda_k : \mathbb{R} \rightarrow \mathbb{R}$  definidas por:

$$\lambda_k(t) = k\text{-ésimo maior valor do conjunto } \{f_{(a_i, b_i)}(t)\}_{i=1}^m,$$

adotando  $\lambda_k(t) = 0$  caso  $k > m$ .

**Definição 3.17** (Distância  $p$ -Paisagem). *A distância topológica entre duas paisagens  $\lambda$  e  $\lambda'$  é dada pela norma em espaços de Banach  $L^p$ :*

$$\Lambda_p(\lambda, \lambda') = \|\lambda - \lambda'\|_p = \left( \sum_{k=1}^{\infty} \int_{\mathbb{R}} |\lambda_k(t) - \lambda'_k(t)|^p dt \right)^{1/p}. \quad (2)$$

## 4 Inferência Estatística sobre Invariantes Topológicos

O desenvolvimento da Homologia Persistente e, em particular, das Paisagens de Persistência, forneceu-nos um espaço funcional contínuo para representar os dados. No entanto, o objetivo fundamental deste trabalho exige que avaliemos, com significância estatística, se a dinâmica estrutural da proteína MBP no seu estado *Apo* (aberta) diverge da sua dinâmica no estado *Holo* (fechada). Para tal, é necessário traduzir o espaço de Banach num domínio probabilístico clássico [9].

### 4.1 A Variável Aleatória Topológica

A fim de aplicar os métodos de inferência estatística tradicional, precisamos de reduzir a representação funcional da topologia a um escalar real que capture a magnitude global da persistência [11].

Seja  $\lambda_k(t)$  a  $k$ -ésima função da paisagem de persistência gerada a partir da matriz de distâncias dinâmicas de uma dada conformação proteica. Definimos uma variável aleatória contínua  $X$  como a área total sob todas as curvas da paisagem de persistência:

$$X = \sum_{k=1}^{\infty} \int_{\mathbb{R}} \lambda_k(t) dt \quad (3)$$

Ao integrarmos as funções de paisagem no domínio real, a variável  $X$  corresponde à área total abrangida por todos os contornos  $\lambda(k, t)$ ,  $k \in \mathbb{N}$ , de uma paisagem de persistência. [4]. Como as flutuações atômicas oriundas do Modelo de Rede Anisotrópica (ANM) possuem natureza estocástica, a paisagem gerada por cada amostra

proteica é, conseqüentemente, uma realização empírica de um processo estocástico. Assim,  $X$  herda as propriedades de uma variável aleatória com uma distribuição de probabilidade subjacente (e desconhecida) com esperança matemática  $\mu$  e variância  $\sigma^2$  [9].

## 4.2 Formulação das Hipóteses

Consideremos duas populações teóricas independentes: a população das conformações fechadas da MBP, cuja variável aleatória topológica denotaremos por  $X_1$  (com média  $\mu_1$ ), e a população das conformações abertas, denotada por  $X_2$  (com média  $\mu_2$ ).

O nosso objetivo é determinar se a diferença observada nas áreas das paisagens de persistência entre os dois grupos reflete uma verdadeira divergência na dinâmica biomolecular ou se resulta de mero ruído amostral. Formulamos, assim, o seguinte teste de hipóteses [11]:

$$\begin{aligned} H_0 : \mu_1 = \mu_2 & \quad \left( \begin{array}{l} \text{A hipótese nula: as topologias médias são} \\ \text{idênticas} \end{array} \right) \\ H_a : \mu_1 \neq \mu_2 & \quad \left( \begin{array}{l} \text{A hipótese alternativa: as topologias mé-} \\ \text{dias diferem significativamente} \end{array} \right) \end{aligned}$$

Devido à estrutura do espaço de Banach, a variável  $X$  satisfaz a Lei dos Grandes Números e o Teorema Central do Limite [4]. Isso implica que, para uma amostra suficientemente grande ( $n \rightarrow \infty$ ), a distribuição da média amostral  $\bar{X}$  aproximar-se-ia de uma distribuição Normal. Contudo, em contextos biológicos e cristalográficos, o número de estruturas resolvidas com alta qualidade é frequentemente limitado.

## 4.3 O Teste de Permutação Não-Paramétrico

No estudo de Kovacev-Nikolic et al. (2016), a amostra disponível continha apenas  $n = 14$  estruturas de MBP (sendo sete na forma aberta e sete na fechada) [11]. Com amostras tão diminutas, a suposição de normalidade exigida por testes paramétricos clássicos (como o teste  $t$  de Student) não pode ser garantida com rigor [9].

Para contornar esta limitação de forma matematicamente exata, emprega-se o **Teste de Permutação**. Este é um método de inferência não-paramétrico que não assume qualquer distribuição prévia (como a gaussiana) para os dados [9]. O procedimento lógico do teste baseia-se na combinatória dos rótulos das classes sob a validade da hipótese nula  $H_0$ .

O algoritmo estatístico prossegue da seguinte forma:

1. **Estatística Observada:** Calcula-se a diferença absoluta entre as médias amostrais originais dos dois grupos:  $T_{\text{obs}} = |\bar{X}_1 - \bar{X}_2|$ .
2. **Permutação sob  $H_0$ :** Se a hipótese nula for verdadeira, o facto de uma proteína ser categorizada como "Apo" ou "Holo" é irrelevante para o valor de  $X$ .

Portanto, agrupam-se todas as observações numa única amostra de tamanho  $N = n_1 + n_2$ .

3. **Distribuição Empírica:** Permutam-se (embaralham-se) os rótulos originais de todas as formas possíveis. Para cada permutação  $i$ , calcula-se a nova estatística de teste  $T_i$ . No caso de  $N = 14$  com grupos de 7, existem  $\binom{14}{7} = 3432$  permutações distintas (ou 1716 combinações absolutas de divisão).
4. **Cálculo do Valor- $p$ :** O valor- $p$  empírico é a proporção de permutações que produzem uma diferença de médias tão ou mais extrema do que a diferença originalmente observada:

$$\text{Valor-}p = \frac{1}{M} \sum_{i=1}^M I(T_i \geq T_{\text{obs}}) \quad (4)$$

onde  $M$  é o número total de permutações e  $I(\cdot)$  é a função indicadora, que assume o valor 1 se a condição for satisfeita e 0 caso contrário.

Se o valor- $p$  calculado for inferior ao nível de significância adotado (tradicionalmente  $\alpha = 0,05$ ), rejeitamos  $H_0$ . No contexto do nosso problema biológico, uma rejeição de  $H_0$  prova de forma cabal que a distinção topológica entre os estados da MBP é real e inerente à sua matriz de dinâmica [11], validando assim a eficácia das Paisagens de Persistência como método discriminatório.

A fundamentação deste teste serve como o selo de validação estatística da nossa modelagem. No entanto, a análise não se esgota na inferência estática. Ao comprovar que as distribuições são separáveis, o próximo passo lógico é extrair as variáveis topológicas vetorizadas e introduzi-las num ambiente de Aprendizagem de Máquina (Machine Learning), com o intuito de construir fronteiras de decisão preditivas para classificar novas estruturas moleculares.

## 5 Redução de dimensionalidade e Aprendizado de Máquina

Após a comprovação estatística via Teste de Permutação de que as assinaturas topológicas dos estados *Apo* e *Holo* da proteína MBP são fundamentalmente distintas [11], o objetivo final torna-se preditivo. Desejamos utilizar esse espaço de características para classificar novas estruturas moleculares. Contudo, as paisagens de persistência ou as próprias matrizes de distância habitam espaços de alta dimensionalidade, o que exige técnicas robustas de redução de dimensão para visualização e algoritmos de otimização convexa para classificação [12].

### 5.1 Visualização Não-Linear: ISOMAP e Gráfico Scree

A matriz de distância dinâmica  $D$ , oriunda da correlação cruzada do ANM, codifica a arquitetura de comunicação da proteína. Tentar visualizar esse objeto matemático diretamente em  $\mathbb{R}^2$  ou  $\mathbb{R}^3$  através de métodos lineares clássicos, como

a Análise de Componentes Principais (PCA) ou o Escalonamento Multidimensional (MDS) clássico, frequentemente distorce a geometria intrínseca dos dados. Isso ocorre porque tais métodos assumem que as distâncias entre os pontos são puramente euclidianas [15].

No caso de biomoléculas, os resíduos estão restritos a uma variedade diferenciável não-linear ditada por restrições estéricas e ligações covalentes. Para preservar essa geometria intrínseca, adotamos o algoritmo ISOMAP (*Isometric Feature Mapping*) [15].

---

**Algoritmo 1** Mapeamento Isométrico de Características (ISOMAP)

---

**Entrada:** Matriz de distâncias dinâmicas locais  $D$ , parâmetro de vizinhança  $k$ , dimensão alvo  $d$ .

**Saída:** Matriz de coordenadas projetadas  $Y \in \mathbb{R}^{N \times d}$ .

**Passo 1: Construção do Grafo de Vizinhança local**

- 1: Defina um grafo  $G$  sobre os  $N$  resíduos da proteína.
- 2: **para** cada resíduo  $i \in \{1, \dots, N\}$  **faça**
- 3:     Determine os  $k$  vizinhos mais próximos de  $i$  com base na matriz  $D$ .
- 4:     Adicione arestas no grafo  $G$  conectando  $i$  aos seus  $k$  vizinhos.
- 5:     Atribua à aresta  $(i, j)$  o peso  $D_{ij}$ .
- 6: **fim para**

**Passo 2: Estimativa da Matriz de Distâncias Geodésicas ( $D_G$ )**


- 7: Inicialize  $D_G(i, j) = D_{ij}$  se existir aresta, caso contrário  $D_G(i, j) = \infty$ .
- 8: Aplique o algoritmo de *Floyd-Warshall* ou *Dijkstra* para encontrar o caminho mínimo entre todos os pares de nós em  $G$ .
- 9: Atualize a matriz  $D_G$  de forma que  $D_G(i, j)$  contenha o comprimento geodésico mínimo entre  $i$  e  $j$ .

**Passo 3: Embutimento Métrico via Escalonamento Multidimensional**

- 10: Aplique o MDS clássico não-métrico à matriz de distâncias geodésicas  $D_G$ .
  - 11: Construa a matriz de produto interno centrada  $B = -\frac{1}{2}H(D_G^{(2)})H$ , onde  $H$  é a matriz de centralização e  $D_G^{(2)}$  contém o quadrado das distâncias geodésicas.
  - 12: Extraia os  $d$  maiores autovalores e seus autovetores correspondentes da matriz  $B$ .
  - 13: **retorne** Coordenadas  $Y$  geradas pelos  $d$  autovetores escalonados.
- 

O sucesso algébrico do algoritmo depende da escolha correta do parâmetro de dimensão embutida  $d$ . Para determinar o valor ideal, ou seja, a dimensionalidade intrínseca que captura a maior parte da variância da proteína sem introduzir ruído, recorre-se ao **Gráfico Scree** (*Scree plot*). Este gráfico plota o erro residual da projeção em função do número de dimensões. O ponto de inflexão da curva (frequentemente chamado de "cotovelo") indica a dimensão ótima. Estudos anteriores

demonstram que, para os dados da MBP, a projeção tridimensional ( $d = 3$ ) atinge a estabilidade do erro, sendo considerada apropriada para a separação geométrica dos estados conformacionais [11].



**Figura 10:** Redução de dimensão via Isomap para a estrutura 1OMP. A flexão abrupta no parâmetro  $d = 3$  indica a dimensionalidade intrínseca ideal para a representação das flutuações dinâmicas da MBP.

## 5.2 Classificação com SVM

Com o espaço de dados modelado e visualmente compreensível, o problema de distinguir proteínas abertas de fechadas reduz-se a um problema clássico de reconhecimento de padrões supervisionado. Para essa tarefa, empregamos as Máquinas de Vetores de Suporte (SVM — *Support Vector Machines*), fundamentadas na Teoria do Aprendizado Estatístico de Vapnik [8, 12].

Dado um conjunto de treinamento composto por pares  $(x_i, y_i)$ , onde  $x_i \in \mathbb{R}^n$  é o vetor de características (seja derivado da matriz  $D$  ou vetorizado da paisagem de persistência) e  $y_i \in \{-1, 1\}$  é o rótulo da conformação (*Apo* ou *Holo*), o objetivo do SVM é encontrar o hiperplano de separação ótimo.

Matematicamente, a fronteira de decisão é modelada pela equação:

$$w \cdot x + b = 0 \quad (5)$$

onde  $w$  é o vetor peso normal ao hiperplano e  $b$  é o viés.

O diferencial do SVM reside na maximização da *margem* de separação, definida como a distância geométrica entre o hiperplano e os exemplos de treinamento mais próximos (os vetores de suporte). Este problema de otimização é formulado como:

$$\begin{aligned} \min_{w, b} \quad & \frac{1}{2} \|w\|^2 \\ \text{sujeito a} \quad & y_i(w \cdot x_i + b) \geq 1, \quad \forall i \end{aligned}$$



Ao resolver o dual deste problema de programação quadrática através dos multiplicadores de Lagrange, garante-se uma solução ótima global. Para este estudo específico da MBP, como atestado pela análise de erro em trabalhos correlatos [11], um *kernel* linear é suficiente para separar os grupos com elevada acurácia, indicando que o pré-processamento topológico já transformou os dados em um espaço linearmente separável.

### 5.3 Validação Cruzada

Devido à escassez de dados estruturais de alta qualidade disponíveis no Protein Data Bank (PDB) para um subconjunto estrito de análises, a divisão tradicional do *dataset* em partições de treino e teste compromete a capacidade de aprendizado do modelo [12].

Para garantir a robustez estatística do classificador SVM sem desperdiçar dados, utiliza-se a estratégia de validação cruzada *Leave-One-Out* (LOOCV). Neste método empírico iterativo, se possuímos  $N$  amostras, o modelo é treinado  $N$  vezes. Em cada iteração  $i$ , o modelo utiliza  $N - 1$  exemplos para ajustar os parâmetros do hiperplano e realiza a predição na única amostra excluída.

A taxa de acerto final do modelo é obtida calculando a média das predições em todas as  $N$  iterações. Esta técnica garante um estimador de erro de generalização quase não-enviesado, assegurando que o classificador topológico possa ser aplicado a novas conformações da MBP na prática com confiança e rigor.

*Nota.* Com todo o aparato biofísico, algébrico-topológico, estatístico e computacional formalmente definido nos capítulos anteriores, o terreno encontra-se plenamente preparado. O capítulo subsequente consolida esta base teórica através da aplicação empírica na proteína de Ligação à Maltose, demonstrando de forma prática a geração de matrizes, as projeções visuais de ISOMAP e os resultados analíticos da classificação pelo algoritmo de suporte de vetores.

## 6 O Desvio Quadrático Médio (RMSD)

Na biofísica estrutural, a métrica canônica para quantificar a dissimilaridade geométrica entre duas conformações de uma mesma macromolécula é o Desvio Quadrático Médio, universalmente conhecido como RMSD (*Root-Mean-Square Deviation*). No contexto deste trabalho, o RMSD atua como a métrica de base. Ele nos fornece uma medida puramente estática e euclidiana da diferença entre as proteínas abertas (*Apo*) e fechadas (*Holo*), estabelecendo o referencial de comparação para as métricas topológicas que serão exploradas nos resultados [13].

Do ponto de vista matemático, o cálculo do RMSD entre duas matrizes de coordenadas não é uma simples diferença euclidiana ponto a ponto. Como as proteínas podem estar representadas em referenciais arbitrários no espaço tridimensional  $\mathbb{R}^3$ , uma comparação direta das coordenadas resultaria em um erro gigantesco originado por rotações e translações rígidas aleatórias. Portanto, o cálculo exige a formulação de um problema de otimização: é necessário encontrar a isometria (translação e

rotação) que minimiza a distância entre os conjuntos de pontos.

## 6.1 Formulações Algébricas e o Algoritmo de Kabsch

Sejam  $V$  e  $W$  duas matrizes de dimensão  $N \times 3$ , representando as coordenadas tridimensionais de  $N$  átomos (neste estudo, os  $N = 370$  carbonos-alfa da MBP) de duas conformações distintas. O RMSD ótimo é definido como:

$$\text{RMSD}(V, W) = \min_{R, \vec{t}} \sqrt{\frac{1}{N} \sum_{i=1}^N \|Rv_i + \vec{t} - w_i\|^2} \quad (6)$$

onde  $R$  é uma matriz de rotação ortogonal ( $R^T R = I$  e  $\det(R) = 1$ ) e  $\vec{t}$  é um vetor de translação.

Para resolver este problema de otimização de forma exata e determinística, implementamos o Algoritmo de Kabsch. O primeiro passo do algoritmo anula a translação  $\vec{t}$  ao centralizar ambos os conjuntos de dados em seus respectivos centros de massa. Dados os vetores centroides  $\bar{v} = \frac{1}{N} \sum v_i$  e  $\bar{w} = \frac{1}{N} \sum w_i$ , definimos as novas coordenadas centralizadas como  $v'_i = v_i - \bar{v}$  e  $w'_i = w_i - \bar{w}$ .

Com a translação resolvida, o problema reduz-se a encontrar a matriz de rotação ótima  $R$ . Para isso, computa-se a matriz de covariância cruzada  $C$ :

$$C = (V')^T W' \quad (7)$$

O teorema de Kabsch demonstra que a rotação ótima é extraída aplicando-se a Decomposição em Valores Singulares (SVD) à matriz  $C$ . Seja a decomposição  $C = U \Sigma \tilde{V}^T$ , a matriz de rotação que minimiza a distância quadrática é dada por:

$$R = \tilde{V} S U^T \quad (8)$$

onde  $S$  é uma matriz identidade, exceto pelo último elemento diagonal, que assume o valor do determinante de  $\tilde{V} U^T$ , garantindo que a transformação seja uma rotação pura e não uma reflexão.

Toda essa estrutura algébrica foi computacionalmente implementada para o pré-processamento das 14 amostras cristalográficas, conforme formalizado no Algoritmo 2.

---

**Algoritmo 2** Cálculo do RMSD Ótimo (Algoritmo de Kabsch)

---

**Entrada:** Matrizes de coordenadas  $V, W \in \mathbb{R}^{N \times 3}$ .

**Saída:** Valor escalar do RMSD ótimo entre as estruturas.

**Passo 1: Centralização**

- 1: Calcule os centros de massa  $\bar{v}$  e  $\bar{w}$ .
- 2: **para**  $i = 1$  **até**  $N$  **faça**
- 3:      $v'_i \leftarrow v_i - \bar{v}$
- 4:      $w'_i \leftarrow w_i - \bar{w}$
- 5: **fim para**

**Passo 2: Matriz de Covariância e SVD**

- 6: Construa a matriz de covariância  $C = \sum_{i=1}^N (v'_i)(w'_i)^T$ .
- 7: Compute a SVD de  $C$ :  $[U, \Sigma, \tilde{V}] = \text{SVD}(C)$ .

**Passo 3: Rotação Ótima**

- 8:  $d \leftarrow \text{sinal}(\det(\tilde{V}U^T))$
- 9: Defina  $S = \text{diag}(1, 1, d)$ .
- 10:  $R \leftarrow \tilde{V}SU^T$

**Passo 4: Cálculo da Distância**

- 11: soma  $\leftarrow 0$
  - 12: **para**  $i = 1$  **até**  $N$  **faça**
  - 13:     soma  $\leftarrow$  soma +  $\|Rv'_i - w'_i\|^2$
  - 14: **fim para**
  - 15: **retorne**  $\sqrt{\text{soma}/N}$
- 

A obtenção da matriz de valores de RMSD cruzados entre todos os pares de proteínas MBP fornece o mapa estático da nossa amostra. Contudo, como será discutido nas seções subsequentes, o paradigma topológico propõe-se a ir além do alinhamento rígido, rastreando a correlação dinâmica intrínseca das flutuações estruturais que o RMSD, por definição, não consegue captar.

## 7 Metodologia

Com a fundamentação teórica e biológica devidamente estabelecida nos capítulos anteriores, este capítulo destina-se a descrever o processo computacional aplicado à Proteína de Ligação à Maltose (MBP). O percurso metodológico detalha desde a mineração e filtragem dos dados estruturais brutos — destacando a expansão inédita da base amostral clássica — até a estruturação dos dados no formato exigido pelas métricas topológicas e algoritmos de classificação.

## 7.1 Aquisição e Preparação do Conjunto de Dados

O estudo de Kovacev-Nikolic et al. (2016) [11] estabeleceu a prova de conceito da aplicação da homologia persistente à MBP utilizando uma amostra restrita de 14 estruturas tridimensionais (sendo 7 conformações abertas e 7 fechadas). Neste trabalho, essas 14 estruturas foram preservadas e processadas inicialmente para atuar como o nosso conjunto de calibração. Os códigos das aplicações práticas discutidas nesta seção foram implementados em Python e estão disponíveis no GitHub: <https://github.com/AnthonyMrqs/Analise-Topologica-de-Dados.git>.

Contudo, para conferir ineditismo e robustez estatística à pesquisa, bem como testar a capacidade de generalização espacial dos algoritmos, a base de dados foi substancialmente expandida. Realizou-se a mineração computacional de 29 novas estruturas de alta resolução da MBP diretamente do repositório *Protein Data Bank* (PDB) [2]. A rotulação das classes para o aprendizado supervisionado seguiu rigorosamente os metadados cristalográficos de cada arquivo: conformações *Apo* (abertas) correspondem às estruturas resolvidas sem ligantes acoplados, enquanto as conformações *Holo* (fechadas) consistem naquelas cristalizadas ativamente com maltose ou oligossacarídeos derivados.

O processamento algorítmico desses arquivos brutos (em formato `.cif`) exigiu a implementação de rotinas de limpeza de dados. Estruturas cristalográficas frequentemente contêm ruídos tridimensionais para a modelagem elástica, como moléculas de solvente, íons metálicos soltos e múltiplas cadeias polipeptídicas idênticas na célula unitária.

Por meio de *scripts* automatizados desenvolvidos na linguagem Python (suportados pela biblioteca `ProDy`), cada estrutura foi filtrada. O código varreu os arquivos e isolou exclusivamente as coordenadas espaciais euclidianas  $(x, y, z)$  dos átomos de carbono-alfa ( $C_\alpha$ ) pertencentes à **Cadeia A**.

Dado o grau de conservação da proteína da *E. coli* avaliada, este isolamento algorítmico culminou na geração de representações uniformes de grão grosso. Como resultado de saída desta etapa preliminar, obtivemos matrizes de coordenadas de dimensão  $370 \times 3$  para cada uma das proteínas amostradas, garantindo a isometria do número de nós (vértices) necessária para o processamento da matriz Correlação nas etapas seguintes.

## 7.2 Extração da Dinâmica Estrutural e Construção do Espaço Métrico

Após a padronização e o isolamento das coordenadas dos carbonos-alfa da cadeia A para todo o conjunto de dados (composto pelas estruturas de calibração e pelas 29 novas estruturas mineradas), procedeu-se à extração da dinâmica molecular elástica. Esse procedimento foi executado computacionalmente por meio da aplicação do Modelo de Rede Anisotrópica (ANM) [1]. Utilizando rotinas automatizadas baseadas no pacote `ProDy`, a matriz Hessiana de cada conformação da MBP foi construída e submetida à decomposição espectral. O comportamento mecânico global de flutuação foi obtido pelo truncamento nos 20 primeiros modos normais não-triviais

de baixa frequência, resultando nas matrizes de correlação cruzada  $C$  de dimensão  $370 \times 370$  para cada uma das amostras proteicas [11].

Para converter o comportamento dinâmico elástico em um espaço pseudométrico apto para o cálculo da homologia persistente, aplicou-se a transformação projetiva sobre cada entrada das matrizes de correlação cruzada geradas, calculando-se  $D_{ij} = 1 - |C_{ij}|$ . Essa operação dita que resíduos com acoplamento mecânico perfeito ( $|C_{ij}| = 1$ ) assumam distância dinâmica nula ( $D_{ij} = 0$ ), enquanto resíduos com oscilações independentes ou ortogonais assumam a distância máxima ( $D_{ij} = 1$ ). O fluxo computacional completo que automatiza o processamento elástico e o armazenamento dessas matrizes de distância funcional está formalizado no Algoritmo 3.

---

**Algoritmo 3** Fluxo Computacional para Extração da Matriz de Distância Dinâmica

---

**Entrada:** Lista de identificadores  $\mathcal{L} = \{id_1, id_2, \dots, id_M\}$ , Categoria da proteína  $c$  (Apo/Holo).

**Saída:** Salvamento das matrizes de distância em formato binário .npz.

```

1: Criar diretórios dataset/c e matrizes/c
2: para cada identificador  $id \in \mathcal{L}$  faça
    Etapa 1: Obtenção e Filtragem de Dados
3:     arquivo_cif  $\leftarrow$  ObterEstruturaPDB( $id$ , formato = cif)
4:      $\mathcal{E} \leftarrow$  AnalisarEstrutura(arquivo_cif)
5:     se  $C_\alpha$  é nulo então
6:         continue ▷ Descarta estruturas defeituosas
7:     fim se
    Etapa 2: Modelagem Física ANM
8:      $H \leftarrow$  ConstruirMatrizHessiana( $C_\alpha$ )
9:      $[\Lambda, V] \leftarrow$  CalcularModosNormais( $H$ )
    Etapa 3: Matriz de Correlação e Transformação Métrica
10:     $C \leftarrow$  CalcularCorrelaçãoCruzada( $\Lambda, V$ ) ▷ Gera matriz  $N \times N$ 
11:    Inicializar matriz de distância dinâmica  $D$  de dimensão  $N \times N$ 
12:    para  $i = 1$  até  $N$  faça
13:        para  $j = 1$  até  $N$  faça
14:             $D_{ij} \leftarrow 1 - |C_{ij}|$ 
15:        fim para
16:    fim para
    Etapa 4: Armazenamento Computacional
17:    caminho  $\leftarrow$  Concatenar(matrizes/c,  $id + \_matriz.npz$ )
18:    SalvarBinario(caminho,  $D$ )
19: fim para

```


---

Com as matrizes dinâmicas tridimensionais colapsadas em espaços métricos bidimensionais de  $370 \times 370$  entradas empíricas reais, o problema físico foi plenamente convertido em um problema matricial. O próximo passo do escopo metodológico dedica-se a aplicar as filtrações simpliciais sobre essas matrizes para a extração dos invariantes topológicos.

### 7.3 Filtração de Vietoris-Rips e Paisagens de Persistência

Com os espaços pseudométricos estabelecidos pelas matrizes de distância dinâmica  $D$ , o tratamento de dados adentra o domínio da Análise Topológica de Dados. O objetivo desta fase é converter matrizes discretas de proximidade em invariantes topológicos contínuos, capazes de quantificar a conectividade global de cada estado da proteína.

Para reconstruir a forma contínua das flutuações, computou-se o complexo simplicial de Vietoris-Rips para cada matriz de distância. Em termos de implementação algorítmica, definiu-se um parâmetro de limiar máximo de conexão (frequentemente adotado como  $t_{\max} = 0.7$ , uma vez que a pseudométrica opera no intervalo  $[0, 1]$ ). A Figura 11 ilustra a progressão geométrica desta filtração computacional, demonstrando como os carbonos-alfa isolados conectam-se para formar arestas, triângulos e tetraedros à medida que o parâmetro de escala evolui, solidificando a arquitetura latente da macromolécula.



**Figura 11:** Evolução geométrica do complexo de Vietoris-Rips ao longo da filtração, aplicada sobre uma amostra representativa de 100 carbonos-alfa da estrutura proteica 1OMP. Observa-se a formação progressiva de simplexes de dimensões superiores até a consolidação da topologia global da proteína. As faces de 3-Simplexo são mostradas em verde, os 2-Simplexo são mostrados em amarelo, os 1-Simplexos são mostrados como linhas e os 0-Simplexos são mostrados como pontos.

Após a construção da filtração, extraíram-se os intervalos de nascimento e morte para o primeiro grupo de homologia ( $H_1$ ), que corresponde aos ciclos ou "túneis" unidimensionais. A escolha metodológica pelo grau 1 decorre da constatação de que a cavidade do sítio de ligação da MBP — cuja dinâmica difere drasticamente

entre as conformações aberta e fechada — é capturada com máxima expressividade por este invariante [11].

Contudo, os intervalos de persistência obtidos habitam um espaço métrico não-linear, inviabilizando o uso direto em algoritmos estatísticos. Para contornar este obstáculo matemático, cada diagrama de persistência foi transformado na sua respectiva **Paisagem de Persistência** (Definição 3.16) [4].

A vetorização contínua das paisagens exigiu a fixação empírica de três parâmetros topológicos, baseados nas propriedades da amostra: o intervalo do limiar ( $t \in [0.0, 0.7]$ ), a resolução da discretização em 50 pontos equidistantes, e a extração estruturada de 73 funções (camadas) de paisagem. Para garantir o rigor numérico, intervalos topológicos que sobreviveram até o fim da filtração (morte no infinito) tiveram seu ciclo de vida truncado no limiar máximo do experimento.

O procedimento lógico exato responsável por transformar a pseudométrica biofísica no vetor final de características está delineado no Algoritmo 4. O vetor escalar resultante (de dimensão  $73 \times 50 = 3650$ ) posiciona formalmente as flutuações da proteína em um espaço de Banach, configurando o dado de entrada otimizado para os modelos preditivos.

---

**Algoritmo 4** Computação de Paisagens de Persistência em Espaço de Banach

---

**Entrada:** Matriz de distância  $D \in \mathbb{R}^{N \times N}$ , grau homológico  $g = 1$ , resolução  $R = 50$ , limiar de escala  $t_{\max} = 0.7$ , número de camadas  $K = 73$ .

**Saída:** Vetor descritor unidimensional  $v \in \mathbb{R}^{K \times R}$  da paisagem de persistência.

**Passo 1: Construção Simplicial e Extração de Homologia**

- 1:  $\mathcal{V} \leftarrow \text{ComplexoVietorisRips}(D, \text{distância máxima} = t_{\max})$
- 2:  $\mathcal{T} \leftarrow \text{CriarArvoreSimplicial}(\mathcal{V}, \text{dimensão máxima} = g + 1)$
- 3:  $\mathcal{I} \leftarrow \text{CalcularIntervalosDePersistencia}(\mathcal{T}, \text{grau} = g)$

**Passo 2: Tratamento e Truncamento de Singularidades**

- 4:  $\mathcal{I}_{\text{finito}} \leftarrow$  lista vazia
- 5: **para** cada intervalo (nascimento, morte) em  $\mathcal{I}$  **faça**
- 6:     **se** morte =  $\infty$  **então**
- 7:         morte  $\leftarrow t_{\max}$
- 8:     **fim se**
- 9:     Adicionar (nascimento, morte) em  $\mathcal{I}_{\text{finito}}$
- 10: **fim para**

**Passo 3: Mapeamento em Paisagem de Persistência**

- 11: **se**  $\mathcal{I}_{\text{finito}}$  está vazio **então**
- 12:     **retorne** Vetor nulo de dimensão  $(K \times R)$
- 13: **fim se**
- 14:  $P \leftarrow \text{PaisagemPersistencia}(\text{camadas} = K, \text{resolução} = R, \text{domínio} = [0, t_{\max}])$
- 15: Matriz funcional  $M \leftarrow P.\text{transformar}(\mathcal{I}_{\text{finito}})$

**Passo 4: Discretização e Vetorização**

- 16: **retorne**  $\text{Aplanar}(M)$       $\triangleright$  Achata a matriz funcional em um único vetor
-

## Referências

- [1] A. R. Atilgan et al. “Anisotropy of Fluctuation Dynamics of Proteins with an Elastic Network Model”. Em: *Biophysical Journal* 80.1 (2001), pp. 505–515.
- [2] Frances C. Bernstein et al. “The Protein Data Bank: A Computer-based Archival File For Macromolecular Structures”. Em: *Journal of Molecular Biology* 112.3 (1977), pp. 535–542.
- [3] W. Boos e H. Shuman. “Maltose/Maltodextrin System of Escherichia coli: Transport, Metabolism, and Regulation”. Em: *Microbiology and Molecular Biology Reviews* 62.1 (1998), pp. 204–229.
- [4] Peter Bubenik. “Statistical topological data analysis using persistence landscapes”. Em: *Journal of Machine Learning Research* 16.1 (2015), pp. 77–102.
- [5] D. Bucher, Barry J. Grant e J. Andrew McCammon. “Induced Fit or Conformational Selection? The Role of the Semi-closed State in the Maltose Binding Protein”. Em: *Biochemistry* 50 (2011), pp. 10530–10539.
- [6] Zixuan Cang, Lin Mu e Guo-Wei Wei. “Representability of algebraic topology for biomolecules in machine learning based scoring and virtual screening”. Em: *PLoS computational biology* 14.1 (2018). Preprint originalmente submetido em 2015 (arXiv:1510.00953), e1005929.
- [7] Zixuan Cang et al. *A topological approach for protein classification*. Preprint submetido em Outubro de 2015. Out. de 2015.
- [8] Corinna Cortes e Vladimir Vapnik. “Support-Vector Networks”. Em: *Machine Learning* 20.3 (1995), pp. 273–297. DOI: 10.1007/BF00994018.
- [9] Jay L. Devore. *Probabilidade e Estatística para Engenharia e Ciências*. 8ª ed. São Paulo, Brasil: Cengage Learning, 2012.
- [10] S. Hudault, J. Guignot e A. L. Servin. “Escherichia coli strains colonising the gastrointestinal tract protect germfree mice against Salmonella typhimurium infection”. Em: *Gut* 49.1 (2001), pp. 47–55.
- [11] Violeta Kovacev-Nikolic et al. “Using persistent homology and dynamical distances to analyze protein binding”. Em: *Statistical Applications in Genetics and Molecular Biology* 15.1 (2016), pp. 19–38.
- [12] Ana Carolina Lorena e André C. P. L. F. de Carvalho. “Uma Introdução às Support Vector Machines”. Em: *RITA (Revista de Informática Teórica e Aplicada)* 14.2 (2007), pp. 43–67.
- [13] D. Seeliger e B. L. de Groot. “Conformational Transitions upon Ligand Binding: Holo-Structure Prediction from Apo Conformations”. Em: *PLoS Computational Biology* 6.1 (2010), e1000634.
- [14] John C. Spurlino, Guang-Ying Lu e Florante A. Quioco. “The 2.3-Å Resolution Structure of the Maltose- or Maltodextrin-binding Protein, A Primary Receptor of Bacterial Active Transport and Chemotaxis”. Em: *THE JOURNAL OF BIOLOGICAL CHEMISTRY* 266.8 (1991).
- [15] Joshua B. Tenenbaum, Vin de Silva e John C. Langford. “A Global Geometric Framework for Nonlinear Dimensionality Reduction”. Em: *Science* 290.5500 (2000), pp. 2319–2323. DOI: 10.1126/science.290.5500.2319.



- [16] R. Tinarrage. *Topological Data Analysis: A Summer Course*. Material de curso, notas de aula sobre Homologia Persistente e Complexos Simpliciais. 2021.
- [17] R. Van Houdt e C. W. Michiels. “Role of bacterial cell surface structures in *Escherichia coli* biofilm formation”. Em: *Research in Microbiology* 156.5-6 (2005), pp. 626–633.